

Appunti di Ingegneria del Software

Appunti basati sulle lezioni di Davide Falessi

A.A. 2025/2026

Indice

1	Teoria della Misurazione e Scale di Misura	10
1.1	Introduzione alla Misurazione del Software	10
1.1.1	Definizioni Formali	10
1.1.2	Proprietà di una Metrica di Qualità	10
1.2	Tassonomia delle Scale di Misura	11
1.2.1	Scala Nominale e Ordinale	11
1.2.2	Scale Numeriche (Intervallo e Rapporto)	11
1.3	Modelli di Qualità: Lo Standard ISO/IEC 25010	12
1.4	Introduzione alle Metriche Object-Oriented	12
2	GQM+S, Stima dei Costi e Planning Poker	13
2.1	GQM+Strategies (Goal-Question-Metric + Strategies)	13
2.1.1	Il Reference Process (I 6 Step del GQM+S)	13
2.2	Introduzione alla Stima dei Costi	14
2.2.1	Componenti del Costo ed Overheads	14
2.2.2	Il Ruolo del Linguaggio di Programmazione	15
2.3	Tecniche di Stima	15
2.4	Planning Poker	15
2.4.1	Dinamiche e Regole del Gioco	16
2.4.2	Vantaggi e Consigli Pratici (Tips)	16
3	Introduzione all'Architettura Software	17
3.1	Cos'è un'Architettura Software	17
3.1.1	Architetture Intended vs Unintended	17
3.2	Il Modello 4+1 di Kruchten	18
3.3	Progettazione e Decision-Making	18
3.3.1	L'importanza dei Requisiti Non Funzionali	18
3.3.2	Trade-offs e il ruolo dell'Architetto	19
3.4	Documentazione: Viste e Punti di Vista	19
3.5	Software Product Lines (SPL)	19
3.6	Stili Architettureali	20
4	Debito Tecnico e Code Smells	21
4.1	Il Debito Tecnico (Technical Debt)	21
4.1.1	Cause e Conseguenze	21
4.1.2	Strategie di Gestione	22
4.2	Introduzione ai Code Smells	22
4.3	Catalogo dei "Worst Smells"	22
4.3.1	Esempi di Worst Smells	23

5	Machine Learning e Software Analytics per la Software Engineering	24
5.1	Definizione di Machine Learning, ruolo di statistica e informatica	24
5.2	Esempi d'uso: associazioni, classificazione, regressione	24
5.2.1	Apprendimento di associazioni	24
5.2.2	Classificazione	25
5.2.3	Regressione	25
5.3	Tipi di apprendimento: supervised, unsupervised, semi-supervised, reinforcement	25
5.3.1	Supervised learning	25
5.3.2	Unsupervised learning	26
5.3.3	Semi-supervised learning	26
5.3.4	Reinforcement learning	26
5.4	Etica del data mining e del ML	26
5.5	Terminologia: istanze, feature, attributi nominali/numerici, output, modelli	27
5.5.1	Instances	27
5.5.2	Features o attributi	27
5.5.3	Output e modelli	27
5.6	Software quality e costo dei bug	28
5.7	Software analytics: definizione, obiettivi e fonti dati	28
5.8	AI/ML applicati alla Software Engineering	29
5.8.1	Applicazioni alla qualità	29
5.8.2	Applicazioni alla produttività	29
5.9	Defect prediction e ML for software defects	30
5.10	Pipeline: measure, clean data, analyze, model, explain	30
5.11	Estrazione dati da ITS e VCS e raccolta metriche	31
5.12	Identificazione difetti, labeling e defect dataset	31
5.13	Black-box models e necessità di spiegazione	32
5.14	XAI, GDPR, fairness, accountability, transparency	32
5.15	CMMI Level 5 e process improvement	33
5.16	Process chart e controllo statistico	33
5.17	Casi applicativi mostrati nelle slide, anche se solo introdotti	34
5.17.1	Simulatore di release e defect prediction	34
5.17.2	Traceability recovery	34
5.17.3	Defectiveness prediction via JIT	35
5.18	Riepilogo finale	35
6	SZZ: Identifying Buggy Entities	36
6.1	Contesto	36
6.1.1	Cos'è la defect prediction	36
6.1.2	Perché la qualità del dataset è fondamentale	36
6.1.3	Principali fonti di rumore nei dataset	36
6.2	Cos'è SZZ	37
6.2.1	Definizione e obiettivo	37
6.2.2	Uso del versioning e dell'annotation	37
6.2.3	Idea di partire dal fix per risalire al bug-introducing change	37
6.3	Come funziona SZZ	38
6.3.1	Identificazione del fix commit	38
6.3.2	Analisi delle linee modificate	38

6.3.3	Ricerca all'indietro dell'ultima modifica precedente	38
6.3.4	Differenza tra bug-fix change e bug-introducing change	39
6.4	Esempi nelle slide	39
6.4.1	Esempio 1: "When Do Changes Induce Fixes?"	39
6.4.2	Esempio 2: "The Impact of Refactoring Changes on the SZZ Algorithm: An Empirical Study"	40
6.5	Limiti di SZZ	40
6.5.1	Code additions	40
6.5.2	Regressive bugs	41
6.5.3	Refactoring	41
6.5.4	Imprecise backward search	41
6.5.5	Snoring	42
6.6	Da ricordare per l'esame	42
7	Leveraging Defects Lifecycle for Labeling Defective Classes	43
7.1	Contesto e obiettivo del lavoro	43
7.1.1	Defect prediction	43
7.1.2	Importanza del dataset	43
7.1.3	Labeling delle classi difettose	43
7.1.4	Obiettivo generale dello studio	44
7.2	Concetti fondamentali	44
7.2.1	SZZ	44
7.2.2	Earliest AV in JIRA	44
7.2.3	Defect lifecycle	44
7.2.4	Significato di IV, OV, FV e AV	44
7.3	SZZ: funzionamento e limiti	45
7.3.1	Come funziona SZZ	45
7.3.2	Uso di <code>git blame</code> / annotation mechanism	45
7.3.3	Bug introducing commit	45
7.3.4	Limiti del metodo	46
7.4	Aim dello studio e Research Questions	46
7.4.1	Idea di stable life-cycle dei defect	46
7.4.2	Research Questions	46
7.5	RQ1: Is the AV available and consistent?	47
7.5.1	Razionale	47
7.5.2	Design e selezione di progetti e bug	47
7.5.3	Risultati	48
7.5.4	Discussione e implicazioni pratiche	48
7.6	RQ2: Do methods have different accuracy in AV labeling?	48
7.6.1	Razionale	48
7.6.2	Selezione dei progetti	48
7.6.3	Formula della Proportion e significato di P	49
7.6.4	Varianti di Proportion	49
7.6.5	Metodi confrontati	50
7.6.6	Variabili dipendenti e definizione di TP, TN, FP, FN	50

8	Defect Labeling, Evaluation and Metrics	51
8.1	RQ3: Accuratezza nel labeling delle classi	51
8.1.1	Differenza rispetto a RQ2	51
8.1.2	Razionale	51
8.1.3	Unità di analisi	51
8.1.4	Design	51
8.1.5	Risultati	52
8.1.6	Discussione	53
8.2	RQ4: Identificazione delle feature importanti	53
8.2.1	Razionale	53
8.2.2	Feature selection	54
8.2.3	Correlation analysis	54
8.2.4	Standard Mean Relative Error	55
8.2.5	Risultati	55
8.2.6	Discussione	55
8.3	Figure, tabelle e workflow del paper	56
8.3.1	Diagramma del defect lifecycle (Fig. 1.1)	56
8.3.2	Workflow del predicted AV (Fig. 3.1)	56
8.3.3	Workflow del class labeling (Fig. 3.2)	56
8.3.4	Workflow della creazione dei complete datasets (Fig. 3.3)	57
8.3.5	Feature selection e correlation analysis (Fig. 3.4 e Fig. 3.5)	57
8.3.6	Interpretazione di grafici, boxplot e tabelle comparative	57
8.4	Evaluation of Machine Learning Models	57
8.4.1	Training, testing e tuning	57
8.4.2	Perché l'errore sul training set non basta	58
8.4.3	Training set vs test set	58
8.4.4	Dati rappresentativi	58
8.4.5	Problema dei dati limitati	58
8.5	Tecniche di validazione non temporali	58
8.5.1	Holdout	59
8.5.2	Stratification	59
8.5.3	Repeated holdout	59
8.5.4	K-fold cross-validation	59
8.5.5	Stratified k-fold cross-validation e repeated stratified cross-validation	59
8.5.6	Leave-one-out cross-validation	60
8.5.7	Bootstrap	60
8.6	Tecniche di validazione temporali	60
8.6.1	Time-series validation	60
8.6.2	Ordered holdout	60
8.6.3	Walk-forward	60
8.6.4	Importanza dell'ordine temporale	60
8.7	Performance metrics	61
8.7.1	Binary classifier	61
8.7.2	Confusion matrix e metriche base	61
8.7.3	Precision	61
8.7.4	Recall	62
8.7.5	Accuracy	62
8.7.6	Kappa	62

8.7.7	Dipendenza dal contesto applicativo	62
8.8	ROC curves e AUC	62
8.8.1	Threshold dependence	62
8.8.2	ROC curve	63
8.8.3	AUC	63
8.9	Collegamento tra i due PDF	63
8.9.1	Come il labeling influenza la qualità del dataset e del modello . . .	63
8.9.2	Realismo temporale e defect prediction	63
8.9.3	Scegliere bene metriche e validazione	64
8.10	Conclusioni finali	64
8.10.1	Risultati del paper Proportion e limiti dell'approccio Jira-based . .	64
8.10.2	Confronto Proportion vs SZZ	64
8.10.3	Conclusioni su validazione e metriche	64
9	Snoring: rumore nei dataset di defect prediction	65
9.1	Introduzione e contesto	65
9.2	Sleeping defects e snoring classes	65
9.3	Assegnazione dei difetti alle classi	66
9.4	SZZ: funzionamento e limiti	67
9.5	Research Questions dello studio	67
9.6	RQ1: To what extent do defects sleep?	68
9.6.1	Razionale	68
9.6.2	Design	68
9.6.3	Variabili	68
9.6.4	Risultati e discussione	68
9.7	RQ2: To what extent do classes snore?	68
9.7.1	Razionale	68
9.7.2	Design	68
9.7.3	Variabili	69
9.7.4	Risultati e discussione	69
9.8	RQ3: Impatto sulla valutazione dei classificatori	69
9.8.1	Razionale	69
9.8.2	Design	69
9.8.3	Metriche	69
9.8.4	Risultati e discussione	70
9.9	RQ4: Impatto sull'accuratezza predittiva	70
9.9.1	Razionale	70
9.9.2	Design	70
9.9.3	Risultati e discussione	70
9.10	RQ5: Quando no data è meglio di snoring data	70
9.10.1	Razionale	70
9.10.2	Design	71
9.10.3	Risultati e discussione	71
9.11	Conclusioni	71
9.12	Future works	71
9.13	Da ricordare	72

10 Effort-Aware Accuracy Metrics e valutazione dei classificatori	73
10.1 Contesto generale	73
10.1.1 Defect prediction e testing activity context	73
10.1.2 Perché l'accuratezza classica non basta	73
10.1.3 Effort-aware accuracy metrics	73
10.2 Concetti fondamentali	74
10.2.1 Definizione di EAM	74
10.2.2 Ranking delle entità difettose	74
10.2.3 Relazione tra effort e LOC da ispezionare	74
10.2.4 Differenza tra ranking per probabilità e ranking effort-aware	74
10.3 PofBx e NPofBx	74
10.3.1 Definizione di PofBx	74
10.3.2 Definizione di NPofBx	74
10.3.3 Significato della normalizzazione	74
10.3.4 Ranking per predicted probability / size	75
10.3.5 Differenza pratica tra i due approcci	75
10.4 Esempio introduttivo	75
10.4.1 Dataset di esempio	75
10.4.2 Significato di PofB20	75
10.4.3 Significato di NPofB20	75
10.4.4 Perché la normalizzazione migliora il numero di difetti trovati	75
10.5 Aim del lavoro e Research Questions	76
10.5.1 Problemi nell'uso delle EAM	76
10.5.2 Proposta di normalizzazione	76
10.5.3 Research Questions	76
10.6 RQ1	76
10.6.1 Numero di studi, progetti, EAM e classifier	76
10.6.2 Risultati principali	76
10.7 RQ2	77
10.7.1 Intuizione di base	77
10.7.2 Variabili indipendente e dipendente	77
10.7.3 PofB10–PofB90 e average	77
10.7.4 Preprocessing	77
10.7.5 Walk-forward	77
10.7.6 Classifier usati	78
10.7.7 Risultati	78
10.7.8 Relative gain	78
10.7.9 Cliff's delta e p-value	78
10.8 RQ3	78
10.8.1 Spearman rank correlation	78
10.8.2 Confronto ranking con e senza normalizzazione	78
10.8.3 Best classifier	79
10.8.4 Risultati e interpretazione pratica	79
10.9 RQ4	79
10.9.1 Confronto tra diverse NPofBx	79
10.9.2 Ruolo di x da 10 a 90	79
10.9.3 Average NPofB e confronto dei ranking	79
10.9.4 Risultati e best classifier	79

10.10	Figure, tabelle e grafici	79
10.10.1	Esempio PofB20 e NPofB20	80
10.10.2	Tabella delle EAM usate negli studi precedenti	80
10.10.3	Tabella dei relative gains	80
10.10.4	Tabella degli equivalent best classifiers	80
10.11	Main results e conclusioni	80
10.11.1	Superiorità delle NPofBs rispetto alle PofBs	80
10.11.2	Cambiamento del best classifier dopo la normalizzazione	80
10.11.3	Implicazioni pratiche	80
10.12	ACUME tool	81
10.12.1	Scopo	81
10.12.2	Input e output	81
10.12.3	Utilità per i ricercatori	81
11	Milestone 1: Dataset Creation	82
11.1	Obiettivo della Milestone 1	82
11.2	Assegnazione del progetto	82
11.3	Struttura del dataset CSV	83
11.4	Selezione delle release	83
11.5	Snapshot di release	83
11.6	Classi da considerare	84
11.7	Class metrics	84
11.8	Commit metrics	85
11.9	NSmells	85
11.10	Labeling della bugginess	86
11.11	Uso di SZZ e Proportion	86
11.12	ComputedAV e intervallo di release affette	87
11.13	Workflow operativo completo	87
11.14	Errori comuni da evitare	88
11.15	Da ricordare	88
12	Balancing	89
12.1	Problema del class imbalance	89
12.2	Effetto dello sbilanciamento sui classificatori	89
12.3	Undersampling	90
12.4	Oversampling	90
12.5	SMOTE	91
12.6	Confronto tra undersampling, oversampling e SMOTE	91
12.7	Lab	92
12.8	Weka API	92
12.8.1	Undersampling	92
12.8.2	Oversampling	92
12.8.3	SMOTE	93
12.9	Collegamento con il progetto	93
12.10	Da ricordare	94

13 Weka GUI e Feature Selection	95
13.1 Introduzione a Weka	95
13.2 Formato dati in Weka	95
13.3 Explorer: preprocessing e classificazione	96
13.4 Experimenter	97
13.5 Feature Selection: obiettivi	97
13.6 Filter approach	98
13.7 Info Gain e Spearman	98
13.7.1 Information Gain	98
13.7.2 Spearman correlation	98
13.8 Wrapper approach	99
13.9 Search strategies	99
13.10 Train, validation e test	100
13.11 Feature Selection in Weka	100
13.12 Lab e collegamento con il progetto	101
13.13 Da ricordare	102
 14 What If I Had No Smells?	 103
14.1 Introduzione ai code smells	103
14.1.1 Definizione ed esempi	103
14.1.2 Legame con il technical debt	103
14.1.3 Analisi storica e analisi controfattuale	103
14.2 Obiettivo del lavoro	104
14.2.1 Domanda centrale del paper	104
14.2.2 Significato della stima	104
14.2.3 Interesse pratico e di ricerca	104
14.3 What-if analysis method	104
14.3.1 Significato di what-if scenario	104
14.3.2 Azzerare gli smells mantenendo invariate le altre caratteristiche	104
14.3.3 Uso di modelli appresi su dati reali e applicati a dati sintetici	105
14.4 Contesto industriale	105
14.4.1 Progetti e tipi di smell analizzati	105
14.4.2 Ruolo di SonarQube e dei quality gates	105
14.4.3 Avoiding smells vs removing smells	105
14.4.4 Vantaggi e svantaggi dell'evitare smells a priori	105
14.5 Metodo dello studio	106
14.6 Metric selection e metric collection	106
14.6.1 Perché servono metriche oltre a Size e NSmells	106
14.6.2 Ruolo delle change metrics	106
14.6.3 Tabella delle metriche	106
14.6.4 Raccolta dei dati con SonarQube	106
14.6.5 Differenza temporale tra smells e difetti	107
14.6.6 Significato del diagramma di raccolta dati	107
14.7 Dataset manipulation	107
14.7.1 Definizione dei dataset A, B+, B e C	107
14.7.2 Perché B rappresenta lo scenario sintetico	107
14.7.3 Media delle feature e correlazione	108
14.7.4 Messaggio metodologico della manipolazione	108

14.8	Model selection	108
14.8.1	Classificatori confrontati	108
14.8.2	Uso della leave-one-out cross-validation	108
14.8.3	Criterio di scelta del modello migliore	108
14.8.4	Perché Bagging risulta il migliore	109
14.9	Results	109
14.9.1	Applicazione del modello ai dataset A, B+, B e C	109
14.9.2	Interpretazione del passaggio da 66 a 38 defective files in B+	109
14.9.3	Riduzione complessiva del 20% su A	109
14.9.4	Differenza tra riduzione sui file smelly e riduzione sull'intero dataset	109
14.10	Limiti e messaggi chiave	110
14.10.1	Perché il risultato non implica causalità certa	110
14.10.2	Natura ipotetica dello scenario senza smells	110
14.10.3	Evitare alcuni smells potrebbe non ridurre i difetti	110
14.10.4	Casi in cui accettare smells può essere ragionevole	110
14.10.5	Trade-off con costi, effort e time-to-market	110
14.10.6	Contributo principale del paper	111
14.10.7	Valore della what-if analysis e ruolo degli smells	111
14.10.8	Importanza di contestualizzare i risultati	111
15	Panoramica del modulo di Software Testing	113
15.1	Introduzione al modulo	113
15.2	Informazioni organizzative	113
15.2.1	Canali Teams	113
15.2.2	Ricevimento e comunicazione	114
15.3	Sillabo del modulo	114
15.4	Materiale didattico	114
15.5	Modalità di esame	115
15.6	Attività richieste: generazione dei test	115
15.6.1	Scelta delle classi	115
15.6.2	Test manuali	115
15.6.3	Test automatici	116
15.6.4	Integrazione nel build	116
15.7	Valutazione della qualità dei test	116
15.8	Varianti delle classi e uso degli LLM	117
15.9	Report finale e consegna	117
15.9.1	File <code>classes.txt</code>	118
15.9.2	Invio e discussione orale	118
15.10	Messaggi chiave della lezione	118

Capitolo 1

Teoria della Misurazione e Scale di Misura

1.1 Introduzione alla Misurazione del Software

La misurazione nel software engineering non è un fine, ma uno strumento decisionale di supporto. Come ricordano Lord Kelvin e Tom DeMarco, l'assenza di misurazione impedisce il controllo e, di conseguenza, il miglioramento dei processi e dei prodotti[cite: 330, 341].

1.1.1 Definizioni Formali

Secondo i modelli standard, è necessario distinguere tre concetti fondamentali:

- **Misura (Measure):** Rappresentazione numerica di una caratteristica o di un attributo di un prodotto o processo software (es. 5000 LOC, 30 mesi-uomo)[cite: 363, 364, 365, 368].
- **Metrica (Metric):** La scala o il sistema di misurazione utilizzato per quantificare una misura[cite: 352]. Definisce le regole di assegnazione dei valori (es. Complessità Ciclomatica, Densità dei Difetti)[cite: 353, 354].
- **Misurazione (Measurement):** Il processo pratico di assegnazione dei numeri alle misure utilizzando una metrica[cite: 357].

1.1.2 Proprietà di una Metrica di Qualità

Per essere considerata valida, una metrica deve soddisfare i seguenti criteri:

Rilevanza: Deve misurare un attributo significativo e importante del prodotto o processo software[cite: 380].

Oggettività: Il risultato deve basarsi su dati verificabili e riproducibili, non su opinioni o stime soggettive[cite: 381, 382].

Affidabilità e Consistenza: La metrica deve produrre risultati costanti in condizioni diverse e deve essere coerente con gli obiettivi del progetto[cite: 383, 384].

Usabilità: Il calcolo e l'interpretazione devono essere facili, intuitivi e non richiedere sforzi o risorse eccessive[cite: 385, 386].

Nota del Prof

La pertinenza di una metrica è strettamente legata al contesto di business. Un errore critico in un sistema assicurativo potrebbe riguardare l'accuratezza dei calcoli (oracolo) con conseguenze disastrose, mentre per un motore di ricerca come Google la priorità assoluta risiede nella disponibilità del servizio (uptime), dove anche poche ore di downtime globale risultano inaccettabili.

1.2 Tassonomia delle Scale di Misura

La scelta della scala utilizzata dipende dalla natura dei dati misurati e determina quali operazioni statistiche siano matematicamente applicabili[cite: 407, 459, 477].

1.2.1 Scala Nominale e Ordinale

- **Nominale:** Utilizzata per assegnare valori a etichette o categorie senza un ordine intrinseco o magnitudine (es. tipi di difetti: logica, UI, performance, sicurezza)[cite: 417, 418, 419]. Operazioni ammesse: Moda, frequenza[cite: 459].
- **Ordinale:** Prevede un ordine di rango per le categorie, ma la distanza o magnitudine tra i valori non è definita né significativa (es. priorità dei difetti: Critical, High, Medium, Low)[cite: 422, 423, 424]. Operazioni ammesse: Mediana[cite: 459].

Nota del Prof

Le scale ordinali, pur limitando le analisi statistiche alla mediana, offrono spesso una maggiore oggettività rispetto a scale numeriche forzate. Valutare la severità di un bug su una scala 0-100 introduce un'alta soggettività (es. la differenza tra 65 e 70 è arbitraria), mentre una distinzione qualitativa (Blocker vs Non-Blocker) risulta più robusta, netta e oggettiva.

1.2.2 Scale Numeriche (Intervallo e Rapporto)

In queste scale i valori sono assegnati in ordine di rango e la magnitudine della differenza tra i punti ha un significato reale e misurabile[cite: 427, 433].

- **Intervallo:** La magnitudine delle differenze è significativa, ma non possiede uno zero assoluto reale[cite: 427, 428].
- **Rapporto (Ratio):** È il tipo di scala più sofisticato, in cui la magnitudine delle differenze è calcolabile e possiede uno zero assoluto reale (es. LOC, sforzo, tempo)[cite: 433, 434, 435].

Statistiche ammesse per entrambe: Media, Deviazione Standard, Varianza, Range (per la scala di Rapporto sono ammessi anche coefficiente di variazione e media geometrica)[cite: 459].

1.3 Modelli di Qualità: Lo Standard ISO/IEC 25010

Lo standard ISO 25010 definisce una tassonomia dettagliata degli attributi di qualità (qualità del prodotto e qualità in uso)[cite: 33]. Le caratteristiche principali individuate dallo standard sono:

1. **Functional Suitability (Adeguatezza funzionale):** Completezza, correttezza e adeguatezza funzionale[cite: 39, 40, 41, 42].
2. **Performance Efficiency (Efficienza delle prestazioni):** Comportamento temporale, utilizzo delle risorse e capacità strutturale[cite: 43, 44, 45, 46].
3. **Security (Sicurezza):** Riservatezza, integrità, non ripudio, responsabilità e autenticità[cite: 47, 48, 49, 50, 51, 52].
4. **Maintainability (Manutenibilità):** Modularità, riusabilità, analizzabilità, modificabilità e testabilità[cite: 53, 54, 55, 56, 57, 58].

Nota del Prof

È cruciale distinguere sempre il modello di qualità dalle metriche: il modello (come l'ISO 25010) definisce *cosa* significa la qualità fornendone una tassonomia, mentre le metriche definiscono *come* quantificarla operativamente[cite: 30]. L'adozione di questi standard fallisce sistematicamente se manca la "buona fede" aziendale; l'uso delle metriche al solo scopo di ottenere certificazioni formali di facciata, senza mirare a un miglioramento sostanziale del prodotto, svalorizza l'utilità dell'intero sistema di valutazione ingegneristico.

1.4 Introduzione alle Metriche Object-Oriented

Le metriche object-oriented vengono impiegate per misurare la qualità dei sistemi software ad oggetti e identificare tempestivamente difetti di progettazione o futuri problemi di manutenibilità[cite: 68, 69]. Vanno sempre interpretate come indicatori di rischio e valutate in modo comparativo (rispetto a una baseline o a un trend) e non in senso assoluto[cite: 73].

Nota del Prof

In ambito manageriale, è molto più efficace adottare un approccio pratico basato sulle distribuzioni piuttosto che sulle medie globali. Risulta strategicamente più utile concentrare le attività di analisi, refactoring e test mirati esclusivamente sul 10% delle classi che presentano i valori peggiori di complessità (*outliers*), piuttosto che tentare di ottimizzare e riscrivere l'intero sistema in modo uniforme.

Capitolo 2

GQM+S, Stima dei Costi e Planning Poker

2.1 GQM+Strategies (Goal-Question-Metric + Strategies)

L'approccio GQM+Strategies (GQM+S) è una metodologia che combina il metodo classico GQM con l'identificazione delle migliori strategie per raggiungere gli obiettivi. Questo approccio collega a cascata gli obiettivi aziendali alla misurazione:

Business Goals → Software Goals → Questions → Measures → Strategies / Targets.

Nota del Prof

Il CQM originale è stato co-creato dal Professor Cantone. L'estensione "+ Strategies" serve ad associare l'azione tecnica al risultato voluto. Tutto parte dal Business: ogni feature o refactoring viene fatto in primis per raggiungere obiettivi aziendali.

2.1.1 Il Reference Process (I 6 Step del GQM+S)

Il processo si sviluppa in sei step principali per permettere il miglioramento continuo:

0. **Initialize:** Impegno (Commitment), Staffing e Responsabilità.
1. **Characterize:** Definire lo scope dell'applicazione e caratterizzare il contesto ambientale.
2. **Set Goals:** Analisi dello status quo, prioritizzazione degli obiettivi e costruzione della griglia goals-strategies.
3. **Choose Process:** Pianificare l'implementazione delle strategie e organizzare la raccolta/analisi dei dati.
4. **Execute Model:** Esecuzione delle strategie, raccolta dati e feedback.
5. **Analyze Results:** Analisi dei dati, revisione delle strategie e analisi costi/benefici.
6. **Package and Improve:** Adattamento dei goal e registrazione delle "lessons learned".

Nota del Prof

L'ultimo step di "packaging" si basa sul concetto di *Experience Factory*: lo scopo è impacchettare l'esperienza in una knowledge base per riutilizzarla in futuro.

Solo nelle slide (non spiegato a voce)

Esempi di utilizzo tipici:

- **Miglioramento del processo:** Ridurre lead time o rework (Metriche: cycle time, difetti sfuggiti).
- **Project management:** Migliorare prevedibilità (Metriche: milestone burndown, throughput).
- **Supporto decisionale:** Valutare l'adozione di nuove tecnologie (Metriche: esiti progetto pilota).

2.2 Introduzione alla Stima dei Costi

La stima si basa su tre domande fondamentali: quanto sforzo (*effort*) è richiesto, quanto tempo di calendario è necessario e qual è il costo totale dell'attività.

Nota del Prof

Bisogna distinguere l'effort (lavoro puramente impiegato) dal tempo di calendario: un'attività può richiedere poco sforzo ma molto tempo se le risorse non sono subito disponibili.

2.2.1 Componenti del Costo ed Overheads

Il costo include Hardware/Software, viaggi, formazione e l'Effort, che è il fattore dominante (salari e costi sociali). Gli **Overheads** includono:

- Costi degli edifici (riscaldamento, luce).
- Costi di rete e comunicazione.
- Strutture condivise come mensa o biblioteca.

Nota del Prof

Il salario dello sviluppatore a volte non copre neanche il 50% del costo totale per un'azienda a causa degli overhead. Inoltre, il software ha un costo marginale di replicazione quasi nullo: vendere a un secondo cliente non costa nulla di più in termini di produzione.

2.2.2 Il Ruolo del Linguaggio di Programmazione

Solo nelle slide (non spiegato a voce)

Il linguaggio impatta drasticamente su tempi e costi. Ad esempio, l'Assembly richiede molto più tempo per coding (8 settimane per 5000 linee) e testing (10 settimane) rispetto a un linguaggio ad alto livello per lo stesso sistema.

2.3 Tecniche di Stima

IMPORTANTE PER L'ESAME

All'esame non vengono chieste le tecniche a memoria, ma i vantaggi, gli svantaggi e quando usare l'una rispetto all'altra.

- **Algorithmic cost modelling:** Approccio basato su formule e dati storici, generalmente basato sulla dimensione del software (es. COCOMO).
- **Expert judgement:** Uno o più esperti usano la loro esperienza per predire i costi.
 - *Vantaggi:* Metodo relativamente economico; accurato se gli esperti hanno esperienza diretta in sistemi simili.
 - *Svantaggi:* Molto inaccurato se mancano veri esperti nel dominio.
- **Estimation by analogy:** Il costo è calcolato comparando il progetto con uno simile nello stesso dominio.
 - *Vantaggi:* Accurato se sono disponibili dati di progetti passati.
 - *Svantaggi:* Impossibile se non si è mai affrontato un progetto comparabile; richiede un database di costi sistematicamente aggiornato.
- **Parkinson's Law:** Il progetto costa qualunque risorsa sia disponibile. Il lavoro si espande per riempire il tempo disponibile.
 - *Vantaggi:* Non si va mai oltre il budget (*no overspend*).
 - *Svantaggi:* Il sistema rimane solitamente incompleto (*unfinished*).
- **Pricing to win:** Il costo è pari a quanto il cliente può spendere.
 - *Vantaggi:* Permette di vincere il contratto.
 - *Svantaggi:* Bassa probabilità che il cliente ottenga ciò che vuole; i costi non riflettono il lavoro reale richiesto.

2.4 Planning Poker

Il Planning Poker è una tecnica Agile per la stima del consenso, basata sulle carte di James Grenning.

2.4.1 Dinamiche e Regole del Gioco

Ogni partecipante riceve un mazzo di carte con una sequenza numerica, solitamente di **Fibonacci** (1, 2, 3, 5, 8, 13, 21, ecc.).

- **La Sfida:** Il moderatore presenta una *user story* e il team può fare domande al Product Owner.
- **Voto Segreto:** Ogni membro seleziona privatamente una carta che rappresenta la "grandezza" (*size*) del task, considerando tempo, rischio e complessità.
- **Svelamento e Dibattito:** Le carte vengono mostrate insieme. Se non c'è consenso, chi ha dato i valori estremi spiega le proprie ragioni. Il gruppo discute e si vota di nuovo finché non si raggiunge un accordo.

IMPORTANTE PER L'ESAME

Perché i "buchi" di Fibonacci? Servono a forzare la granularità corretta. All'aumentare della grandezza aumenta l'incertezza: la sequenza ci spinge a scegliere tra valori distanti (es. 13 o 21), riflettendo la reale imprecisione della stima per task grandi.

Nota del Prof

In caso di mancato consenso, si sceglie la stima superiore per tutelarsi dalla naturale indole ottimista dell'uomo, che tende a sottostimare i tempi ignorando gli imprevisti.

2.4.2 Vantaggi e Consigli Pratici (Tips)

Il Planning Poker favorisce la collaborazione e fa emergere i problemi tecnici in anticipo attraverso il dibattito.

- **Chi vota:** Solo chi farà materialmente il lavoro. I manager non votano per non influenzare le stime al ribasso.
- **Pareggi:** Se il team è diviso tra due taglie consecutive (es. 5 e 8), si sceglie la maggiore e si procede.

Solo nelle slide (non spiegato a voce)

Suggerimenti per l'efficienza:

- Usare un timer per limitare le discussioni a circa un minuto.
- Includere una carta "I need a break" per segnalare la stanchezza.
- Mantenere una **Baseline** consistente tra le varie iterazioni.

Capitolo 3

Introduzione all'Architettura Software

3.1 Cos'è un'Architettura Software

IMPORTANTE PER L'ESAME

L'architettura software è uno dei pilastri dell'ingegneria del software e rappresenta una delle domande più frequenti in sede d'esame.

Secondo lo standard **IEEE 1471**, l'architettura è definita come:

“L'organizzazione fondamentale di un sistema, incarnata nei suoi componenti, nelle loro relazioni reciproche e con l'ambiente, e i principi che ne governano la progettazione e l'evoluzione.”

L'intento principale, come sostenuto da Kruchten, è fornire un **controllo intellettuale** su sistemi di enorme complessità, permettendo agli stakeholder di comprendere la struttura senza annegare nei dettagli implementativi.

3.1.1 Architetture Intended vs Unintended

Ogni sistema possiede intrinsecamente un'architettura, che può essere classificata in due modi:

- **Intended (Pianificata):** Esplicita e documentata prima della scrittura del codice. Segue l'approccio del *Forward Engineering*.
- **Unintended (Accidentale):** Implicita e spontanea. Emerge quando si scrive codice senza un piano; in questo caso, l'architettura deve essere ricostruita a posteriori (*Reverse Engineering*).

Nota del Prof

Immaginate di costruire una casa: nell'approccio *intended* disegnate prima la pianta. Nell'approccio *unintended* costruite le stanze a casaccio e solo alla fine vi accorgete di che forma ha la casa. Ricordate però il Manifesto Agile: l'architettura ha valore solo se serve a produrre codice migliore, non deve essere burocrazia inutile.

3.2 Il Modello 4+1 di Kruchten

Per gestire la complessità, Kruchten propone di decomporre l'architettura in diverse **viste** basate sul principio della *separation of concerns*.

- **Logical View:** Supporta i requisiti funzionali, ovvero ciò che il sistema deve fare per l'utente finale.
- **Development View:** Si concentra sull'organizzazione dei moduli e dei package nel codice sorgente.

Nota del Prof

Un esempio tipico è lo **stack di Android**, che mostra come il sistema sia stratificato dal Kernel Linux fino alle applicazioni.

- **Dynamic View:** Analizza il comportamento a runtime, i processi e le interazioni tra oggetti. Viene solitamente modellata con i *Sequence Diagram*.

Solo nelle slide (non spiegato a voce)

Completamento del modello:

- **Deployment View:** Si occupa della mappatura fisica del software sui nodi hardware e della distribuzione geografica dei server.
- **Scenarios (il “+1”):** Casi d'uso o sequenze di azioni che fanno da collante tra le altre quattro viste, verificandone la coerenza.

Nota del Prof

Pensate a una casa: potete guardare la pianta elettrica, quella idraulica o quella strutturale. Sono tutte viste diverse dello stesso edificio, necessarie a stakeholder diversi (elettricista, idraulico, ingegnere).

3.3 Progettazione e Decision-Making

Il design architeturale si basa su tre fattori: **Riuso** (di pattern o componenti), **Metodo** (tecniche sistematiche) e **Intuizione** (l'esperienza dell'architetto).

3.3.1 L'importanza dei Requisiti Non Funzionali

Nota del Prof

L'architettura è dettata principalmente dai **Requisiti Non Funzionali** (attributi di qualità come sicurezza, velocità, scalabilità). Questi requisiti sono strutturali: non si può “aggiungere la sicurezza” alla fine del progetto. È come una casa: se volete che sia antisismica, deve nascere così. Non potete renderla antisismica una volta costruita senza abbatterla.

3.3.2 Trade-offs e il ruolo dell'Architetto

L'architetto deve bilanciare forze contrastanti provenienti da stakeholder diversi. Le decisioni sono spesso sub-ottimali e prese "al buio" (quando i requisiti sono ancora vaghi).

Solo nelle slide (non spiegato a voce)

Questo dilemma è rappresentato graficamente dalla scelta tra carne "Cotta" o "Cruda": ogni scelta comporta un vantaggio per uno stakeholder e uno svantaggio per un altro.

3.4 Documentazione: Viste e Punti di Vista

IMPORTANTE PER L'ESAME

Questa è una distinzione fondamentale. Molti studenti confondono i due termini: ricordateli bene per l'esame.

- **Architectural View (Vista):** È la rappresentazione del sistema da una certa prospettiva. È composta da uno o più *modelli* (o diagrammi).
- **Architectural Viewpoint (Punto di Vista):** È l'insieme di regole, convenzioni e linguaggi usati per costruire la vista.

Nota del Prof

Esempio dello stadio: il *Viewpoint* è il concetto teorico di "guardare dalla tribuna stampa" (regole e angolazione). La *View* è la foto specifica che scattate in quello stadio particolare applicando quel punto di vista. In questo corso, Modello e Diagramma sono considerati sinonimi.

3.5 Software Product Lines (SPL)

Una SPL è una famiglia di prodotti che condividono un set comune di funzionalità (**Core Assets**). Si basa sul *Systematic Reuse*.

- **Scoping:** Decidere cosa includere nella piattaforma comune. Se lo scope è troppo largo si spreca soldi; se è troppo stretto si perde l'opportunità di riuso.
- **Vantaggi:** Riduzione drastica dei tempi e dei costi di sviluppo per i prodotti successivi al primo.

Nota del Prof

Pensate alle auto: la Mercedes usa lo stesso tasto per il finestrino su tutti i modelli. La BMW usa lo stesso motore fisico per vari modelli, limitandone la potenza via software. Nel software il riuso è vitale, ma genera conflitti di budget: il Team A spesso non vuole pagare il costo extra per rendere un modulo riutilizzabile anche dal Team B.

3.6 Stili Architetture

Lo **Stile Architetture** è un pattern astratto; l'**Architettura** è la sua applicazione pratica.

1. **Client/Server:** Il server gestisce dati e sicurezza, i client richiedono servizi. Dissaccoppiamento parziale (il server non conosce i client).
2. **Peer-to-Peer:** Ogni nodo è sia client che server.

Nota del Prof

Come BitTorrent: chi scarica deve anche caricare, evitando colli di bottiglia.

3. **Pipes and Filters:** Stream di dati trasformati in sequenza.

Nota del Prof

Usato in sistemi critici come l'avionica. Performance altissime, riuso quasi nullo.

4. **Shared Data:** Comunicazione tramite un database centrale.

Solo nelle slide (non spiegato a voce)

Si divide in **Repository** (l'agente chiede i dati) e **Blackboard** (il sistema notifica gli agenti quando i dati cambiano).

Capitolo 4

Debito Tecnico e Code Smells

4.1 Il Debito Tecnico (Technical Debt)

Il Debito Tecnico (TD) rappresenta l'applicazione di concetti finanziari al dominio dell'ingegneria del software, aggiungendo criteri di tempo ed economia al classico concetto di manutenibilità.

IMPORTANTE PER L'ESAME

Il debito tecnico si scompone in due concetti finanziari fondamentali che lo distinguono dalla semplice manutenibilità:

- **Capitale (Principal):** Il costo (effort) necessario per eliminare il debito, ovvero il tempo speso per il refactoring.
- **Interessi (Interest):** La penalità futura pagata se il debito non viene eliminato, che si traduce in rallentamento dello sviluppo o maggiore probabilità di bug.

4.1.1 Cause e Conseguenze

Il debito emerge tipicamente per ottimizzazioni a breve termine che creano handicap a lungo termine. Le cause includono la **crescita organica** (aumento naturale della complessità) e **scelte opportunistiche** (trade-off per rispettare le scadenze).

Nota del Prof

Spesso si creano trade-off tra qualità interna e "Time to Market". Seguendo il principio Agile "Working code over comprehensive documentation", gli sviluppatori possono trascurare la modularizzazione o i commenti pur di consegnare software funzionante e farsi pagare .

IMPORTANTE PER L'ESAME

Il debito tecnico impatta sempre la release successiva: se il codice non è manutenibile oggi, lo sviluppo futuro sarà più lento e pronò ai difetti.

Solo nelle slide (non spiegato a voce)

Gli analizzatori statici (come SonarQube) faticano a calcolare gli "Interessi" (il costo futuro), rendendoli attualmente una metrica poco chiara.

4.1.2 Strategie di Gestione

Nota del Prof

Il debito tecnico "scade": se un modulo di scarso valore non verrà mai più modificato, non produrrà interessi. È un errore fare refactoring su codice che non verrà più toccato.

Le strategie di gestione includono:

- **Monitoraggio e Refactoring:** Uso di strumenti come SonarCloud per tracciare il trend delle violazioni.
- **Quality Gate:** Una regola che blocca automaticamente i commit contenenti nuove violazioni.

Nota del Prof

Metafora della barca bucata: la prima cosa da fare non è svuotare l'acqua (vecchio debito), ma tappare il buco (usare il quality gate per non farne entrare di nuovo).

4.2 Introduzione ai Code Smells

Occorre distinguere tra tre concetti:

- **Quality Rule:** Principio ingegneristico validato (es. commenti, bassa complessità).
- **Violation o Code Smell:** Porzione di codice non conforme a una regola di qualità.
- **Defect (Bug):** Problema che impatta la qualità esterna (es. crash).

IMPORTANTE PER L'ESAME

I Code Smells **non sono bug**. Non causano malfunzionamenti immediati ma rendono la manutenzione difficile. Agiscono come un "campo minato", aumentando la probabilità che uno sviluppatore introduca difetti reali.

4.3 Catalogo dei "Worst Smells"

I "Worst Smells" sono violazioni che non portano alcun vantaggio in nessuna circostanza, a differenza di alcuni smell "classici" (come God Class o Code Clones) che possono nascere da trade-off temporali.

4.3.1 Esempi di Worst Smells

- **Modificatori non ordinati:** Crea confusione visiva inutile.
- **Object.finalize() sovrascritto:** In Java, forzare la distruzione manuale è spesso deleterio.
- **Codice commentato:** Sporca la codebase; spesso sono rimasugli di prototipi.
- **Mancanza del "break" in uno Switch:** Causa comportamenti imprevisti proseguendo nei case successivi.
- **Concatenazione di Stringhe con '+' in un ciclo:** Degrada gravemente le performance; il refactoring corretto prevede l'uso di **StringBuilder**.
- **Pessimo Naming:** Esempi includono attributi chiamati A, B o C.

Nota del Prof

Chiamare un metodo `ThisIsAGreatMethod1` non fa risparmiare tempo significativo: non siamo in Formula 1 dove si risparmiano millisecondi.

Solo nelle slide (non spiegato a voce)

L'analisi su 27 progetti Apache ha rivelato che i Worst Smells non sono meno frequenti né più severi degli altri, ma non avendo ragioni di esistere, vanno bloccati sempre tramite Quality Gates.

Capitolo 5

Machine Learning e Software Analytics per la Software Engineering

5.1 Definizione di Machine Learning, ruolo di statistica e informatica

Il **Machine Learning (ML)** è lo studio degli algoritmi che migliorano le proprie performance in un determinato **task** attraverso l'**esperienza**. L'obiettivo è ottimizzare un criterio di performance utilizzando dati di esempio o esperienze passate.

Questa disciplina unisce due campi fondamentali:

- **Statistica**: necessaria per trarre inferenze a partire da un campione di dati.
- **Informatica**: necessaria per fornire algoritmi efficienti in grado di risolvere il problema di ottimizzazione, oltre a rappresentare e valutare il modello per l'inferenza.

Nota del Prof

È fondamentale comprendere che ogni misurazione e ogni modello di ML, sebbene si basi su dati raccolti nel passato, ha come unico scopo quello di **prendere decisioni sul futuro**. L'intero sistema si fonda su un assioma filosofico implicito ma cruciale: assumiamo che il futuro sia simile al passato. Senza questa assunzione di base, l'uso dei dati storici per addestrare un modello sarebbe completamente inutile.

5.2 Esempi d'uso: associazioni, classificazione, regressione

Il Machine Learning viene applicato a diverse tipologie di problemi.

5.2.1 Apprendimento di associazioni

L'**apprendimento di associazioni** calcola la probabilità che un evento si verifichi in concomitanza di un altro. Un esempio tipico è la **basket analysis**, in cui si stima la probabilità che chi compra un certo prodotto acquisti anche un altro prodotto.

5.2.2 Classificazione

La **classificazione** serve a dividere i dati in categorie. Tra gli esempi più importanti troviamo:

- **Credit scoring**: differenziare clienti a basso o alto rischio in base a reddito e risparmi.
- **Face recognition**.
- **Character recognition**.
- **Speech recognition**.
- **Diagnosi medica**.
- **Predizione del click** su pubblicità web.

5.2.3 Regressione

La **regressione** viene utilizzata quando l'output non è una categoria, ma un valore numerico continuo. Un esempio classico è la predizione del **prezzo di un'auto usata** in base ai suoi attributi.

Nota del Prof

Sistemi come Google o Netflix basano il loro intero modello di business sulla predizione. Google non vende solo spazi pubblicitari, ma predice quale utente cliccherà su quale banner per massimizzare i profitti. Netflix usa algoritmi di classificazione e raccomandazione per permettere all'utente di trovare rapidamente il contenuto desiderato. Inoltre, i sistemi di autenticazione biometrica non cercano una corrispondenza pixel per pixel, ma utilizzano il ML per capire quali variazioni sono significative e quali no.

Le principali applicazioni del ML si articolano quindi in tre grandi famiglie: **associazioni**, **classificazione** e **regressione**. Esse coprono problemi di co-occorrenza, categorizzazione e stima di valori numerici.

5.3 Tipi di apprendimento: supervised, unsupervised, semi-supervised, reinforcement

I modelli di ML possono apprendere in modi diversi a seconda dei dati disponibili.

5.3.1 Supervised learning

Nel **supervised learning**, il modello riceve sia i dati di addestramento sia gli output desiderati, cioè le **label**.

Nota del Prof

Un esempio è fornire al modello la dimensione di un tumore dicendogli esplicitamente se in passato si è rivelato benigno o maligno, affinché impari a classificarlo in futuro.

5.3.2 Unsupervised learning

Nell'**unsupervised learning**, vengono forniti dati di addestramento senza output desiderati. Lo scopo è trovare struttura, similarità o gruppi latenti nei dati.

Nota del Prof

In questo caso l'obiettivo non è predire un valore esatto, ma organizzare i dati in cluster simili tra loro, ad esempio per raggruppare geni simili o fare network analysis.

5.3.3 Semi-supervised learning

Solo nelle slide (non spiegato a voce)

Il **semi-supervised learning** utilizza dati di addestramento in cui solo una parte limitata delle istanze possiede le label corrette.

5.3.4 Reinforcement learning

Solo nelle slide (non spiegato a voce)

Il **reinforcement learning** è una tipologia di apprendimento basata su un sistema di ricompense e punizioni. Nelle slide è citato, ma non viene approfondito a voce.

Nel complesso, la distinzione tra questi paradigmi dipende dal tipo di supervisione disponibile e dal modo in cui il sistema riceve informazione utile per apprendere.

5.4 Etica del data mining e del ML

L'utilizzo dei dati solleva questioni etiche rilevanti. L'anonimizzazione dei dati è difficile, e l'uso di certe informazioni può condurre a discriminazioni. Per esempio, utilizzare razza, sesso o religione per l'approvazione di un prestito è eticamente problematico, mentre in ambito medico gli stessi dati possono essere legittimi.

Le domande fondamentali sono:

- Chi ha accesso ai dati?
- Per quale scopo sono stati raccolti?
- Quali conclusioni possono essere tratte legittimamente?

Nota del Prof

Quando un sistema ML prende decisioni, la responsabilità è un tema complesso. Se una Tesla a guida autonoma causa un incidente, oggi la responsabilità legale ricade ancora su chi è al volante, anche in virtù degli accordi di licenza accettati dagli utenti. Inoltre, il ML tende a replicare i bias umani presenti nei dati storici: se nel passato una certa etnia o un certo genere ha subito discriminazioni, il modello può apprendere e riprodurre quel comportamento in futuro.

L'etica del ML impone quindi attenzione a **privacy**, **bias**, **discriminazione** e **responsabilità**. I dati storici non sono neutrali, e i modelli possono ereditare le distorsioni del contesto da cui provengono.

5.5 Terminologia: istanze, feature, attributi nominali/-numerici, output, modelli

Per utilizzare correttamente gli algoritmi di ML è necessario padroneggiare una terminologia standard.

5.5.1 Instances

Le **instances** sono i singoli esempi indipendenti del concetto da apprendere.

Nota del Prof

In un dataset strutturato a tabella, l'istanza rappresenta la singola riga, ad esempio la combinazione di una specifica classe software in una specifica release.

5.5.2 Features o attributi

Le **feature** sono gli aspetti misurabili di un'istanza. Possono essere:

- **Nominali**: valori simbolici o categorici.
- **Numerici**: valori quantitativi su cui si possono eseguire operazioni matematiche.

Nota del Prof

Le feature rappresentano le colonne della tabella. In genere, l'ultima colonna è l'output o variabile da predire, mentre le altre sono metriche che aiutano nella predizione.

5.5.3 Output e modelli

La conoscenza prodotta da un sistema di ML può essere rappresentata tramite:

- **tabelle decisionali**;
- **modelli lineari**;

- alberi decisionali;
- regole;
- cluster.

IMPORTANTE PER L'ESAME

Molti ambienti di ML, in particolare **Weka**, non supportano correttamente gli attributi con scala ordinale, ad esempio *Low*, *Medium*, *High*. Weka tende a trattarli come semplici categorie nominali, perdendo l'informazione dell'ordine. Per questo motivo, spesso occorre eliminare la colonna oppure trasformarla in una variabile binaria, accettando il relativo trade-off nella perdita di informazione.

Un dataset è dunque una tabella in cui le **righe** rappresentano le istanze e le **colonne** rappresentano le feature. La corretta interpretazione del tipo di attributo è essenziale, soprattutto quando si usano strumenti come Weka.

5.6 Software quality e costo dei bug

La **qualità del software** ha un impatto economico enorme. I bug costano a livello globale migliaia di miliardi di dollari, e le attività di **Quality Assurance (QA)** risultano estremamente costose.

Nei sistemi industriali di grandi dimensioni:

- vengono effettuate migliaia di **code review** al giorno;
- vengono eseguiti milioni di **test**;
- ogni modifica deve essere controllata con attenzione.

Nota del Prof

Poiché il testing è molto oneroso, diventa fondamentale stimare in anticipo quali entità del codice, come classi o metodi, abbiano maggiore probabilità di essere difettose, così da concentrare lì l'effort di QA.

Ne segue che la defect prediction nasce anche come risposta economica e organizzativa al problema della qualità: non è sostenibile controllare tutto con la stessa intensità, quindi occorre **prioritizzare**.

5.7 Software analytics: definizione, obiettivi e fonti dati

La **Software Analytics** è la combinazione di **Software Data** e **Data Analytics**. Il software produce una grande quantità di dati distribuiti tra repository, sistemi di build, log di CI/CD, issue tracker, code review e file di configurazione.

Gli obiettivi principali della Software Analytics sono:

1. **Quality improvement**: prevenire crash e bug.

2. **Process improvement**: capire l'impatto di pratiche come code review e rapid release.
3. **Productivity improvement**: valutare l'effetto della CI e di altre pratiche sul team.
4. **Empirical theory building**: costruire teorie empiriche sull'ingegneria del software.

La Software Analytics sfrutta quindi i dati prodotti dagli strumenti di sviluppo per migliorare **qualità**, **processi**, **produttività** e comprensione empirica del software.

5.8 AI/ML applicati alla Software Engineering

L'Intelligenza Artificiale sta trasformando l'Ingegneria del Software.

5.8.1 Applicazioni alla qualità

Tra le applicazioni principali ci sono:

- **defect prediction**;
- **vulnerability prediction**;
- **malware prediction**;
- **test case generation**.

5.8.2 Applicazioni alla produttività

L'AI può supportare anche la produttività del team, ad esempio tramite:

- generazione di **UI**, requisiti, codice e commenti;
- previsione della **produttività** di sviluppatori o team;
- **recommendation** di developer o reviewer;
- identificazione del **turnover** degli sviluppatori.

Solo nelle slide (non spiegato a voce)

Nelle slide vengono citati esempi industriali concreti, come un **AI coding assistant** sviluppato in collaborazione con Mozilla, i tool **SapFix** e **Sapienz** di Facebook per trovare e correggere bug automaticamente, e **Sketch2Code** di Microsoft per trasformare schizzi su lavagna in codice HTML.

Nel contesto della Software Engineering, l'AI non serve quindi solo a prevedere bug, ma anche a supportare gli sviluppatori nella produzione di codice, nel testing e nella gestione del lavoro di squadra.

5.9 Defect prediction e ML for software defects

Nel contesto dei difetti software, il ML ha tre grandi obiettivi:

1. **Predire** i difetti futuri, per ottimizzare le risorse di QA.
2. **Spiegare** perché un software fallisce.
3. **Costruire** teorie empiriche sulla defectiveness.

Nota del Prof

Prevenire è meglio che curare. Eliminare code smells e individuare le classi più rischiose consente di combattere i bug in modo proattivo e di stabilire priorità di testing più efficaci.

La defect prediction non si limita quindi a indicare *dove* è probabile trovare un difetto, ma cerca anche di chiarire *perché* quel rischio esiste e come ridurlo a livello di processo o di codice.

5.10 Pipeline: measure, clean data, analyze, model, explain

L'applicazione della Software Analytics alla defect prediction segue una pipeline precisa:

1. **Measure**: estrazione dei dati grezzi e raccolta delle metriche.
2. **Clean Data**: pulizia dei dati.
3. **Analyze**: ricerca di correlazioni e relazioni tra feature.
4. **Model**: costruzione e addestramento di modelli analitici o black-box.
5. **Explain**: estrazione di conoscenza utile per spiegare le predizioni.

Nota del Prof

Nel corso verrà seguita esattamente questa pipeline: si partirà da una tabella grezza, la si analizzerà, si sceglieranno e si normalizzeranno le colonne, si costruirà il modello e infine si cercherà di estrarre conoscenza utile a evitare in futuro gli stessi errori.

In sintesi

La pipeline consente di trasformare dati grezzi provenienti dai repository in **modelli predittivi** e poi in **conoscenza spiegabile e azionabile**. È uno schema concettuale fondamentale perché collega raccolta dati, modellazione e interpretazione.

5.11 Estrazione dati da ITS e VCS e raccolta metriche

Il primo passo della pipeline consiste nell'estrazione dei dati da due sorgenti principali:

- **ITS (Issue Tracking System)**: ad esempio Jira, che contiene ticket, bug report e informazioni di progetto.
- **VCS (Version Control System)**: ad esempio Git, che contiene codice sorgente, snapshot e log dei commit.

Da queste fonti si raccolgono diverse famiglie di metriche:

- **Code Metrics**: dimensione, complessità, design object-oriented, accoppiamento, coesione.
- **Process Metrics**: numero di commit, churn, difetti pre-release, pratiche di sviluppo.
- **Human Factors**: code ownership, numero di sviluppatori che hanno toccato il file, esperienza dello sviluppatore.

Nota del Prof

Più persone modificano una stessa classe, maggiore è il rischio di introdurre difetti. Inoltre, se un commit è effettuato da uno sviluppatore che non ha esperienza su quella classe, la probabilità di errore cresce sensibilmente.

Combinando dati da **Jira** e **Git**, si ottengono quindi metriche sul codice, sul processo e sui fattori umani, tutte utili per la defect prediction.

5.12 Identificazione difetti, labeling e defect dataset

Per addestrare un modello di defect prediction è necessario costruire un dataset etichettato, in cui ogni classe venga marcata come **difettosa** o **non difettosa**.

Questo processo dipende dal **linkage** tra:

- ticket nell'Issue Tracking System;
- commit nel Version Control System;
- versioni del software coinvolte nel ciclo di vita del difetto.

Nota del Prof

Quando uno sviluppatore effettua un commit per risolvere un problema, inserisce spesso nel messaggio del commit l'ID del ticket Jira associato. Questo ID rappresenta il razionale del cambiamento. Grazie a questa connessione tra commit e ticket, e tramite tecniche come **SZZ** e **Proportion**, è possibile non solo sapere quale commit ha corretto il bug, ma anche risalire a ritroso fino al commit che lo aveva introdotto.

In sintesi

Il **labeling** dipende dalla capacità di collegare correttamente ticket, commit e release. Questo collegamento è alla base della costruzione del **defect dataset** ed è il passaggio che determina la qualità dei dati su cui verranno addestrati i modelli.

5.13 Black-box models e necessità di spiegazione

Molti algoritmi di apprendimento producono modelli **black-box**: ricevono un input e restituiscono una predizione, ma senza rendere trasparente il ragionamento interno che ha portato a quella decisione.

Per esempio, un modello può dire che una certa classe ha alta probabilità di essere difettosa, ma senza spiegare quali fattori abbiano portato a quel risultato.

Nota del Prof

Un predittore come una rete neurale può essere molto accurato, ma non sa giustificare in modo leggibile il perché della sua scelta. Nell'ingegneria del software, invece, capire il motivo della difettosità è cruciale, perché consente al manager di agire sulla causa e non soltanto sul sintomo.

In contesto ingegneristico, quindi, la sola accuratezza non basta: il valore operativo di una predizione aumenta notevolmente quando essa è accompagnata da una spiegazione comprensibile.

5.14 XAI, GDPR, fairness, accountability, transparency

La necessità di spiegare i modelli è legata sia a motivazioni tecniche sia a motivazioni etiche e legali. In questo contesto si colloca il paradigma **FAT**:

- **Fairness**;
- **Accountability**;
- **Transparency**.

L'**Articolo 22 del GDPR** richiede che i processi decisionali automatizzati che hanno impatto sugli individui siano accompagnati da una spiegazione adeguata.

Questo porta a domande fondamentali:

- I sistemi di AI rispettano le leggi?
- I modelli producono decisioni discriminatorie?
- Comprendiamo davvero perché un modello fa una certa predizione?

Nota del Prof

Una tecnica di Explainable AI consiste nell'affiancare a un modello black-box, come una rete neurale, un modello gemello spiegabile, ad esempio un albero decisionale.

Invece di addestrare l'albero direttamente sui dati originali, lo si addestra sugli output generati dalla rete neurale, così da mimarne il comportamento e renderne più leggibili le decisioni.

In sintesi

La **XAI** nasce dall'esigenza di rendere i modelli comprensibili, verificabili e compatibili con vincoli legali ed etici come quelli imposti dal GDPR. In questo quadro, la spiegabilità non è un'aggiunta opzionale, ma una proprietà sempre più centrale.

5.15 CMMI Level 5 e process improvement

Il **CMMI (Capability Maturity Model Integrated)** è uno standard per misurare la maturità dei processi di sviluppo software.

I livelli principali sono:

1. **Initial**
2. **Managed**
3. **Defined**
4. **Quantitatively Managed**
5. **Optimizing**

Il **Level 5**, cioè *Optimizing*, rappresenta il livello più elevato: le performance del processo vengono migliorate in modo continuo tramite innovazione e controllo quantitativo.

Nota del Prof

Il professore riporta un'esperienza diretta in cui ha aiutato un'azienda a mantenere il Livello 5 del CMMI. L'obiettivo era dimostrare statisticamente che certe strategie di miglioramento avessero prodotto benefici reali. I risultati hanno mostrato una forte riduzione dei difetti e un marcato aumento del profitto per dipendente.

Il riferimento al CMMI mostra bene come metriche, controllo statistico e miglioramento continuo possano essere integrati in una visione strutturata della qualità.

5.16 Process chart e controllo statistico

Per controllare la stabilità del processo si utilizzano i **process chart** o **control chart**. Essi servono a:

- identificare problemi mentre si verificano;
- predire l'intervallo atteso dei risultati del processo;
- verificare se il processo è statisticamente stabile;
- decidere se intervenire con correzioni locali o con cambiamenti più strutturali.

La costruzione di un process chart prevede:

1. scelta della variabile da osservare;
2. scelta dell'unità temporale;
3. calcolo della **media**;
4. calcolo dell'**Upper Control Limit** come media più tre deviazioni standard;
5. calcolo del **Lower Control Limit** come media meno tre deviazioni standard.

Nota del Prof

Finché i dati restano all'interno dei limiti di controllo, il processo è considerato statisticamente stabile. Se invece un punto supera uno dei limiti, si attiva una retrospettiva per analizzare la root cause dell'anomalia e capire come evitare che si ripeta.

I **process chart** permettono dunque di monitorare il processo nel tempo e di individuare rapidamente deviazioni anomale che richiedono analisi e intervento.

5.17 Casi applicativi mostrati nelle slide, anche se solo introdotti

Le lezioni presentano anche alcuni casi applicativi concreti.

5.17.1 Simulatore di release e defect prediction

Nota del Prof

È stata sviluppata un'interfaccia per supportare i manager nel **release planning**. Modificando alcuni slider relativi a variabili di input, come la percentuale di God Classes, la compliance architetturale o il numero di nuovi sviluppatori, il modello ricalcolava dinamicamente il numero atteso di difetti nella release successiva. Il sistema forniva anche intervalli di confidenza e scenari di best case e worst case.

5.17.2 Traceability recovery

Solo nelle slide (non spiegato a voce)

Nelle slide si introducono studi sull'uso di tecniche NLP e classificatori di ML per stimare il numero di link rimanenti nel recupero della tracciabilità dei requisiti.

5.17.3 Defectiveness prediction via JIT

Solo nelle slide (non spiegato a voce)

Le slide finali introducono il tema del miglioramento della defect prediction combinando informazioni **Just-In-Time** a livello di commit con metriche classiche a livello di classe e metodo.

Le tecniche discusse trovano applicazione sia in strumenti concreti di supporto decisionale per i manager, sia in linee di ricerca avanzate su **tracciabilità** e **predizione dei difetti**.

5.18 Riepilogo finale

I concetti chiave emersi sono i seguenti:

- Il **Machine Learning** apprende dai dati passati per prendere decisioni sul futuro.
- Le principali famiglie di problemi sono **associazioni**, **classificazione** e **regressione**.
- La **Software Analytics** usa dati provenienti da repository, issue tracker e pipeline di sviluppo per migliorare qualità, processi e produttività.
- La **defect prediction** serve a stimare quali classi o componenti sono più a rischio di contenere difetti.
- La pipeline fondamentale è: **Measure** → **Clean Data** → **Analyze** → **Model** → **Explain**.
- Il **labeling** delle classi dipende dal corretto collegamento tra ticket, commit e release.
- I modelli **black-box** sono potenti ma poco trasparenti, perciò diventa centrale la **Explainable AI**.
- La spiegabilità è importante non solo dal punto di vista tecnico, ma anche per ragioni di **fairness**, **accountability**, **transparency** e conformità al **GDPR**.
- Il **CMMI Level 5** e i **process chart** mostrano come il controllo quantitativo del processo possa tradursi in miglioramenti concreti di qualità e produttività.

Capitolo 6

SZZ: Identifying Buggy Entities

6.1 Contesto

6.1.1 Cos'è la defect prediction

La **defect prediction** è una tecnica che mira a identificare gli **artefatti software** — per esempio classi, metodi o linee di codice — che hanno un'alta probabilità di contenere un difetto. L'obiettivo principale è **ridurre i costi e i tempi del testing e della code review**, permettendo agli sviluppatori di concentrare lo sforzo sulle parti più critiche del sistema.

Nota del Prof

Il testing, sia automatico sia manuale, può essere molto costoso in termini economici e computazionali. Il punto della defect prediction non è “indovinare i bug” in astratto, ma usare i dati storici per **prioritizzare** le attività di qualità. Anche se nel progetto del corso si lavora soprattutto a livello di classe, la stessa logica può essere applicata anche a commit, metodi o linee di codice.

6.1.2 Perché la qualità del dataset è fondamentale

L'**affidabilità di un modello di predizione** dipende direttamente dalla **qualità del dataset** con cui il modello viene addestrato. Se le etichette sono sbagliate o rumorose, il classificatore apprenderà relazioni imprecise e tenderà a produrre risultati poco affidabili.

Nota del Prof

Qui vale in pieno il principio del *Garbage In, Garbage Out*: se i dati in ingresso sono sbagliati, incompleti o rumorosi, anche il modello finale sarà inevitabilmente distorto.

6.1.3 Principali fonti di rumore nei dataset

Tra le principali fonti di rumore citate nelle slide compaiono:

- defect misclassification;
- defect origin.

Solo nelle slide (non spiegato a voce)

Le slide ricordano che lavori precedenti hanno già identificato queste fonti di rumore e hanno proposto tecniche per affrontarle.

Nota del Prof

Un esempio tipico di **misclassification** è quando un ticket classificato come “bug” in realtà descrive una nuova funzionalità o un miglioramento. Un altro problema è il **linkage**: se il commit di fix non contiene l’ID del ticket, allora si perde il collegamento tra issue tracker e version control system, e diventa molto più difficile ricostruire quali classi fossero davvero difettose.

6.2 Cos’è SZZ

6.2.1 Definizione e obiettivo

SZZ è un processo algoritmico usato per identificare **quando un difetto è stato effettivamente introdotto** all’interno di un progetto software. In altre parole, non si limita a dire quale commit ha corretto il problema, ma cerca di risalire al commit precedente che ha inserito la modifica difettosa.

Nota del Prof

Il nome **SZZ** deriva semplicemente dai cognomi degli autori del lavoro originario.

6.2.2 Uso del versioning e dell’annotation

Il metodo sfrutta il **meccanismo di annotation** dei sistemi di versionamento, ad esempio il comando `git blame` in Git. Questo meccanismo permette di associare ogni riga del codice alla revisione che l’ha modificata per ultima.

Nota del Prof

L’annotation è importante perché consente di guardare una riga del file nello stato corrente e chiedersi: *chi l’ha scritta o modificata per ultimo, e in quale commit?* È proprio questa informazione che permette a SZZ di fare la ricerca all’indietro.

6.2.3 Idea di partire dal fix per risalire al bug-introducing change

L’idea centrale di SZZ è partire da un’informazione affidabile nel presente, cioè il **fix commit**, e usarla per ricostruire il passato. In particolare, l’algoritmo osserva **quali linee sono state cambiate per correggere il bug** e poi cerca di capire **quando quelle stesse linee erano state modificate l’ultima volta prima del fix**.

Il commit precedente individuato da questa ricerca viene considerato il **bug-introducing change**, cioè il candidato che ha introdotto il difetto.

IMPORTANTE PER L'ESAME

Il punto chiave da ricordare è questo: **SZZ usa la correzione del bug come indizio per ricostruirne l'origine**. Non parte dal bug report in senso astratto, ma dalla porzione concreta di codice che è stata cambiata per eliminare il problema.

6.3 Come funziona SZZ

6.3.1 Identificazione del fix commit

Il primo passo consiste nell'identificare il **fix commit**, cioè il commit che corregge il difetto.

Nota del Prof

Operativamente, si parte dall'issue tracker, ad esempio Jira, si selezionano i ticket chiusi e classificati come bug, e si cercano i commit collegati a quei ticket. Quel commit rappresenta la **fix** osservabile nel repository.

6.3.2 Analisi delle linee modificate

Una volta trovato il fix commit, SZZ confronta la versione corretta con la versione immediatamente precedente e individua le **linee di codice effettivamente toccate dalla correzione**. Questo passaggio viene normalmente realizzato tramite una **diff**.

L'idea è che il difetto sia collegato proprio a quella parte di codice che è stata modificata nel fix. Perciò SZZ non analizza l'intero file in modo indistinto, ma si concentra sulla porzione di codice che ha subito la correzione.

Nota del Prof

SZZ non “capisce” il significato del bug. Non fa reasoning semantico. Vede solo che certe righe sono state corrette e assume che proprio lì si trovi la traccia storica utile per risalire all'origine del problema.

6.3.3 Ricerca all'indietro dell'ultima modifica precedente

Dopo aver isolato le linee corrette, l'algoritmo esegue una **backward search**. Per ogni riga coinvolta nel fix, usa il meccanismo di annotation per trovare **l'ultima modifica precedente** che aveva scritto o cambiato quella stessa riga.

Quel commit storico viene trattato come il miglior candidato disponibile per il **bug-introducing commit**. L'idea è quindi:

fix osservato nel presente → righe corrette → ricerca storica dell'ultima
modifica precedente

IMPORTANTE PER L'ESAME

SZZ è un algoritmo di **tracciamento storico**, non di comprensione semantica del bug. Funziona bene quando il problema è davvero contenuto nelle linee poi corrette;

funziona peggio quando il bug dipende da contesto, interazioni più ampie o codice mancante.

6.3.4 Differenza tra bug-fix change e bug-introducing change

È fondamentale distinguere chiaramente tra:

- **bug-fix change**: il commit che *risolve* il problema correggendo il codice;
- **bug-introducing change**: il commit passato che, secondo SZZ, ha *introdotto* il difetto, cioè la modifica storica da cui ha origine la porzione di codice poi corretta.

La differenza non è solo temporale, ma anche metodologica: il **bug-fix change** è osservabile con certezza, mentre il **bug-introducing change** è una **stima inferita** tramite backward search.

Nota del Prof

Nel dataset di defect prediction questa distinzione è decisiva. Non basta sapere quale commit ha riparato il bug: bisogna stimare da quale versione in poi una certa classe o un certo file debbano essere considerati difettosi.

6.4 Esempi nelle slide

6.4.1 Esempio 1: “When Do Changes Induce Fixes?”

Solo nelle slide (non spiegato a voce)

Il primo diagramma mostra una sequenza temporale in cui viene segnalato un bug e, in una revisione successiva, viene effettuato un fix. Nel fix commit vengono modificati tre metodi distinti, indicati come `a()`, `b()` e `c()`. SZZ traccia all'indietro la storia di ciascuna di queste porzioni di codice e individua tre revisioni precedenti differenti, ad esempio 1.11, 1.14 e 1.16.

Questo esempio è importante perché mostra che **un singolo bug fix può dipendere da più cambiamenti storici diversi**. Il fix avviene in un unico momento, ma le righe o i metodi corretti possono essere stati introdotti o alterati in revisioni differenti.

Il messaggio didattico è quindi duplice:

1. SZZ lavora a livello di **porzioni di codice**, non a livello astratto di “bug” nel suo complesso;
2. la genealogia del difetto può essere **distribuita** su più commit precedenti.

6.4.2 Esempio 2: “The Impact of Refactoring Changes on the SZZ Algorithm: An Empirical Study”

Nota del Prof

Nel secondo esempio compare un ciclo `for`. Nella versione che introduce il comportamento errato, la condizione è scritta come `for(int i=0; i<=4; i++)`. In seguito al bug report #123, il fix corregge il codice trasformandolo in `for(int i=0; i<4; i++)`.

L'esempio serve a visualizzare il funzionamento operativo di SZZ in modo molto concreto:

1. si individua il **fix commit** grazie al collegamento tra bug report e commit;
2. si esegue la **diff** rispetto alla versione precedente per isolare la riga corretta;
3. si traccia all'indietro la storia di quella riga per capire in quale commit era comparsa la forma difettosa.

Nel caso illustrato, la forma errata è la condizione `i<=4`, che viene poi corretta in `i<4`. SZZ usa proprio questa differenza come indizio per risalire al **bug-introducing change**.

Questo esempio chiarisce bene la logica standard dell'algoritmo: **si osserva il fix, si isolano le righe corrette, si segue la loro storia all'indietro**.

6.5 Limiti di SZZ

Le slide sottolineano che SZZ ha diverse **limitazioni** e che la sua accuratezza non è perfetta. Il problema di fondo è che l'algoritmo si basa su un'assunzione forte: *il bug è stato introdotto nelle stesse linee che vengono poi modificate per correggerlo*. Questa ipotesi è spesso utile, ma non sempre vera.

6.5.1 Code additions

Solo nelle slide (non spiegato a voce)

Le slide riportano che solo il **26–29%** dei **bug-introducing commits** può essere trovato con un algoritmo basato sull'assunzione che un bug sia stato introdotto dalle stesse linee di codice poi modificate per fixarlo.

Questo limite emerge quando il bug non viene corretto modificando una riga sbagliata già esistente, ma **aggiungendo codice che prima mancava**. Per esempio, il fix può consistere nell'inserire un controllo, una condizione o una gestione d'errore assente nella versione difettosa.

In questo caso, SZZ fallisce o diventa molto impreciso, perché non esiste una versione precedente di quella nuova riga da tracciare con `git blame`.

Nota del Prof

Se il difetto dipende da qualcosa che mancava nel codice, l'algoritmo cerca nel passato una riga che in realtà non esisteva ancora. Questo spiega perché i casi di **code addition** siano così problematici per SZZ.

6.5.2 Regressive bugs

I **regressive bugs** sono difetti che emergono dopo modifiche successive del sistema, anche se la riga coinvolta in passato era corretta nel contesto originario.

Il problema è che SZZ tende a tornare alla **prima modifica storica trovata su quella riga**, attribuendo il bug a un commit antico che magari, al momento della sua introduzione, non era affatto errato. La riga può essere diventata problematica solo più tardi, quando il contesto del sistema è cambiato.

Nota del Prof

Qui il limite è concettuale: una riga non è necessariamente “sbagliata in assoluto”. Può diventare sbagliata solo dopo l'introduzione di una nuova feature o dopo una modifica dell'ambiente o dei requisiti. SZZ, però, tende a incolpare chi ha scritto per primo quella riga.

6.5.3 Refactoring

Il **refactoring** cambia la struttura del codice senza modificarne, almeno idealmente, il comportamento funzionale. Esempi tipici sono rinominare variabili, spostare metodi o riorganizzare il codice.

Se la prima modifica precedente trovata da SZZ è proprio un refactoring, l'algoritmo rischia di etichettare quel commit come **bug-introducing**, anche se quel commit non ha realmente introdotto il difetto. In altre parole, il refactoring può **interrompere la pista storica** e nascondere il vero punto di introduzione del bug.

Nota del Prof

SZZ segue la storia delle righe, non il significato profondo della funzionalità. Per questo un refactoring può far sembrare che il bug nasca lì, quando in realtà quella modifica ha solo riscritto o spostato codice senza introdurre il problema.

6.5.4 Imprecise backward search

La **imprecise backward search** indica che SZZ può essere abbastanza efficace nell'individuare **quale porzione di codice** sia collegata al difetto, ma molto meno preciso nello stabilire **da quanto tempo** quella porzione debba essere considerata buggy.

Una riga di codice può essere stata introdotta molto tempo prima in modo corretto e diventare difettosa solo in seguito a cambiamenti dei requisiti, del contesto o delle interazioni con altre parti del sistema. Se SZZ risale troppo indietro, rischia di etichettare come difettose versioni che, storicamente, erano ancora corrette.

IMPORTANTE PER L'ESAME

Questo è uno dei limiti più importanti da ricordare: **SZZ** è spesso più affidabile nel dire “dove guardare” che nel dire con precisione “da quando” il codice sia diventato errato.

6.5.5 Snoring

Solo nelle slide (non spiegato a voce)

Nelle slide lo **snoring** è semplicemente citato nell'elenco delle limitazioni, ma non viene spiegato nel dettaglio.

Nel quadro generale del corso, lo snoring è il fenomeno per cui alcune classi contengono già difetti, ma questi difetti non sono ancora stati scoperti o corretti. Di conseguenza, il dataset può continuare a etichettarle come non difettose.

Il collegamento con SZZ è che l'algoritmo dipende dall'esistenza di un **fix osservabile**. Se un difetto esiste ma non è ancora stato corretto, SZZ non ha alcuna traccia concreta da seguire e quindi non può ricostruirne l'origine.

Nota del Prof

In questa lezione lo snoring viene solo accennato. L'idea essenziale è che SZZ vede soltanto i bug che hanno già lasciato una traccia nella storia dei fix. I bug ancora “dormienti” sfuggono all'algoritmo e contribuiscono a sporcare il labeling del dataset.

6.6 Da ricordare per l'esame

- **Definizione di SZZ:** è un algoritmo che sfrutta il meccanismo di annotation dei sistemi di versionamento per risalire dal **fix commit** al possibile **bug-introducing commit**.
- **Idea chiave:** si parte dalle **linee corrette dal fix** e si cerca l'ultima modifica precedente di quelle stesse linee.
- **Differenza fondamentale:** il **bug-fix change** è il commit che ripara il problema; il **bug-introducing change** è il commit storico che, secondo SZZ, ha introdotto la modifica difettosa.
- **Passaggi essenziali:** identificare il fix commit, eseguire la diff, isolare le righe corrette, usare `git blame` per la backward search.
- **Principali limiti:** **code additions**, **regressive bugs**, **refactoring**, **imprecise backward search** e, in senso più ampio, i problemi legati ai bug non ancora osservabili come nel caso dello **snoring**.

Capitolo 7

Leveraging Defects Lifecycle for Labeling Defective Classes

7.1 Contesto e obiettivo del lavoro

7.1.1 Defect prediction

La **defect prediction** ha l'obiettivo di identificare gli artefatti software, ad esempio classi o file, che hanno un'alta probabilità di manifestare un difetto. Lo scopo principale è ridurre i costi di testing e di code review, permettendo agli sviluppatori di concentrare gli sforzi sulle parti più critiche del codice.

7.1.2 Importanza del dataset

Affinché un modello di predizione sia affidabile, è fondamentale costruire **dataset di difetti di alta qualità**. L'intero lavoro si concentra infatti non tanto sul classificatore in sé, quanto sulla fase precedente, cioè la **costruzione del dataset** e in particolare il **labeling** delle classi come difettose o non difettose.

Se il labeling è inaccurato, il modello apprenderà relazioni sbagliate tra metriche e defectiveness. Per questo motivo, la qualità del dataset non è un dettaglio secondario, ma una condizione necessaria per ottenere risultati credibili.

Nota del Prof

Ci troviamo nella fase iniziale di **misurazione** e creazione del dataset. Prima ancora di addestrare un modello di Machine Learning, bisogna capire come etichettare correttamente le classi che in passato sono state davvero affette da difetti.

7.1.3 Labeling delle classi difettose

Le slide presentano due strategie principali per etichettare le classi come difettose o non difettose:

- usare **SZZ**;
- usare la **Earliest Affected Version (AV)** in **JIRA**, quando disponibile.

Il problema è che entrambe queste fonti possono essere incomplete o inaccurate. Da qui nasce la necessità di studiare metodi automatici alternativi per ricostruire il ciclo di vita del difetto.

7.1.4 Obiettivo generale dello studio

Lo studio ha un duplice obiettivo.

Da un lato, vuole capire **quanto siano disponibili e affidabili le informazioni di AV** inserite dagli sviluppatori nei ticket Jira. Dall'altro, propone un nuovo metodo automatizzato, chiamato **Proportion**, basato sull'idea che i difetti abbiano un **life-cycle relativamente stabile**.

In sintesi, il lavoro vuole:

1. misurare quanto sia realistico affidarsi ai dati di AV presenti in Jira;
2. proporre un metodo alternativo quando l'AV manca o è incoerente;
3. confrontare l'accuratezza del nuovo metodo con quella di diverse varianti di **SZZ**.

7.2 Concetti fondamentali

7.2.1 SZZ

SZZ è l'algoritmo classico per identificare il momento in cui un difetto è stato introdotto nel codice. A partire da un **fix commit**, SZZ usa il meccanismo di annotation del versioning system, per esempio **git blame**, per risalire all'ultima modifica precedente delle linee corrette.

7.2.2 Earliest AV in JIRA

L'approccio **Earliest AV in JIRA** consiste nell'usare la prima **Affected Version** riportata manualmente dagli sviluppatori nel sistema di tracciamento, ad esempio Jira. Se questa informazione fosse sempre presente e consistente, costituirebbe un riferimento molto utile per il labeling.

7.2.3 Defect lifecycle

L'idea centrale del paper è che ogni difetto attraversi un **ciclo di vita** che può essere descritto in termini di versioni del software. Questo ciclo di vita collega il momento in cui il difetto viene introdotto, quello in cui viene osservato e quello in cui viene definitivamente corretto.

7.2.4 Significato di IV, OV, FV e AV

Per descrivere il life-cycle del difetto, il paper usa quattro nozioni fondamentali.

- **IV (Injected Version)**: è la versione in cui il difetto viene introdotto nel codice.

Nota del Prof

È la prima versione in cui il bug esiste davvero nel sistema, anche se magari nessuno se n'è ancora accorto.

- **OV (Opening Version)**: è la versione in cui viene aperto il ticket del bug.

Nota del Prof

È il momento in cui la *failure*, cioè il malfunzionamento osservabile, viene riconosciuta e registrata.

- **FV (Fixed Version)**: è la prima versione rilasciata dopo il *fix commit*.

Nota del Prof

È la prima release in cui quel bug non dovrebbe più comparire.

- **AV (Affected Versions)**: sono tutte le versioni affette dal difetto, cioè l'intervallo di versioni comprese tra il momento di introduzione e quello di correzione.

In termini concettuali, le versioni difettose sono quelle comprese nell'intervallo $[IV, FV)$. Questo significa che la **Fixed Version** non è più affetta dal bug, mentre tutte le versioni precedenti a partire dalla **Injected Version** lo sono.

7.3 SZZ: funzionamento e limiti

7.3.1 Come funziona SZZ

SZZ individua i commit che hanno introdotto il bug tracciando la storia del codice sorgente. L'algoritmo parte da un **fix commit**, cioè da un commit che sappiamo correggere un bug, e usa quella correzione come indizio per cercare all'indietro il possibile **bug-introducing commit**.

7.3.2 Uso di `git blame` / `annotation mechanism`

Operativamente, SZZ prende le linee di codice modificate da un **fix commit** e usa `git blame` per risalire nel tempo, identificando il commit precedente che aveva introdotto o modificato quelle stesse righe.

L'assunzione di fondo è che il bug sia stato introdotto proprio nelle linee poi corrette dal fix. Quando questa assunzione è vera, SZZ può fornire una buona stima del momento di introduzione del difetto.

7.3.3 Bug introducing commit

Il commit individuato tramite backward search viene considerato il **bug-introducing commit**. Da quel momento in poi, la classe o il file coinvolto vengono etichettati come difettosi.

Nota del Prof

In pratica, il commit che ha scritto la forma sbagliata del codice viene trattato come l'origine storica del bug. È un'inferenza plausibile, ma non sempre perfetta.

7.3.4 Limiti del metodo

Le slide chiariscono che SZZ ha limiti strutturali importanti.

- **Non è perfettamente accurato:** il commit trovato da SZZ è una stima, non una verità certa.
- **Non riesce a identificare bene i regression bugs:** un codice può diventare errato solo in seguito a cambiamenti successivi del sistema, anche se in passato era corretto.
- **Non funziona bene quando il fix consiste solo in aggiunta di codice:** se il bug viene corretto introducendo codice nuovo, senza modificare righe già esistenti, SZZ non ha una traccia storica affidabile su cui applicare `git blame`.

Nota del Prof

SZZ può generare sia **falsi positivi** sia **falsi negativi**. Produce falsi positivi quando va troppo indietro nel tempo e attribuisce il difetto a linee che storicamente erano corrette; produce falsi negativi quando non riesce a risalire al vero punto di introduzione del bug.

7.4 Aim dello studio e Research Questions

7.4.1 Idea di stable life-cycle dei defect

L'intuizione centrale dello studio è che i difetti abbiano un **ciclo di vita stabile**. In altre parole, pur variando da bug a bug, sembrerebbe esistere una relazione abbastanza regolare tra:

- il numero di versioni che intercorrono tra introduzione del difetto e sua scoperta;
- il numero di versioni che intercorrono tra scoperta del difetto e sua correzione.

Questa ipotesi motiva il metodo **Proportion**: se tale proporzione è abbastanza stabile, allora è possibile stimare automaticamente la posizione dell'IV anche quando l'AV esplicita manca.

7.4.2 Research Questions

Le domande di ricerca dello studio sono quattro:

- **RQ1:** le **Affected Versions (AV)** sono disponibili e consistenti in Jira?
- **RQ2:** i vari metodi, ad esempio SZZ e Proportion, hanno accuratèzze diverse nell'etichettare le **Affected Versions**?

- **RQ3:** i metodi hanno accuratezze diverse nell'etichettare le **single classi difettose**?
- **RQ4:** l'uso di metodi diversi porta all'identificazione di **feature importanti** diverse nei modelli di predizione?

In questo capitolo ci fermiamo a **RQ1** e **RQ2**.

7.5 RQ1: Is the AV available and consistent?

7.5.1 Rationale

La prima domanda vuole verificare se il campo **Affected Version** sia effettivamente utilizzabile come fonte affidabile per il labeling. Ci sono infatti due problemi distinti:

- **availability:** gli sviluppatori potrebbero non compilare affatto il campo AV;
- **consistency:** il campo potrebbe essere compilato, ma in modo incoerente rispetto all'ordine temporale delle versioni.

Nota del Prof

Per esempio, se la versione più vecchia indicata come affetta risulta successiva all'apertura del ticket, allora quella AV non è coerente e non può essere usata come ground truth affidabile.

7.5.2 Design e selezione di progetti e bug

Per RQ1 sono stati analizzati **212 progetti Apache** collegati sia a **Git** sia a **Jira**. Sono stati considerati solo gli issue report che soddisfacevano simultaneamente i seguenti criteri:

- `Type == Bug`;
- `Status == Closed` oppure `Resolved`;
- `Resolution == Fixed`.

Inoltre, sono stati esclusi:

- i difetti che non avevano un **Git-related fix commit**;
- i difetti che **non erano post-release**.

Dal punto di vista sperimentale:

- la **variabile indipendente** è il singolo **defect**;
- la **variabile dipendente** è la **percentuale di AV disponibili** e di **AV disponibili e consistenti**.

7.5.3 Risultati

I risultati mostrano che il problema è molto rilevante. Sul totale dei difetti selezionati:

- il numero complessivo di bug chiusi e collegati a Git nei 212 progetti Apache è pari a **125.860**;
- **63.539 bug**, cioè circa il **51%**, risultano privi di AV utilizzabile oppure presentano un'AV inaffidabile.

Inoltre, per la maggior parte dei progetti, più del **25%** dei difetti non possiede una AV disponibile e consistente.

7.5.4 Discussione e implicazioni pratiche

La conclusione di RQ1 è netta: l'approccio basato esclusivamente sulla AV inserita in Jira **non è sufficiente** nella maggioranza dei casi.

Se più della metà dei bug non ha una AV affidabile, allora il labeling realistico basato solo sui dati espliciti del ticket diventa spesso impossibile. Questo giustifica la necessità di metodi automatici alternativi.

Nota del Prof

Se non abbiamo un'AV affidabile e non introduciamo un metodo compensativo, finiamo per etichettare come pulite molte classi che invece erano già affette da difetti. Questo produce inevitabilmente molti **falsi negativi** nel dataset.

7.6 RQ2: Do methods have different accuracy in AV labeling?

7.6.1 Razionale

Dato che RQ1 mostra che l'AV è spesso assente o inconsistente, RQ2 si chiede se esistano metodi automatici più accurati per **predire correttamente le versioni affette da un bug**.

La domanda non è più semplicemente "l'AV c'è?", ma: *quando manca, quale metodo ricostruisce meglio l'intervallo delle versioni difettose?*

7.6.2 Selezione dei progetti

Per valutare i metodi in modo affidabile, RQ2 restringe l'analisi a progetti per cui esiste una ground truth più solida. I criteri di selezione sono:

- progetti con più del **50%** di AV disponibili e consistenti;
- progetti con almeno **100 bug** collegati a un Git fix commit e con AV disponibile e consistente;
- progetti con almeno **6 versioni**.

Dopo questa selezione, rimangono **76 progetti Apache Jira**.

7.6.3 Formula della Proportion e significato di P

Il paper introduce una misura proporzionale del ciclo di vita del difetto:

$$P = \frac{FV - IV}{FV - OV}$$

Questa quantità misura, in termini di versioni, il rapporto tra:

- la distanza tra **Fixed Version** e **Injected Version**;
- la distanza tra **Fixed Version** e **Opening Version**.

Una volta stimata P , è possibile ricavare una **Predicted IV** mediante la formula:

$$\text{Predicted IV} = FV - (FV - OV) \cdot P$$

Nota del Prof

L'idea intuitiva è che, pur cambiando la durata assoluta dei singoli bug, la **proporzione** tra momento di scoperta e momento di correzione tenda a essere relativamente stabile. Per questo motivo si prova a usare P come “firma temporale” del lifecycle dei difetti.

7.6.4 Varianti di Proportion

Il paper confronta tre modi diversi di stimare P :

- **Cold Start:** P è calcolato come mediana dei difetti osservati negli altri progetti;
- **Increment:** P è calcolato come media dei difetti corretti nelle versioni precedenti dello stesso progetto;
- **Moving Window:** P è calcolato come media dell'ultimo 1% dei difetti corretti.

Le tre varianti riflettono tre strategie diverse: usare esperienza di altri progetti, usare solo il passato interno del progetto, oppure concentrarsi sul comportamento più recente del processo.

Nota del Prof

A lezione è stata discussa anche una variante chiamata **Total**, che usa tutti i difetti passati e futuri per stimare P . Questa variante non appartiene al paper, ma è utile per capire il problema del realismo temporale.

IMPORTANTE PER L'ESAME

La variante **Total** è concettualmente scorretta in ottica di Machine Learning realistico, perché usa informazioni del futuro per etichettare il passato. In un vero scenario predittivo, il futuro non è disponibile al momento della costruzione del dataset.

7.6.5 Metodi confrontati

I metodi messi a confronto in RQ2 sono:

- **Simple**: assume semplicemente $IV = OV$;
- **SZZ_B** (*Basic*);
- **SZZ_U** (*Unleashed*);
- **SZZ_RA** (*Refactoring Aware*);
- **Proportion_ColdStart**;
- **Proportion_Increment**;
- **Proportion_MovingWindow**;
- le versioni **SZZ_X+**, cioè ciascun metodo SZZ combinato con **Simple**.

7.6.6 Variabili dipendenti e definizione di TP, TN, FP, FN

L'unità di analisi di RQ2 non è ancora la classe-versione, ma la **versione rispetto a un singolo difetto**. In altre parole, si valuta se un metodo etichetta correttamente una certa versione come affetta

Capitolo 8

Defect Labeling, Evaluation and Metrics

8.1 RQ3: Accuratezza nel labeling delle classi

8.1.1 Differenza rispetto a RQ2

Mentre in **RQ2** l'obiettivo era valutare l'accuratezza nell'individuare le **Affected Versions (AV)** di un difetto, in **RQ3** il livello di analisi diventa più fine. Lo scopo non è più soltanto capire se una *versione* sia affetta da un certo bug, ma costruire il dataset più accurato possibile per la **defect prediction a livello di classe**.

In altre parole, RQ2 ragiona ancora in termini di **versione-difetto**, mentre RQ3 passa al problema realmente utile per il dataset finale, cioè stabilire se una **specifica classe** in una **specifica versione** debba essere etichettata come difettosa oppure no.

8.1.2 Rationale

Il rationale di questa ricerca è capire **quale metodo produca il dataset di defect prediction più accurato**. Nel contesto **within-project, across-version, class-level**, la domanda diventa:

una certa classe, in una certa release, deve essere considerata **defective** oppure **non-defective**?

Questa è la forma di labeling che serve davvero per addestrare un classificatore sulle classi software.

8.1.3 Unità di analisi

L'unità di misura non è più la singola versione, ma la coppia **classe-versione**, per esempio *F1.java nella release 1*. Questo significa che ogni istanza del dataset finale rappresenta una classe osservata in una certa release.

8.1.4 Design

Le **variabili indipendenti** rimangono le stesse di RQ2, cioè i diversi metodi di labeling:

- **Simple**;
- **SZZ_B**, **SZZ_U**, **SZZ_RA**;
- **Proportion_ColdStart**, **Proportion_Increment**, **Proportion_MovingWindow**;
- le varianti **SZZ_X+**.

Le **variabili dipendenti** sono le stesse di RQ2, ma cambiano di significato perché l'unità di analisi non è più la versione, bensì la **defectiveness di una classe in una versione**.

Più precisamente:

- **True Positive (TP)**: la classe in una certa versione è realmente difettosa ed è etichettata come difettosa;
- **False Negative (FN)**: la classe in una certa versione è realmente difettosa, ma viene etichettata come non difettosa;
- **True Negative (TN)**: la classe in una certa versione è realmente non difettosa ed è etichettata come non difettosa;
- **False Positive (FP)**: la classe in una certa versione è realmente non difettosa, ma viene etichettata come difettosa.

Da queste quantità vengono poi calcolate le metriche standard:

- **Precision**;
- **Recall**;
- **F1**;
- **MCC**;
- **Kappa**.

8.1.5 Risultati

I risultati mostrano una struttura molto simile a quella già osservata in RQ2, ma con una differenza importante a livello di dominanza dei metodi.

- Come in RQ2, i metodi **Proportion** hanno **Precision** e accuratezza composita, cioè **F1**, **MCC** e **Kappa**, superiori a tutti i metodi **SZZ**.
- Come in RQ2, **SZZ_U** ottiene la **Recall** più alta tra tutti i metodi.
- Come in RQ2, **SZZ_B+** ha la più alta **Precision** all'interno della famiglia **SZZ**.
- Diversamente da RQ2, **Proportion_MovingWindow** emerge come metodo dominante sulle **metriche composite**, risultando il più forte nel labeling delle classi.

8.1.6 Discussione

La discussione di RQ3 porta a tre osservazioni importanti.

La prima è che, confrontando i metodi **SZZ_X** con le corrispondenti varianti **SZZ_X+**, il guadagno nel **class labeling** è **inferiore all'1%**. Quindi, anche qui, l'integrazione con informazioni aggiuntive migliora poco i metodi SZZ sul piano pratico.

La seconda è che **tutti i metodi risultano più accurati nel labeling delle classi che nel labeling delle AV**. Questo è un punto metodologicamente importante: etichettare correttamente una classe è più facile che ricostruire perfettamente l'intero intervallo delle versioni affette da un difetto.

La terza è che questo miglioramento è quantificabile. Rispetto al task di AV labeling, nel task di class labeling si osserva un aumento mediano di:

- **13%** in Precision;
- **5%** in Recall;
- **16%** in F1;
- **27%** in MCC;
- **39%** in Kappa.

Solo nelle slide (non spiegato a voce)

La spiegazione proposta nelle slide è che una singola classe può essere affetta da **più difetti simultaneamente**. Di conseguenza, anche se un metodo manca un difetto specifico, può comunque etichettare correttamente la classe come difettosa grazie alla presenza di un altro difetto concomitante.

Nota del Prof

La Recall di SZZ tende a essere più alta perché SZZ va molto più indietro nel tempo rispetto a Proportion. Questo fa emergere più classi positive, ma al prezzo di moltissimi **falsi positivi**. Quindi SZZ recupera più positivi, ma sporca molto di più il dataset.

8.2 RQ4: Identificazione delle feature importanti

8.2.1 Razionale

RQ4 studia l'effetto a cascata del labeling sulla comprensione del problema. Non basta infatti costruire un dataset etichettato: bisogna anche capire se il metodo di labeling usato influenza **quali feature sembrano importanti** per spiegare la defectiveness.

Il razionale è quindi doppio:

1. capire **quali feature** vengono selezionate come rilevanti dal dataset costruito con un certo metodo;
2. capire se la relazione tra queste feature e la variabile target, cioè la **class defectiveness**, venga preservata correttamente.

Questo è molto importante dal punto di vista pratico, perché le metriche selezionate come più rilevanti guidano anche l'interpretazione ingegneristica del fenomeno: per esempio, si può voler capire se il rischio dipenda da **LOC**, **Churn**, **Age**, **Change Set Size** o altre metriche di processo e prodotto.

8.2.2 Feature selection

Per la **feature selection** si confrontano le feature selezionate usando il dataset prodotto da un certo metodo con le feature selezionate usando il dataset **actual**, cioè quello assunto come riferimento.

Lo scopo è misurare quanto fedelmente un metodo di labeling riesca a preservare la scelta delle feature rilevanti.

Nel materiale del corso viene indicato un approccio di **Exhaustive Search Feature Selection**, implementato tramite Weka e `CfsSubsetEval`. L'idea generale è scegliere feature:

- fortemente informative rispetto alla defectiveness;
- poco ridondanti tra loro.

Per confrontare la correttezza della feature selection vengono riutilizzate metriche analoghe a quelle già viste:

- **TP**;
- **TN**;
- **FP**;
- **FN**;
- **Precision**;
- **Recall**;
- **F1**;
- **MCC**;
- **Kappa**.

8.2.3 Correlation analysis

La seconda metà di RQ4 riguarda la **correlation analysis**. In questo caso non si confrontano più insiemi di feature selezionate, ma il valore della correlazione misurata:

- nel dataset prodotto da un certo metodo;
- nel dataset **actual**.

L'idea è verificare se un metodo di labeling alteri o meno la relazione statistica tra una feature e la defectiveness. Se il labeling è rumoroso, anche la correlazione osservata può risultare distorta.

Nel materiale del corso questa parte viene associata alla **correlazione di Spearman**.

8.2.4 Standard Mean Relative Error

Per quantificare lo scostamento tra la correlazione **predicted** e quella **actual**, viene usato lo **Standard Mean Relative Error**, espresso come:

$$\frac{|\text{Predicted} - \text{Actual}|}{\text{Actual}}$$

Questa formula misura l'errore relativo tra ciò che il metodo stima e ciò che si osserverebbe nel dataset di riferimento.

8.2.5 Risultati

I risultati di RQ4 mostrano in modo molto netto la superiorità dei metodi **Proportion** rispetto ai metodi **SZZ** anche su questo piano.

- I metodi **Proportion** hanno un'accuratezza superiore a tutti i metodi **SZZ** in **tutte e cinque le metriche** considerate.
- I metodi **Proportion** sono gli unici a mostrare una **mediana perfetta** sia in **Precision** sia in **Recall**.
- Diversamente da quanto accade in RQ2 e RQ3, tra le diverse varianti di **SZZ** non emergono grandi differenze.
- Il miglioramento ottenuto passando da **SZZ_X** a **SZZ_X+** resta ancora una volta **inferiore all'1%**.

8.2.6 Discussione

La discussione rende ancora più esplicita la portata dei risultati.

- I metodi **Proportion** hanno un errore che è circa il **25%** dell'errore commesso dai metodi **SZZ**. In altre parole, nel task di identificazione delle feature importanti, **Proportion** sbaglia molto meno.
- A differenza di quanto visto in RQ2 e RQ3, persino il metodo **Simple** risulta più accurato di tutti i metodi **SZZ** in questo task, con un errore che è circa **la metà** di quello di **SZZ**.
- Anche qui il guadagno ottenuto usando le varianti **SZZ_X+** è **praticamente irrilevante**, restando sotto l'1%.

Solo nelle slide (non spiegato a voce)

Le slide sottolineano che la selezione delle feature e l'osservazione delle correlazioni risultano, nel complesso e in media, significativamente più accurate quando si usa il **bugs' life-cycle** rispetto a qualunque metodo **SZZ**.

8.3 Figure, tabelle e workflow del paper

Solo nelle slide (non spiegato a voce)

Le figure, le tabelle e i workflow di questa sezione derivano dalle slide e dal paper, ma non sono stati spiegati a voce in maniera estesa. Conviene quindi leggerli come supporto alla comprensione del flusso metodologico.

8.3.1 Diagramma del defect lifecycle (Fig. 1.1)

Il diagramma del **defect lifecycle** rappresenta la sequenza temporale fondamentale di un bug:

$$IV \rightarrow OV \rightarrow Fix\ Commit \rightarrow FV$$

dove:

- **IV** è la **Injected Version**;
- **OV** è la **Opening Version**;
- **FV** è la **Fixed Version**.

Le versioni affette dal difetto sono quelle comprese nell'intervallo $[IV, FV)$. Questo significa che il bug esiste già da **IV** e smette di essere presente a partire dalla **FV**.

8.3.2 Workflow del predicted AV (Fig. 3.1)

Il workflow del **predicted AV** mostra come le informazioni provenienti da **Git** e **Jira** vengano combinate.

In particolare:

- da **Git** si ricava il **Bug Fix**;
- da **Jira** si ricavano **Ticket Creation** e **Releases**;
- un certo **Method**, ad esempio **Proportion**, usa queste informazioni per costruire una **Predicted AV**;
- la **Predicted AV** viene confrontata con la **Actual AV** per ricavare **TP**, **TN**, **FP** e **FN**.

8.3.3 Workflow del class labeling (Fig. 3.2)

Il workflow del **class labeling** prende i file o le classi toccate dal **fix** e li combina con l'informazione sulle versioni affette per stabilire, release per release, se una certa classe debba essere considerata difettosa oppure no.

Questo è il passaggio che trasforma un'informazione a livello di **bug/versione** in un'informazione a livello di **classe-versione**, cioè nel formato realmente utile per la defect prediction.

8.3.4 Workflow della creazione dei complete datasets (Fig. 3.3)

Nel workflow dei **complete datasets** al class labeling viene aggiunta la fase di **Metric Collection**. Il risultato finale è una tabella in cui, per ogni istanza classe-versione, si raccolgono:

- l'identificativo della **release**;
- il nome del **file** o della **classe**;
- la label di **defectiveness**;
- varie metriche software, ad esempio **LOC**, **LOC Touched**, **Nfix**, **Churn**, **Age**, **Change Set Size**.

8.3.5 Feature selection e correlation analysis (Fig. 3.4 e Fig. 3.5)

Le figure dedicate a **feature selection** e **correlation analysis** mostrano due flussi paralleli:

- nel primo caso, il dataset predetto e quello actual vengono sottoposti a **feature selection**, e si confrontano le feature selezionate;
- nel secondo caso, sui due dataset si calcolano le correlazioni e si confrontano tramite l'errore relativo.

In entrambi i casi, l'idea è verificare quanto bene il metodo di labeling preservi l'informazione utile per la spiegazione del fenomeno.

8.3.6 Interpretazione di grafici, boxplot e tabelle comparative

I grafici e i boxplot delle slide trasmettono due messaggi centrali.

Il primo è che la variabile P risulta **molto più stabile** rispetto a **IV**, **OV** e **FV**. Le slide osservano infatti che la deviazione standard di P è circa **5** tra progetti diversi e circa **2** all'interno dello stesso progetto. Questo supporta l'ipotesi di **stable life-cycle**.

Il secondo è che, nelle metriche di accuratezza, i metodi **SZZ** tendono a mostrare valori più bassi e meno stabili, soprattutto su **MCC** e **Kappa**, mentre i metodi **Proportion** risultano mediamente più alti e più robusti.

8.4 Evaluation of Machine Learning Models

8.4.1 Training, testing e tuning

La costruzione di un modello di Machine Learning richiede almeno tre momenti distinti:

- **training**, in cui il modello viene addestrato;
- **testing**, in cui il modello viene valutato su dati indipendenti;
- **tuning**, in cui si regolano parametri o scelte modellistiche per migliorarne le prestazioni.

8.4.2 Perché l'errore sul training set non basta

L'errore osservato sul **training set** non è sufficiente per stimare la qualità del modello, perché il modello è stato costruito proprio su quei dati. Una performance alta in training può quindi riflettere semplice adattamento ai dati storici, non reale capacità di generalizzazione.

8.4.3 Training set vs test set

Per valutare seriamente un classificatore, bisogna separare:

- un **training set**, usato per apprendere;
- un **test set**, usato solo per verificare quanto il modello sappia comportarsi su dati non visti.

Nota del Prof

Tutti i dati della tabella sono di tipo *supervised*, quindi conosciamo già l'etichetta corretta. Per simulare il caso reale, si nasconde una parte dei risultati e si usa il modello addestrato sul training set per predirli. Solo dopo si confrontano *actual* e *predicted*.

8.4.4 Dati rappresentativi

Affinché la stima dell'errore abbia senso, sia il training set sia il test set devono essere **rappresentativi** dello stesso problema. Se training e test descrivono popolazioni diverse, la valutazione non misura più correttamente la capacità di generalizzazione.

8.4.5 Problema dei dati limitati

Idealmente, training e test dovrebbero essere grandi. In pratica, però, nei problemi di defect prediction i dati etichettati non sono infiniti, e questo rende necessarie tecniche di validazione che riusino i dati in modo intelligente senza violare il realismo sperimentale.

Nota del Prof

L'assioma implicito di tutta la validazione è che **il futuro sia simile al passato**. Usiamo il passato per stimare come il modello si comporterà su dati futuri che non abbiamo ancora osservato.

8.5 Tecniche di validazione non temporali

Queste tecniche si usano quando l'ordine temporale dei dati non è determinante oppure quando le istanze possono essere trattate come indipendenti.

8.5.1 Holdout

Nel metodo **holdout** il dataset viene diviso una sola volta, per esempio in 2/3 training e 1/3 testing.

Il vantaggio è la semplicità; lo svantaggio è che il campione selezionato per test potrebbe non essere rappresentativo.

Nota del Prof

Se una classe rara finisce tutta nel test set, il modello non l'ha mai vista in training e quindi non può imparare a riconoscerla.

8.5.2 Stratification

La **stratification** è una variante dell'holdout che cerca di mantenere in training e test proporzioni simili della classe di interesse, così da ridurre il rischio di campioni troppo sbilanciati.

8.5.3 Repeated holdout

Nel **repeated holdout** si ripete più volte l'holdout con partizioni diverse e si media l'errore. In questo modo si attenua la dipendenza da una singola divisione sfortunata dei dati.

Il limite è che i test set possono sovrapporsi, e il costo computazionale cresce rapidamente.

Nota del Prof

Se una singola run richiede 5 ore, ripetere l'holdout 5 volte porta facilmente a 25 ore di elaborazione.

8.5.4 K-fold cross-validation

La **k-fold cross-validation** divide il dataset in K parti uguali. A ogni iterazione, una parte viene usata per il test e le altre $K - 1$ per il training. Il processo viene ripetuto K volte, così che ogni istanza finisca nel test set esattamente una volta.

Nota del Prof

L'analogia della pizza è molto efficace: si taglia la pizza in K spicchi, se ne usa uno come test e gli altri come training, poi si cambia spicchio e si ripete finché ogni spicchio è stato usato una volta come test.

8.5.5 Stratified k-fold cross-validation e repeated stratified cross-validation

La versione **stratified** cerca di mantenere la proporzione delle classi in ogni fold. Una pratica comune è il **10 times 10-fold stratified**, che offre stime molto stabili ma richiede molte esecuzioni.

8.5.6 Leave-one-out cross-validation

La **leave-one-out cross-validation** è il caso limite in cui $K = n$, cioè ogni test set contiene una sola istanza. Massimizza l'uso dei dati per il training, ma ha costi computazionali elevati e rende impossibile la stratificazione.

8.5.7 Bootstrap

Il **bootstrap** usa campionamento con reinserimento. Alcune istanze possono comparire molte volte nel training set, mentre altre possono non comparire affatto.

Nota del Prof

Nel contesto del corso questo metodo viene sconsigliato, perché tende a produrre campioni troppo distorti e poco realistici per la defect prediction.

8.6 Tecniche di validazione temporali

Queste tecniche si usano quando l'ordine temporale è parte integrante del problema, come accade nei dataset software basati sull'evoluzione delle release.

8.6.1 Time-series validation

La **time-series validation** preserva l'ordine cronologico dei dati, evitando che il training contenga informazioni provenienti dal futuro rispetto al test.

8.6.2 Ordered holdout

L'**ordered holdout** è un holdout che rispetta la cronologia: la parte iniziale del dataset va nel training set e la parte finale nel test set.

8.6.3 Walk-forward

Nel **walk-forward** il dataset viene diviso in blocchi cronologici, per esempio per release. A ogni passo, si addestra il modello su tutte le release precedenti e si testa su quella successiva.

Nota del Prof

Se l'obiettivo è predire la **Release 4**, allora il training set deve essere composto dall'unione di **Release 1, 2 e 3**. In questo modo il modello usa solo ciò che, realisticamente, era già noto prima della Release 4.

8.6.4 Importanza dell'ordine temporale

Nel contesto della defect prediction, ignorare il tempo significa violare il realismo sperimentale. Un metodo che usa informazioni provenienti dal futuro produce stime artificialmente ottimistiche.

Nota del Prof

Questo è esattamente il problema della variante **Total** discussa a lezione: usare bug futuri per etichettare il passato significa dare al modello un vantaggio che in un vero scenario di predizione non avrebbe mai.

8.7 Performance metrics

8.7.1 Binary classifier

Un **binary classifier** è un modello che assegna ogni istanza a una di due classi, per esempio **Buggy** oppure **Non-Buggy**.

8.7.2 Confusion matrix e metriche base

Le quattro quantità fondamentali della **confusion matrix** sono:

- **TP (True Positive)**: predetto positivo, realmente positivo;
- **FP (False Positive)**: predetto positivo, realmente negativo;
- **TN (True Negative)**: predetto negativo, realmente negativo;
- **FN (False Negative)**: predetto negativo, realmente positivo.

Nota del Prof

Un **False Positive** significa sprecare effort di testing su una classe che in realtà è sana.

Nota del Prof

Un **False Negative** è molto più pericoloso: la classe è davvero difettosa, ma il modello la considera pulita, quindi rischia di arrivare in produzione senza essere testata adeguatamente.

8.7.3 Precision

La **Precision** è definita come:

$$\frac{TP}{TP + FP}$$

e misura quanto siano affidabili le predizioni positive del modello.

Nota del Prof

È la logica di “al lupo al lupo”: se il modello segnala bug ovunque, finirà inevitabilmente con l’avere una Precision bassa.

8.7.4 Recall

La **Recall** è definita come:

$$\frac{TP}{TP + FN}$$

e misura quanti dei positivi reali vengono effettivamente recuperati dal classificatore.

8.7.5 Accuracy

L'**Accuracy** è:

$$\frac{TP + TN}{TP + TN + FP + FN}$$

ma, da sola, può essere fuorviante in presenza di dataset molto sbilanciati.

8.7.6 Kappa

Il **Kappa** misura quanto il classificatore faccia meglio di un classificatore casuale o maggioritario. Vale:

- 1 in caso di classificazione perfetta;
- 0 se la performance equivale al caso;
- valori negativi se il classificatore è peggiore del caso.

Nota del Prof

Nel contesto del corso, un valore di Kappa sufficientemente alto suggerisce che ci sia davvero una relazione empirica non banale tra metriche software e difetti.

8.7.7 Dipendenza dal contesto applicativo

Solo nelle slide (non spiegato a voce)

Le metriche non vanno mai interpretate in isolamento. Per esempio, una Recall molto alta può essere banale da ottenere in dataset fortemente sbilanciati. Bisogna quindi sempre valutare le metriche nel contesto applicativo corretto.

8.8 ROC curves e AUC

8.8.1 Threshold dependence

Metriche come **Precision**, **Recall** e **F1** dipendono dalla soglia usata per trasformare una probabilità in una decisione binaria.

8.8.2 ROC curve

La **ROC curve** rappresenta il compromesso tra:

- **True Positive Rate (TPR)**;
- **False Positive Rate (FPR)**.

Ogni punto della curva corrisponde a una soglia diversa.

8.8.3 AUC

L'**AUC** è l'area sotto la ROC curve e misura, in termini probabilistici, la capacità del modello di assegnare un punteggio più alto a un positivo che a un negativo.

IMPORTANTE PER L'ESAME

Il limite principale dell'AUC, sottolineato a lezione, è che media le prestazioni su **tutte** le soglie possibili, comprese soglie che nel contesto reale potrebbero non avere alcun senso pratico. Per questo motivo, pur essendo utile, non sempre è la metrica più significativa dal punto di vista ingegneristico.

8.9 Collegamento tra i due PDF

Questa parte del materiale mette in relazione due livelli diversi dello stesso problema:

- da un lato il **labeling dei difetti**, cioè la costruzione del dataset;
- dall'altro la **valutazione dei modelli**, cioè il modo in cui giudichiamo la bontà di un classificatore.

8.9.1 Come il labeling influenza la qualità del dataset e del modello

Prima di poter valutare un modello, bisogna costruire un dataset con una ground truth il più possibile affidabile. Se il metodo di labeling è inaccurato, allora il classificatore verrà addestrato su esempi etichettati male e imparerà pattern sbagliati.

Nota del Prof

Questo è un caso classico di *Garbage In, Garbage Out*. Se SZZ sporca il dataset andando troppo indietro nel tempo o etichettando male le classi, il modello imparerà associazioni scorrette e fallirà anche se la fase di validazione è formalmente ben eseguita.

8.9.2 Realismo temporale e defect prediction

L'idea di **realismo temporale** accomuna sia i metodi di labeling sia le tecniche di validazione. Usare solo difetti passati per stimare P , come in **Proportion_Increment**, e usare solo release passate per addestrare il modello, come nel **walk-forward**, riflette lo stesso principio: il modello non deve mai leggere il futuro.

8.9.3 Scegliere bene metriche e validazione

Se lo scopo è supportare decisioni reali su testing e code review, allora servono:

- un **dataset ben etichettato**;
- una **validazione coerente con il tempo**;
- metriche interpretabili, come **F1** e **Kappa**, da leggere insieme e non separatamente.

Un metodo di labeling migliore, come **Proportion**, rende anche più affidabile l'identificazione delle feature importanti, cioè delle vere cause del rischio di difettosità.

8.10 Conclusioni finali

I risultati del paper su **Proportion** e i concetti sulle metriche di valutazione convergono verso una stessa conclusione metodologica: nel Machine Learning applicato alla Software Engineering non basta scegliere un buon classificatore; occorre soprattutto essere rigorosi nella **costruzione del dataset** e nella **validazione del modello**.

8.10.1 Risultati del paper Proportion e limiti dell'approccio Jira-based

Su circa **125.000 difetti**, il lavoro mostra che affidarsi soltanto alle **Affected Versions** presenti in Jira è impossibile in circa il **51%** dei casi, a causa di AV mancanti o incoerenti.

8.10.2 Confronto Proportion vs SZZ

Nei dataset costruiti a livello di classi, i metodi **Proportion** risultano mediamente più accurati di **SZZ** in **Precision**, **F1**, **MCC** e **Kappa**. **SZZ** mantiene una Recall più alta, ma questo dipende dal fatto che tende a etichettare come positive molte più classi, pagando però un prezzo elevato in termini di falsi positivi.

8.10.3 Conclusioni su validazione e metriche

Nessuna metrica da sola è sufficiente. Per giudicare davvero la bontà di un modello di defect prediction bisogna:

- usare un labeling credibile;
- rispettare il tempo con tecniche come **ordered holdout** o **walk-forward**;
- interpretare le metriche in modo congiunto, tenendo conto del contesto applicativo.

Il messaggio finale è quindi che **dataset quality**, **realismo temporale** e **valutazione corretta** sono tre aspetti inseparabili dello stesso problema.

Capitolo 9

Snoring: rumore nei dataset di defect prediction

9.1 Introduzione e contesto

La **defect prediction** mira a identificare gli artefatti software, come classi o file, che hanno un'alta probabilità di presentare un difetto. Il suo obiettivo principale è ridurre i costi di testing e code review, permettendo agli sviluppatori di concentrare gli sforzi sulle parti più rischiose del codice.

Il contesto dello studio è la **within-project defect prediction**, cioè la classificazione delle classi difettose all'interno di specifiche release di uno stesso progetto.

L'affidabilità di un modello predittivo dipende direttamente dalla qualità del dataset. Se il dataset contiene rumore, anche la valutazione e l'addestramento dei classificatori possono risultare distorti.

Nota del Prof

Il concetto centrale è il principio **Garbage In, Garbage Out**: se le etichette del dataset sono sbagliate, anche il modello più sofisticato apprenderà informazioni distorte.

Solo nelle slide (non spiegato a voce)

Le slide ricordano che lavori precedenti avevano già individuato altre fonti di rumore nei dataset di defect prediction, come la misclassification e l'origine errata dei difetti.

9.2 Sleeping defects e snoring classes

Uno **sleeping defect**, o **dormant bug**, è un difetto che viene scoperto o corretto diverse release dopo la sua introduzione effettiva nel codice. Il difetto è quindi già presente nel sistema, ma non è ancora visibile al costruttore del dataset.

Il ciclo di vita di un difetto può essere descritto tramite tre eventi principali:

- **I, Injected**: il difetto viene introdotto nel codice;
- **N oppure OV, Noticing/Opening Version**: il difetto viene osservato o viene aperto il ticket;

- **F oppure FV, Fixed Version:** il difetto viene corretto tramite fix commit.

Le **snoring classes** sono classi affette esclusivamente da difetti non ancora corretti. Poiché l'esistenza del difetto non è conoscibile prima del fix, queste classi vengono erroneamente considerate non difettose.

Nota del Prof

La metafora è utile: il difetto *dorme*, mentre la classe *rusa*, perché produce rumore nel dataset. Una classe rusa solo se tutti i difetti che la colpiscono sono ancora dormienti. Se contiene almeno un difetto già noto e corretto, viene comunque etichettata come difettosa.

IMPORTANTE PER L'ESAME

Lo **snoring** introduce nei dataset **falsi negativi**, non falsi positivi. Una classe etichettata come difettosa è supportata da un fix osservato; una classe etichettata come non difettosa, invece, potrebbe contenere un difetto non ancora scoperto.

Solo nelle slide (non spiegato a voce)

Le slide mostrano un esempio con tre classi, C1, C2 e C3, osservate su più release. Una classe può essere realmente difettosa in una release intermedia, ma risultare *not defective* se il relativo fix avviene solo in una release successiva.

9.3 Assegnazione dei difetti alle classi

Per stabilire da quando una classe deve essere considerata difettosa, il processo può usare due fonti principali:

1. la prima **Affected Version** riportata nel sistema di issue tracking, ad esempio Jira;
2. un algoritmo di ricostruzione storica, come **SZZ**, quando l'Affected Version non è disponibile o non è affidabile.

Le nozioni principali sono:

- **IV, Injected Version:** release in cui il difetto viene introdotto;
- **OV, Opening Version:** release in cui viene aperto il ticket;
- **FV, Fixed Version:** release in cui il difetto viene corretto;
- **AV, Affected Version:** informazione che indica le versioni affette dal difetto.

Nota del Prof

Una classe può essere realmente difettosa ma apparire non buggy se, nello snapshot analizzato, il difetto è già presente ma il relativo ticket o fix sarà osservato solo in futuro. Questo è il punto in cui nasce il falso negativo.

9.4 SZZ: funzionamento e limiti

SZZ è un processo algoritmico usato per identificare quando un difetto è stato introdotto in un progetto software.

A partire da un **bug-fix commit**, SZZ analizza le linee modificate dalla correzione e usa meccanismi come `git blame` per risalire all'ultima modifica precedente di quelle stesse linee. Tale modifica viene interpretata come possibile **bug-introducing change**.

Solo nelle slide (non spiegato a voce)

Nelle slide è mostrato un esempio in cui un bug di tipo “Array index out of range” viene corretto modificando la condizione di un ciclo da `i<=4` a `i<4`. SZZ parte dal fix e risale alla versione precedente in cui la riga errata era stata introdotta.

SZZ presenta diversi limiti:

- può fallire quando il fix consiste in una **code addition**;
- è sensibile ai **refactoring**;
- può produrre una **backward search** imprecisa;
- non gestisce perfettamente i **regressive bugs**;
- non elimina il problema dello **snoring**, perché i difetti non ancora corretti restano invisibili.

Solo nelle slide (non spiegato a voce)

Le slide riportano che solo una parte dei bug-introducing changes può essere individuata tramite l'assunzione classica di SZZ, secondo cui il bug è stato introdotto nelle stesse linee poi modificate dal fix.

9.5 Research Questions dello studio

Lo studio sullo snoring si articola in cinque research questions:

1. **RQ1: To what extent do defects sleep?**
2. **RQ2: To what extent do classes snore?**
3. **RQ3: To what extent does snoring impact the evaluation of classifiers accuracy?**
4. **RQ4: To what extent does snoring impact defect prediction accuracy?**
5. **RQ5: To what extent is no data better than snoring data?**

Le prime due domande misurano l'entità del fenomeno, mentre le ultime tre analizzano l'impatto dello snoring sulla valutazione e sull'addestramento dei classificatori.

9.6 RQ1: To what extent do defects sleep?

9.6.1 Rationale

La prima research question misura quante release trascorrono tra l'introduzione di un difetto e la sua correzione. L'obiettivo è quantificare quanto a lungo un difetto possa restare invisibile nel progetto.

9.6.2 Design

Sono stati selezionati **20 grandi progetti Apache**, con issue tracking in Jira e codice versionato in Git. I progetti considerati hanno almeno 10 release e un buon collegamento tra bug e codice.

9.6.3 Variabili

- **Variabile indipendente:** il bug o ticket in Jira.
- **Variabile dipendente:** numero di release per cui il bug ha dormito, misurato tra l'introduzione e il fix.

9.6.4 Risultati e discussione

Il risultato principale è che il bug medio dorme per circa **7 release**. Inoltre, nella maggior parte dei progetti, i difetti dormono per oltre il **19%** delle release esistenti.

Solo nelle slide (non spiegato a voce)

Le slide riportano casi estremi come **LUCENE-3672**, dormiente per 84 release, e **STRATOS-1653**, dormiente per 51 release su 53.

9.7 RQ2: To what extent do classes snore?

9.7.1 Rationale

Non ogni sleeping defect produce necessariamente una snoring class. Se una classe contiene anche un altro difetto già noto, la classe viene comunque etichettata come difettosa e non genera falso negativo. La RQ2 misura quindi quanto i difetti dormienti si traducano effettivamente in classi rumorose.

9.7.2 Design

Lo studio osserva come cambia la difettosità stimata man mano che l'osservatore avanza nel tempo. Nelle slide questo è rappresentato con i **binocoli**: più ci si sposta avanti nella storia del progetto, più difetti prima invisibili diventano osservabili.

9.7.3 Variabili

- **Variabile indipendente:** **Progress**, cioè il rapporto tra la release osservata e il numero totale di release.
- **Variabile dipendente:** **Missing Rate**, cioè:

$$\frac{FN}{FN + TP}$$

Il Missing Rate rappresenta la quota di classi realmente difettose che non vengono riconosciute come tali. Corrisponde a $1 - Recall$.

9.7.4 Risultati e discussione

Il Missing Rate diminuisce con il progresso temporale, ma resta significativo per molte release. Per la maggior parte dei progetti, il Missing Rate rimane superiore al **50%** se non si rimuove più del **20%** delle release finali.

Nota del Prof

Per ottenere un Missing Rate nullo bisogna in media ignorare una porzione molto ampia delle release finali. Questo mostra che la defectiveness osservata si stabilizza solo molto tempo dopo l'introduzione reale dei difetti.

9.8 RQ3: Impatto sulla valutazione dei classificatori

9.8.1 Rationale

La terza research question analizza se lo snoring alteri la valutazione dei classificatori. Se i dati di test sono rumorosi, si rischia di scegliere come migliore un classificatore che in realtà non lo è.

9.8.2 Design

Sono stati valutati **15 classificatori** tramite **ordered holdout**, mantenendo l'ordine cronologico dei dati: 66% per il training e 33% per il testing.

9.8.3 Metriche

Le metriche considerate includono:

- Precision;
- Recall;
- F1;
- Cohen's Kappa;
- AUC;

- Matthews Correlation Coefficient.

Viene inoltre calcolato il **Relative Bias**, cioè la distanza relativa tra accuratezza misurata su dati rumorosi e accuratezza misurata su dati privi di snoring.

9.8.4 Risultati e discussione

Lo snoring introduce un bias elevato nella valutazione. In particolare, usando dati affetti da snoring, il classificatore realmente migliore viene selezionato correttamente solo in una parte dei casi.

Solo nelle slide (non spiegato a voce)

Le slide riportano che il classificatore migliore viene selezionato correttamente solo nel **45%** dei casi quando la valutazione è eseguita su dati affetti da snoring.

9.9 RQ4: Impatto sull'accuratezza predittiva

9.9.1 Rationale

La quarta research question valuta quanto lo snoring peggiori l'accuratezza predittiva reale dei modelli.

9.9.2 Design

I modelli vengono addestrati su dati affetti da snoring e poi valutati su un test set pulito. In questo modo si misura l'effetto del rumore presente nel training set.

9.9.3 Risultati e discussione

Lo snoring degrada le performance di tutti i classificatori e di tutte le metriche osservate. Le metriche più colpite sono **Recall**, **F1**, **Kappa** e **Matthews**. La **Precision** risulta meno sensibile.

IMPORTANTE PER L'ESAME

Lo snoring danneggia soprattutto la **Recall**, perché introduce falsi negativi nel training set. Il modello impara quindi a classificare come sane molte classi che in realtà sono difettose.

9.10 RQ5: Quando no data è meglio di snoring data

9.10.1 Rationale

La quinta research question valuta se sia preferibile rimuovere alcune release recenti per ridurre il rumore, anche al costo di avere meno dati.

9.10.2 Design

Lo studio confronta scenari in cui vengono rimosse le ultime **1, 2, 3 o 4 release** dal training set.

9.10.3 Risultati e discussione

Rimuovere una release tende a migliorare la qualità della prediction. Tuttavia, rimuovere troppe release peggiora le performance perché riduce eccessivamente la dimensione del dataset.

Nota del Prof

Il risultato mostra un trade-off tra **Garbage In, Garbage Out** e **dimensione del dataset**. Pochi dati puliti possono essere meglio di molti dati rumorosi, ma eliminare troppe release fa perdere informazione utile.

9.11 Conclusioni

Lo snoring è una fonte rilevante di rumore nei dataset di defect prediction. Il fenomeno nasce dal fatto che molti difetti restano dormienti per diverse release e diventano osservabili solo dopo il fix.

I risultati principali sono:

- molti difetti dormono per una porzione significativa della vita del progetto;
- le snoring classes introducono falsi negativi;
- la valutazione dei classificatori può diventare fortemente biasata;
- la Recall è particolarmente danneggiata;
- rimuovere alcune release recenti può migliorare la qualità del training set, ma rimuoverne troppe peggiora il modello.

9.12 Future works

Le possibili estensioni includono:

- tecniche più fine-grained per identificare e rimuovere il rumore;
- combinazione di più strategie di mitigazione;
- uso di etichette probabilistiche invece di etichette binarie rigide;
- replica dello studio nel contesto della **Just-In-Time defect prediction**.

9.13 Da ricordare

IMPORTANTE PER L'ESAME

Lo snoring introduce falsi negativi: classi realmente difettose possono essere etichettate come non difettose perché il fix avverrà solo in futuro.

IMPORTANTE PER L'ESAME

La metrica più penalizzata è la Recall, perché il modello impara a non riconoscere molti veri positivi.

IMPORTANTE PER L'ESAME

Rimuovere alcune release recenti può ridurre il rumore, ma eliminare troppe release riduce eccessivamente la quantità di dati disponibili.

Capitolo 10

Effort-Aware Accuracy Metrics e valutazione dei classificatori

10.1 Contesto generale

Nel campo dell'**ingegneria del software**, i modelli di **defect prediction** sono classificatori di Machine Learning con lo scopo di identificare gli artefatti software, come classi o metodi, che hanno un'alta probabilità di manifestare un difetto.

10.1.1 Defect prediction e testing activity context

Il fine ultimo della **defect prediction** è ridurre il costo delle attività di testing, analisi o *code review*. Prevedendo dove si annidano i bug, il team di sviluppo può dare priorità agli sforzi, concentrandoli su porzioni specifiche di codice, invece di ispezionare l'intero sistema alla cieca.

10.1.2 Perché l'accuratezza classica non basta

Storicamente, i modelli predittivi venivano valutati tramite metriche classiche derivate dal mondo dell'**Information Retrieval**, come **Precision** o **Recall**.

Nota del Prof

Il professore sottolinea che, sebbene le metriche classiche siano utili a livello teorico, risultano inadeguate e poco pratiche nel contesto del testing. Sapere che un classificatore ha una Precision dello 0.90 o una Recall dello 0.89 non fornisce al manager alcuna indicazione pratica sull'impatto reale in termini di *effort* necessario per ispezionare il software. Per questo motivo, le metriche classiche risultano troppo astratte.

10.1.3 Effort-aware accuracy metrics

Per colmare questo divario, sono nate le **Effort-Aware Accuracy Metrics (EAM)**. Si tratta di metriche di accuratezza che tengono esplicitamente in considerazione l'**effort**, cioè il costo o il tempo richiesto per ispezionare il codice suggerito dal classificatore, garantendo così una stima più realistica dei benefici apportati.

10.2 Concetti fondamentali

10.2.1 Definizione di EAM

Le **Effort-Aware Metrics** misurano i benefici forniti da un classificatore in base alla sua capacità di ordinare correttamente le entità candidate a essere difettose, bilanciando i bug trovati con lo sforzo speso per cercarli.

10.2.2 Ranking delle entità difettose

Poiché è impossibile analizzare tutto il software, file e classi vengono inseriti in un **ranking**, cioè una lista ordinata. Il tester ispezionerà il codice partendo dalla cima della lista e scendendo verso il basso finché non esaurisce le risorse a disposizione.

10.2.3 Relazione tra effort e LOC da ispezionare

Nota del Prof

Nell'approccio EAM si assume, come approssimazione, che l'effort necessario per testare un'entità sia linearmente proporzionale alla sua dimensione fisica, cioè al numero di **Linee di Codice (LOC)**. Ispezionare una classe enorme costerà quindi molto più effort rispetto a una classe molto piccola.

10.2.4 Differenza tra ranking per probabilità e ranking effort-aware

L'approccio classico ordina semplicemente le classi in base alla **probabilità** di contenere un bug. Un approccio realmente **effort-aware**, invece, ordina le classi tenendo conto anche di quanto *costa* ispezionarle in termini di LOC.

10.3 PofBx e NPofBx

10.3.1 Definizione di PofBx

La **PofBx** è la EAM non normalizzata più nota. Definisce la percentuale di bug che un tester può identificare ispezionando il top $x\%$ delle linee di codice del sistema, seguendo un ranking basato esclusivamente sulla **probabilità predetta** di difetto.

10.3.2 Definizione di NPofBx

La **NPofBx** è la metrica proposta dagli autori del paper. Rappresenta la versione **normalizzata** della PofBx. Mantiene la stessa logica generale, ma utilizza un ranking differente.

10.3.3 Significato della normalizzazione

Invece di ordinare semplicemente per probabilità predetta, la NPofBx usa un ranking basato sulla **predicted defect density**, cioè una densità predetta dei difetti.

10.3.4 Ranking per predicted probability / size

La densità viene calcolata dividendo la probabilità predetta di un'entità per la sua dimensione:

$$\frac{\text{predicted probability}}{\text{size}}$$

10.3.5 Differenza pratica tra i due approcci

Nota del Prof

Senza normalizzazione, il modello potrebbe suggerire di testare per prima una classe enorme con probabilità del 90% di contenere un bug, esaurendo subito il budget di LOC analizzabili. Con la normalizzazione, il modello capisce che è più conveniente testare per prime diverse classi piccole ma promettenti, trovando molti più bug a parità di LOC lette.

10.4 Esempio introduttivo

Per chiarire l'effetto della normalizzazione, le slide e l'audio presentano un esempio pratico.

10.4.1 Dataset di esempio

Si considera un sistema di **1790 LOC**, diviso in **7 entità**, di cui **3** effettivamente difettose.

10.4.2 Significato di PofB20

Si assume di poter utilizzare il 20% del budget di ispezione. Il 20% di 1790 LOC corrisponde a **358 LOC**. Ordinando le 7 entità per semplice **probabilità predetta**, le prime due entità consumano tutto il budget disponibile. Analizzandole, si trova solo **1** delle **3** entità difettose. Di conseguenza:

$$PofB20 = 33\%$$

10.4.3 Significato di NPofB20

Applicando la normalizzazione, cioè ordinando le entità per Probabilità/Size, le classi piccole e promettenti risalgono la graduatoria. Con lo stesso tetto di 358 LOC, si riescono ad analizzare **3** entità anziché 2, trovando **2** delle **3** entità difettose. Di conseguenza:

$$NPofB20 = 66\%$$

10.4.4 Perché la normalizzazione migliora il numero di difetti trovati

Semplicemente cambiando il criterio di ordinamento del ranking, senza alterare i dati originali né il classificatore, il numero di bug trovati **raddoppia**.

10.5 Aim del lavoro e Research Questions

10.5.1 Problemi nell'uso delle EAM

Il lavoro nasce dall'osservazione che esiste una grave carenza, e talvolta un uso scorretto, delle EAM in letteratura, il che ne mina la validità e la generalizzazione.

10.5.2 Proposta di normalizzazione

L'obiettivo del lavoro è duplice:

1. evidenziare le problematiche storiche nell'uso delle EAM;
2. proporre e valutare la validità della metrica normalizzata **NPofB**, basata sulla **predicted defect density**.

10.5.3 Research Questions

Le quattro domande di ricerca sono:

- **RQ1**: quali EAM vengono usate nei paper di Ingegneria del Software?
- **RQ2**: la normalizzazione migliora effettivamente i valori di PofBs?
- **RQ3**: il ranking dei classificatori cambia se si normalizza la PofB?
- **RQ4**: il ranking dei classificatori cambia al variare della x nelle NPofBx normalizzate?

10.6 RQ1

Per rispondere alla prima domanda, gli autori hanno effettuato uno **Systematic Mapping Study**.

10.6.1 Numero di studi, progetti, EAM e classifier

Sono stati analizzati **152 primary studies** provenienti dai principali journal del settore. Lo studio finale è stato validato su **14 progetti** — 12 open-source e 2 industriali — confrontando **10** diverse soglie di EAM e usando **10 classificatori**.

10.6.2 Risultati principali

I risultati mostrano che:

- la grande maggioranza della letteratura ignora le EAM: **132 studi su 152** usano **0 EAM**, valutando i modelli solo tramite Precision o Recall;
- i pochi studi che usano EAM si limitano quasi sempre a **una sola metrica**, tipicamente **PofB20**, riducendo la generalizzabilità dei risultati;
- sette studi su venti presentavano un **mismatch nei nomi delle metriche**, sintomo di scarsa comprensione o assenza di standardizzazione.

10.7 RQ2

10.7.1 Intuizione di base

La RQ2 indaga se la **NPofB** ottenga performance matematicamente migliori rispetto alla **PofB**.

10.7.2 Variabili indipendente e dipendente

Nota del Prof

Il professore richiama una nozione cruciale di ingegneria degli esperimenti. In questo studio, la **variabile indipendente** è la presenza o assenza della normalizzazione, mentre la **variabile dipendente** è lo score della PofB calcolato con o senza normalizzazione.

10.7.3 PofB10–PofB90 e average

La valutazione è stata eseguita su un intero spettro di soglie, dal **10%** al **90%** a passi di 10, escludendo 0 e 100 perché banali, più una metrica media, **AveragePofB**. In totale vengono considerate **10 PofBs**.

10.7.4 Preprocessing

Prima dell'esperimento, i dati sono stati preprocessati tramite:

1. **Log10 normalization**;
2. **Feature subset selection**;
3. **SMOTE**.

Nota del Prof

La trasformazione in $\log_{10}$ è fondamentale. Se si usano feature disomogenee, per esempio secondi, numero di bug o LOC, passare al logaritmo base 10 rende le distribuzioni più omogenee e aumenta l'accuratezza di base.

10.7.5 Walk-forward

Nota del Prof

Il **walk-forward** è vitale nell'ingegneria del software. Si dividono i dati in release sequenziali: per predire la Release 4 si usa come training set l'unione delle release 1, 2 e 3. Questo impedisce al modello di leggere il futuro e preserva il realismo temporale.

10.7.6 Classifier usati

Solo nelle slide (non spiegato a voce)

Sono stati usati 10 algoritmi ML ben noti: **Decision Table**, **IBk (k-NN)**, **J48**, **KStar**, **Naive Bayes**, **SMO**, **Random Forest**, **Logistic Regression**, **BayesNet** e **Bagging**.

10.7.7 Risultati

La normalizzazione incrementa i valori della PofB in modo statisticamente significativo e di svariati ordini di grandezza.

10.7.8 Relative gain

Il guadagno relativo viene calcolato come:

$$\frac{NPofB - PofB}{PofB}$$

Il **relative gain** cresce fortemente per soglie più basse: per esempio, il guadagno della **PofB10** è circa doppio rispetto a quello della **PofB20**.

10.7.9 Cliff's delta e p-value

IMPORTANTE PER L'ESAME

Il professore insiste molto sulla differenza tra **p-value** ed **effect size**. Il **p-value** indica quanto sia probabile commettere errore nel rigettare l'ipotesi nulla, ma *non* misura la grandezza dell'effetto. Il **Cliff's delta**, invece, misura proprio quanto l'effetto sia grande e importante.

Nota del Prof

Nel caso della normalizzazione, i valori di **Cliff's delta** risultano per lo più classificati come **Large**, cioè maggiori o uguali a 0.43, mostrando che l'effetto non è solo statisticamente significativo, ma anche sostanzialmente rilevante.

10.8 RQ3

10.8.1 Spearman rank correlation

La RQ3 si chiede se, normalizzando la PofB, il classificatore che prima risultava il migliore resti tale oppure se la graduatoria venga stravolta. Per confrontare i ranking si usa il coefficiente di correlazione di **Spearman**.

10.8.2 Confronto ranking con e senza normalizzazione

Il confronto viene fatto tra le classifiche dei classificatori ottenute con la stessa PofB, ma calcolata **con** e **senza** normalizzazione.

10.8.3 Best classifier

L'analisi si concentra anche su un aspetto pratico fondamentale: verificare se il **miglior classificatore** resti lo stesso prima e dopo la normalizzazione.

10.8.4 Risultati e interpretazione pratica

I risultati mostrano una correlazione solo **modesta** nella maggior parte dei casi. In pratica, identificare il miglior classificatore usando la vecchia PofB equivale spesso a scegliere il classificatore sbagliato rispetto alla più realistica NPofB.

Questo implica che molti studi passati basati sulla PofB non normalizzata risultano fuorvianti, perché potrebbero aver promosso come *miglior modello* un algoritmo che, in realtà, non fornisce il massimo beneficio effort-aware al tester.

10.9 RQ4

10.9.1 Confronto tra diverse NPofBx

Una volta stabilito che la normalizzazione è opportuna, la RQ4 si chiede se basti usare una sola metrica, per esempio **NPofB20**, oppure se il comportamento dei classificatori cambi al variare della soglia x .

10.9.2 Ruolo di x da 10 a 90

L'analisi considera soglie che vanno dal **10%** al **90%**, oltre alla metrica media **Average NPofB**.

10.9.3 Average NPofB e confronto dei ranking

Le diverse classifiche vengono confrontate a coppie tramite **Spearman**, valutando anche il comportamento dell'**Average NPofB**.

10.9.4 Risultati e best classifier

I risultati dimostrano che i ranking dei classificatori sono molto lontani dall'essere identici al variare della soglia x . In circa l'**88%** dei casi, il classificatore migliore cambia se si cambia la quantità di codice da ispezionare.

In altre parole, il modello ottimale per ispezionare il **10%** del codice potrebbe non essere più il migliore se l'obiettivo è ispezionarne il **50%**.

10.10 Figure, tabelle e grafici

Solo nelle slide (non spiegato a voce)

Le tabelle e i grafici descritti qui sono presentati nelle slide come supporto visivo dei risultati, anche quando non vengono spiegati in dettaglio a voce.

10.10.1 Esempio PofB20 e NPofB20

Le tabelle iniziali del paper illustrano visivamente l'esempio dei 7 file, mostrando il passaggio da **33%** a **66%** di bug trovati grazie alla normalizzazione.

10.10.2 Tabella delle EAM usate negli studi precedenti

La **Tabella 4.4** mostra che, su **152** studi primari, **132** usano **0 EAM**. Nessun paper in letteratura ha usato **5 o più EAM**.

10.10.3 Tabella dei relative gains

La **Tabella 4.6** mostra il forte guadagno dovuto alla normalizzazione:

- +414% per **PofB10**;
- guadagni progressivamente decrescenti fino a +11% per **PofB90**;
- tutti i confronti hanno **p-value < 0.0001**.

10.10.4 Tabella degli equivalent best classifiers

La **Tabella 4.8** e il boxplot associato mostrano la proporzione di casi in cui il miglior modello resta lo stesso. Per esempio, si passa dal **15%** per **NPofB10** al **29%** per **NPofB90**. Questo dato è importante perché smonta l'idea che testare una sola EAM sia statisticamente e industrialmente corretto.

10.11 Main results e conclusioni

10.11.1 Superiorità delle NPofBs rispetto alle PofBs

Dal punto di vista statistico e dell'ordine di grandezza, la **NPofB** risulta nettamente superiore alla **PofB**. Fornisce valutazioni più realistiche perché allinea le stime matematiche al comportamento effettivo di uno sviluppatore, che nella pratica considera sempre anche il peso delle dimensioni del file.

10.11.2 Cambiamento del best classifier dopo la normalizzazione

L'impatto più forte della normalizzazione è che essa **ribalta il ranking dei classificatori**. Modelli ritenuti ottimi nella letteratura precedente perdono il primato quando si passa alla valutazione normalizzata.

10.11.3 Implicazioni pratiche

Chiunque valuti un classificatore in ingegneria del software dovrebbe:

- calcolare metriche **Effort-Aware normalizzate**, cioè **NPofB**;
- testare il classificatore su **molteplici soglie x** , e non su una sola;
- evitare conclusioni basate esclusivamente su una singola metrica o su una sola soglia.

10.12 ACUME tool

10.12.1 Scopo

L'assenza di metriche EAM in letteratura è spesso dovuta alla mancanza di librerie standard per calcolarle. Gli autori propongono quindi **ACUME** (**ACcUracY MEtrics**), un tool open-source in Python per automatizzare il processo.

10.12.2 Input e output

Il tool agisce alla fine della pipeline. Prende in input un file **CSV** predetto da strumenti di Machine Learning, come Weka o scikit-learn, con quattro colonne essenziali:

- **ID**
- **Size**
- **Predicted Probability**
- **Actual Defectiveness**

In output produce un singolo file CSV contenente:

- le metriche classiche di accuratezza;
- tutte le EAM discusse nel lavoro.

10.12.3 Utilità per i ricercatori

ACUME evita sprechi di tempo, riduce il rischio di mismatch nei nomi delle metriche, aumenta la generalizzazione dei risultati e migliora la riproducibilità degli esperimenti.

In sintesi

Le metriche classiche, come Precision e Recall, risultano troppo astratte nel mondo reale del testing software. Questo studio mostra che pesare il ranking dividendo la probabilità per la grandezza del file, cioè usando **NPofB**, aumenta drasticamente la capacità di ritrovare i bug veri. Il risultato è un cambiamento profondo nelle modalità con cui l'accademia e i professionisti dovrebbero valutare i classificatori: mai più con una sola soglia e mai più senza normalizzazione.

Capitolo 11

Milestone 1: Dataset Creation

11.1 Obiettivo della Milestone 1

La **Milestone 1** richiede la costruzione di un dataset CSV per un progetto software assegnato. Il dataset deve essere usato per attività di **defect prediction**, cioè per predire se una classe in una specifica release sia difettosa oppure no.

L'unità di analisi è la coppia:

classe — release

Ogni riga del CSV rappresenta quindi una classe Java osservata in una determinata release del progetto.

IMPORTANTE PER L'ESAME

La Milestone 1 non consiste solo nell'estrarre metriche dal codice: il punto più delicato è costruire correttamente la colonna **Bugginess**, cioè stabilire se una classe deve essere etichettata come buggy o non buggy in una certa release.

11.2 Assegnazione del progetto

Ogni studente lavora su un progetto determinato tramite la prima lettera del cognome.

Il procedimento è il seguente:

1. si prende la prima lettera del cognome;
2. si converte la lettera nel numero corrispondente dell'alfabeto;
3. si calcola:

$$X = \text{numero} \bmod 6$$

4. si assegna il progetto secondo la seguente mappatura:

- $X = 0$: AVRO;
- $X = 1$: OPENJPA;
- $X = 2$: STORM;
- $X = 3$: ZOOKEEPER;

- $X = 4$: SYNCOPÉ;
- $X = 5$: TAJÓ.

11.3 Struttura del dataset CSV

Il dataset finale deve essere una tabella in formato CSV contenente, per ogni classe e release, le informazioni necessarie alla defect prediction.

Le colonne richieste sono:

- **Name of the project**: nome del progetto;
- **Name of the class**: path o nome della classe Java;
- **Release ID**: identificativo della release;
- **Feature**: circa 20 metriche descrittive della classe o del processo di sviluppo;
- **NSmells**: numero di code smells rilevati;
- **Bugginess**: etichetta finale, con valore **yes** o **no**.

Nota del Prof

Il dataset deve essere piatto, cioè organizzato come una tabella classica: ogni riga è un'istanza, ogni colonna è una feature o una label. Questa struttura è necessaria per poter usare successivamente strumenti di machine learning.

11.4 Selezione delle release

Il workflow prevede di individuare tutte le release del progetto e le relative date. Successivamente bisogna ignorare l'ultimo **66%** delle release.

Di conseguenza, il dataset finale contiene solo il primo **34%** delle release più antiche.

IMPORTANTE PER L'ESAME

Ignorare l'ultimo 66% delle release significa non inserirle come righe nel CSV finale. Tuttavia, i ticket e i commit successivi possono ancora essere necessari per capire se una classe appartenente al primo 34% era già difettosa.

11.5 Snapshot di release

Per ogni release selezionata è necessario trovare l'ultimo commit associato a quella release. A quel punto si effettua il checkout dell'intero codice alla revisione corrispondente.

Questo passaggio serve a costruire un inventario realistico delle classi Java effettivamente presenti nella release.

Nota del Prof

Una classe può essere etichettata come buggy in una release solo se esiste realmente nello snapshot di quella release. Non basta sapere che quella classe sarà toccata da un fix in futuro.

11.6 Classi da considerare

Per ogni release selezionata bisogna individuare le classi Java di produzione presenti nello snapshot.

IMPORTANTE PER L'ESAME

Devono essere escluse le **test classes**. Il dataset deve considerare le classi di produzione, tipicamente sotto percorsi come `src/main/java`, evitando file sotto `src/test/java`.

11.7 Class metrics

Le **class metrics** descrivono la storia e le caratteristiche della classe all'interno della release considerata. Le principali metriche richieste sono:

- **Size (LOC)**: numero di linee di codice;
- **LOC Touched**: somma delle linee aggiunte e cancellate nelle revisioni;
- **NR**: numero di revisioni;
- **Nfix**: numero di fix di difetti;
- **Nauth**: numero di autori;
- **LOC Added**: totale delle linee aggiunte;
- **Max LOC Added**: massimo numero di linee aggiunte in una revisione;
- **Average LOC Added**: media delle linee aggiunte per revisione;
- **Churn**: somma delle linee aggiunte e cancellate;
- **Max Churn**: massimo churn osservato;
- **Average Churn**: churn medio;
- **Change Set Size**: numero di file committati insieme alla classe;
- **Max Change Set**: massimo change set osservato;
- **Average Change Set**: change set medio;
- **Age**: età della classe o della release;
- **Weighted Age**: età pesata rispetto al LOC touched.

Solo nelle slide (non spiegato a voce)

Le slide indicano che alcune metriche possono essere calcolate entro la singola release oppure a partire dalla release 0, cioè considerando tutta la storia disponibile fino alla release corrente.

11.8 Commit metrics

Le **commit metrics** descrivono le caratteristiche dei cambiamenti effettuati nel repository. Esse sono utili perché alcune proprietà dei commit sono correlate alla probabilità di introdurre difetti.

Le metriche principali sono:

- **NS**: numero di sottosistemi modificati;
- **ND**: numero di directory modificate;
- **NF**: numero di file modificati;
- **Entropy**: distribuzione delle modifiche tra i file;
- **LA**: linee di codice aggiunte;
- **LD**: linee di codice cancellate;
- **LT**: linee di codice nel file prima del cambiamento;
- **FIX**: indica se il cambiamento è un defect fix;
- **NDEV**: numero di sviluppatori che hanno modificato i file coinvolti;
- **AGE**: intervallo medio tra l'ultima modifica e quella corrente;
- **NUC**: numero di cambiamenti unici ai file modificati;
- **EXP**: esperienza dello sviluppatore;
- **REXP**: esperienza recente dello sviluppatore;
- **SEXP**: esperienza dello sviluppatore sul sottosistema.

Nota del Prof

Le metriche di processo sono importanti perché non misurano soltanto il codice, ma anche il modo in cui il codice è stato modificato. File toccati spesso, da molti sviluppatori o in commit molto grandi tendono a essere più rischiosi.

11.9 NSmells

La feature **NSmells** rappresenta il numero di code smells rilevati nella classe. Può essere calcolata tramite strumenti di analisi statica come SonarCloud, PMD o strumenti simili.

Nota del Prof

NSmells è una feature del dataset, non la label. Una classe con molti smells non è automaticamente buggy, ma può avere una maggiore probabilità di diventarlo.

11.10 Labeling della bugginess

La colonna **Bugginess** indica se una classe in una specifica release deve essere considerata difettosa.

Il processo parte assumendo che tutte le classi siano inizialmente **no**. Successivamente, per i ticket di difetto validi, alcune coppie classe-release vengono trasformate in **yes**.

I ticket da considerare sono quelli che soddisfano condizioni del tipo:

- tipo uguale a defect o bug;
- stato **Closed** oppure **Resolved**;
- resolution uguale a **Fixed**.

IMPORTANTE PER L'ESAME

Il labeling è il passaggio più critico della Milestone 1: se una classe difettosa viene etichettata come non buggy, il classificatore apprenderà da un esempio sbagliato.

11.11 Uso di SZZ e Proportion

Per identificare le classi buggy è necessario collegare ticket, fix commit e classi modificate.

Una strategia possibile è:

1. individuare i ticket di difetto validi;
2. trovare i commit che correggono quei ticket;
3. identificare le classi Java toccate dai fix commit;
4. stimare le release affette dal difetto;
5. marcare come buggy le coppie classe-release comprese nell'intervallo stimato.

Quando l'Affected Version è disponibile e affidabile, può essere usata per stimare l'inizio del difetto. Quando manca o non è affidabile, si ricorre a **SZZ** o a metodi come **Proportion Total**.

Nota del Prof

L'idea di Proportion è stimare la Injected Version quando non è nota, usando l'andamento medio del ciclo di vita dei difetti osservati nel progetto.

11.12 ComputedAV e intervallo di release affette

Nel progetto è utile distinguere tra:

- **AV originale:** informazione grezza proveniente da Jira;
- **ComputedAV:** insieme di release calcolate come affette dal difetto.

La ComputedAV rappresenta l'intervallo di release in cui il difetto deve essere considerato presente. Operativamente, si può interpretare come un intervallo:

$$[IV, FV)$$

cioè dalla Injected Version inclusa fino alla Fixed Version esclusa.

IMPORTANTE PER L'ESAME

L'AV originale di Jira non deve essere interpretata automaticamente come intervallo continuo. Va validata rispetto alla timeline delle release. La ComputedAV è invece la rappresentazione operativa usata per il labeling.

11.13 Workflow operativo completo

Il workflow della Milestone 1 può essere sintetizzato così:

1. identificare il progetto assegnato;
2. recuperare le release e le rispettive date;
3. selezionare solo il primo 34% delle release;
4. per ogni release selezionata:
 - (a) trovare l'ultimo commit della release;
 - (b) effettuare il checkout del codice;
 - (c) individuare le classi Java di produzione;
 - (d) calcolare le metriche di classe;
 - (e) calcolare le metriche di commit;
 - (f) calcolare NSmells;
 - (g) scrivere una riga nel CSV per ogni classe.
5. recuperare i ticket di difetto validi;
6. collegare ticket e fix commit;
7. identificare le classi toccate dai fix;
8. stimare IV, OV, FV e ComputedAV;
9. assegnare la label **yes/no**;
10. produrre il CSV finale.

11.14 Errori comuni da evitare

- **Scartare i ticket futuri:** anche se il CSV contiene solo il primo 34% delle release, i ticket successivi possono servire per etichettare correttamente quelle release.
- **Confondere AV e ComputedAV:** l'AV di Jira è dato grezzo; la ComputedAV è l'intervallo operativo usato nel progetto.
- **Etichettare classi non presenti:** una classe deve essere marcata buggy solo se esiste nello snapshot della release.
- **Includere classi di test:** il dataset deve riguardare classi di produzione.
- **Usare date incoerenti:** IV, OV, FV, resolution date e fix date devono essere trattate con una semantica chiara.
- **Sovrascrivere informazioni grezze:** i dati originali, come AV da Jira, vanno mantenuti distinti dai dati calcolati.

IMPORTANTE PER L'ESAME

L'errore più grave è costruire il dataset usando solo i ticket presenti entro il primo 34% delle release. Questo fa apparire come non buggy classi che saranno corrette in seguito, reintroducendo falsi negativi nel labeling.

11.15 Da ricordare

IMPORTANTE PER L'ESAME

La riga del dataset rappresenta una coppia classe-release, non una classe in generale.

IMPORTANTE PER L'ESAME

Il CSV finale contiene solo il primo 34% delle release, ma la bugginess deve essere calcolata usando tutti i ticket e i commit disponibili.

IMPORTANTE PER L'ESAME

La label **Bugginess** deve essere coerente con la presenza reale della classe nello snapshot della release.

IMPORTANTE PER L'ESAME

NSmells è una feature, non una label: serve al classificatore per apprendere, ma non determina da sola se una classe è buggy.

Capitolo 12

Balancing

12.1 Problema del class imbalance

Il **class imbalance** si verifica quando i possibili valori della variabile di interesse non sono distribuiti in modo equilibrato dal punto di vista della numerosità. Per esempio, se in un dataset sono presenti il 5% di classi *buggy* e il 95% di classi *non buggy*, il dataset è fortemente sbilanciato.

Nella maggior parte delle applicazioni reali, lo sbilanciamento è una caratteristica naturale del problema. L'evento che si vuole identificare, cioè la classe positiva, è spesso raro.

Solo nelle slide (non spiegato a voce)

Il class imbalance è frequente in applicazioni come **fraud detection**, **intrusion detection**, **risk management**, classificazione di testi e diagnosi o monitoraggio medico.

I classificatori standard tendono a essere dominati dalla classe maggioritaria. Poiché nel training set osservano molte più istanze della maggioranza, imparano a predire soprattutto quella classe. Il risultato è un'alta accuratezza predittiva sulla classe maggioritaria, ma una bassa capacità predittiva sulla classe minoritaria.

Un input bilanciato può aiutare il classificatore perché rende più visibili i pattern della classe minoritaria, mettendo il modello in condizione di riconoscere meglio i positivi.

12.2 Effetto dello sbilanciamento sui classificatori

In presenza di class imbalance, un classificatore può ottenere una **accuracy** apparentemente alta predicendo quasi sempre la classe maggioritaria. Tuttavia, questo comportamento può essere inutile rispetto all'obiettivo reale del problema.

Nota del Prof

Se lo scopo è trovare frodi o diagnosticare una malattia, un modello che predice sempre “sano” o “non frode” può ottenere un'accuracy elevata quando i positivi sono pochi, ma fallisce proprio nel compito più importante: identificare i casi rari.

Nel contesto della **defect prediction**, la classe minoritaria è spesso quella delle classi *buggy*. Il problema non è riconoscere le molte classi sane, ma individuare le poche classi realmente difettose.

Se il training set contiene pochi difetti, il modello tenderà a predire pochi difetti anche nel testing set, riducendo soprattutto la capacità di trovare veri positivi.

12.3 Undersampling

L'**undersampling** è una tecnica di bilanciamento che riduce il numero di istanze della classe maggioritaria, preservando tutte le istanze della classe minoritaria.

L'idea è estrarre un sottoinsieme più piccolo della maggioranza, in modo che la distribuzione tra le classi diventi più equilibrata.

Solo nelle slide (non spiegato a voce)

Nel diagramma delle slide, un'icona a forma di forbice taglia le righe in eccesso dal blocco della *majority class*, riducendolo fino a renderlo confrontabile con il blocco della *minority class*.

Il vantaggio principale dell'undersampling è la semplicità: il dataset diventa più bilanciato e spesso anche più piccolo, riducendo il costo computazionale dell'addestramento.

Lo svantaggio principale è la **perdita di informazione**. Eliminando istanze della classe maggioritaria, si possono rimuovere esempi utili per descrivere correttamente il problema.

Nota del Prof

L'undersampling può peggiorare le prestazioni del classificatore perché fornisce meno dati al modello. Bilanciare il dataset eliminando esempi significa anche rinunciare a una parte della conoscenza disponibile.

12.4 Oversampling

L'**oversampling** è una tecnica di bilanciamento che aumenta il numero di istanze della classe minoritaria.

Nella sua forma più semplice, l'oversampling duplica le istanze minoritarie già presenti, fino a rendere la classe minoritaria numericamente confrontabile con la classe maggioritaria.

Solo nelle slide (non spiegato a voce)

Nel diagramma delle slide, una lente di ingrandimento ispeziona il piccolo blocco della *minority class* e lo espande, creando copie fino a raggiungere una dimensione simile a quella della *majority class*.

Il vantaggio principale dell'oversampling è che non elimina dati storici: tutte le istanze originali vengono mantenute.

Lo svantaggio è il rischio di **overfitting**. Il classificatore può attribuire troppa importanza a istanze duplicate, scambiando ripetizioni artificiali per informazione reale.

Nota del Prof

Duplicare dati non significa aggiungere nuova conoscenza. Se un evento raro viene copiato molte volte, il modello può credere che quel pattern sia più rappresentativo di quanto non sia realmente.

12.5 SMOTE

SMOTE significa **Synthetic Minority Oversampling Technique**. A differenza dell'oversampling semplice, SMOTE non si limita a duplicare istanze esistenti, ma genera nuove istanze sintetiche della classe minoritaria.

La generazione avviene usando le similarità nello **spazio delle feature** tra istanze minoritarie già presenti. In pratica, SMOTE crea nuovi punti intermedi tra esempi minoritari simili.

Solo nelle slide (non spiegato a voce)

Nel diagramma delle slide, i *majority samples* sono rappresentati come quadrati tratteggiati, i *minority samples* come pallini neri e i *synthetic samples* come pallini rossi. SMOTE genera esempi sintetici posizionandoli lungo segmenti che collegano istanze minoritarie simili.

Il vantaggio di SMOTE è che introduce maggiore variabilità rispetto alla semplice duplicazione. Tuttavia, esiste il rischio che le istanze sintetiche non siano realistiche.

Nota del Prof

Il professore sconsiglia l'uso disinvolto di SMOTE. Creare istanze sintetiche significa affidarsi a un algoritmo esterno per inventare nuovi esempi, inserendo dati artificiali nel training set di un altro predittore. Questo può ridurre il realismo dell'esperimento.

12.6 Confronto tra undersampling, oversampling e SMOTE

Le tre tecniche modificano il dataset in modi diversi:

- **undersampling**: riduce la classe maggioritaria;
- **oversampling**: duplica la classe minoritaria;
- **SMOTE**: genera nuove istanze sintetiche della classe minoritaria.

L'undersampling può essere utile quando il dataset è molto grande e si vuole ridurre il costo computazionale. L'oversampling può essere utile quando non si vuole perdere informazione storica. SMOTE prova a superare la duplicazione semplice, ma introduce dati artificiali.

I principali rischi sono:

- **perdita di informazione**, tipica dell'undersampling;
- **overfitting**, tipico dell'oversampling semplice;
- **istanze sintetiche non realistiche**, tipiche di SMOTE.

12.7 Lab

Il laboratorio richiede di confrontare l'accuratezza dei modelli di machine learning con e senza applicazione dell'oversampling.

Il workflow richiesto è:

1. prendere un dataset;
2. usare tre classificatori:
 - **RandomForest**;
 - **NaiveBayes**;
 - **IBk**;
3. applicare una validazione tramite **66/33 ordered split**;
4. confrontare i risultati con e senza oversampling.

Nota del Prof

In un progetto software reale, lo split casuale può essere poco realistico. Se si vuole predire una release futura, il modello deve essere addestrato sulle release precedenti. Mischiare release passate e future può introdurre conoscenza futura nel training, falsando l'esperimento.

12.8 Weka API

12.8.1 Undersampling

Solo nelle slide (non spiegato a voce)

In Weka, l'undersampling può essere eseguito con il filtro:

```
weka.filters.supervised.instance.SpreadSubsample -M 1.0
```

12.8.2 Oversampling

Solo nelle slide (non spiegato a voce)

In Weka, l'oversampling può essere eseguito con il filtro:

```
weka.filters.supervised.instance.Resample
```

Per l'oversampling, le slide indicano i seguenti parametri:

- `noReplacement=false`, per permettere la duplicazione;
- `biasToUniformClass=1.0`;
- `sampleSizePercent=Y`.

Il parametro Y si calcola come:

$$Y = 100 \cdot \frac{majority - minority}{minority}$$

Solo nelle slide (non spiegato a voce)

Per il dataset diabetes, le slide riportano l'esempio:

```
weka.filters.supervised.instance.Resample -B 1.0 -Z 130.3
```

12.8.3 SMOTE

Solo nelle slide (non spiegato a voce)

In Weka, SMOTE può richiedere l'installazione di un package aggiuntivo tramite il gestore dei pacchetti di Weka.

12.9 Collegamento con il progetto

Il balancing è rilevante nei dataset di defect prediction perché le classi *buggy* sono spesso una minoranza rispetto alle classi *non buggy*.

Senza balancing, un classificatore può imparare a predire quasi sempre **no**, ottenendo una buona accuracy apparente ma fallendo nel riconoscimento delle classi difettose.

Valutare solo l'accuracy è quindi fuorviante. In un dataset con il 95% di classi sane, un classificatore che predice sempre **no** ottiene il 95% di accuracy, ma non individua alcun difetto.

Nota del Prof

Dopo il balancing ci si può aspettare un aumento della **Recall**, perché il modello riconosce più positivi reali. Tuttavia, può diminuire la **Precision**, perché aumentando le predizioni positive possono aumentare anche i falsi allarmi.

Per valutare correttamente i modelli, oltre all'accuracy, è opportuno osservare metriche come:

- **Precision**;
- **Recall**;
- **F1**;
- **AUC**;
- **Kappa di Cohen**.

12.10 Da ricordare

IMPORTANTE PER L'ESAME

Il class imbalance è centrale nella defect prediction perché le classi buggy sono spesso rare. Un modello non bilanciato può sembrare accurato, ma ignorare proprio i difetti.

IMPORTANTE PER L'ESAME

L'undersampling riduce la classe maggioritaria ma può perdere informazione. L'oversampling mantiene i dati ma può causare overfitting. SMOTE crea dati sintetici, ma questi possono non essere realistici.

IMPORTANTE PER L'ESAME

Tutte le attività di bilanciamento devono essere applicate esclusivamente al **training set**. Non si deve mai bilanciare il testing set. Bilanciare l'intero dataset prima dello split significa falsare la valutazione, perché il classificatore può essere testato su istanze duplicate o artificiali collegate a quelle viste in addestramento.

IMPORTANTE PER L'ESAME

In presenza di class imbalance, l'accuracy da sola non basta. È necessario osservare metriche come Recall, Precision, F1, AUC e Kappa.

Capitolo 13

Weka GUI e Feature Selection

13.1 Introduzione a Weka

Weka è un toolkit per il **machine learning** e il **data mining** scritto in Java e distribuito con licenza GNU. Viene usato per ricerca, didattica e applicazioni pratiche, ed è collegato al libro *Data Mining* di Witten e Frank.

Le componenti principali di Weka sono:

- **Explorer**: permette di esplorare visivamente i dati, applicare filtri e usare algoritmi di classificazione;
- **Experimenter**: consente di confrontare più algoritmi su uno o più dataset, anche con test statistici;
- **Knowledge Flow**: permette di progettare graficamente pipeline di machine learning;
- **Simple CLI**: interfaccia da riga di comando per eseguire direttamente classi Java di Weka.

Nota del Prof

Nel corso si usano soprattutto **Explorer** ed **Experimenter**. Explorer è utile per prendere confidenza con dataset, distribuzioni, filtri e classificatori; Experimenter è più adatto per confrontare più modelli in modo sistematico e ottenere risultati statisticamente confrontabili.

13.2 Formato dati in Weka

Weka lavora principalmente con file **flat**, cioè dataset organizzati come tabelle relazionali singole.

Solo nelle slide (non spiegato a voce)

I formati supportati includono **ARFF**, **CSV**, **C4.5** e **binary**.

Il formato proprietario di Weka è **ARFF**, che si basa su tre parti principali:

- **@relation**: nome del dataset;
- **@attribute**: definizione degli attributi, cioè nome e tipo di ogni colonna;
- **@data**: valori delle singole istanze, separati da virgola.

Weka distingue tra attributi **numerici** e attributi **nominali**. Per impostazione predefinita, l'ultimo attributo viene considerato la **classe target** da predire.

Nota del Prof

Nel progetto è consigliabile importare i CSV e salvarli subito in formato ARFF. Il CSV non specifica esplicitamente i tipi delle colonne, quindi Weka potrebbe interpretare alcuni attributi in modo errato. Inoltre, Weka non gestisce direttamente le scale ordinali, come *low*, *medium*, *high*: queste vanno trasformate con attenzione, ad esempio tramite codifica binaria o numerica.

13.3 Explorer: preprocessing e classificazione

Nel tab **Preprocess** dell'Explorer è possibile importare i dati tramite il pulsante *Open file*. Dopo l'importazione, Weka permette di visualizzare gli attributi, le distribuzioni, il numero di valori distinti, i valori mancanti e alcune statistiche descrittive.

I filtri di preprocessing permettono di trasformare il dataset prima dell'addestramento.

Solo nelle slide (non spiegato a voce)

Tra i filtri disponibili nelle slide sono citati **discretization**, **normalization**, **resampling** e **attribute selection**.

Selezionando un attributo, Weka mostra informazioni come minimo, massimo, media, deviazione standard e un istogramma colorato rispetto alla classe target.

Nel tab **Classify**, Weka permette di scegliere diversi classificatori.

Solo nelle slide (non spiegato a voce)

Tra i classificatori citati nelle slide compaiono alberi decisionali come **J48** e **RandomForest**, classificatori instance-based come **IBk**, SVM, logistic regression e Bayes nets, tra cui **NaiveBayes**.

Weka include anche **meta-classifiers**, cioè classificatori costruiti sopra altri classificatori.

Solo nelle slide (non spiegato a voce)

Tra i meta-classifiers sono citati **bagging**, **boosting** e **stacking**.

Cliccando sul nome del classificatore è possibile aprire l'*object editor* e configurare i parametri. Le principali opzioni di test sono:

- **Use training set**;

- **Supplied test set**;
- **Cross-validation**, ad esempio 10-fold;
- **Percentage split**.

13.4 Experimenter

L'**Experimenter** permette di confrontare diversi learning schemes in modo più sistematico rispetto all'**Explorer**. È utilizzabile sia per problemi di classificazione sia per problemi di regressione.

Nota del Prof

L'**Experimenter** è particolarmente utile quando bisogna confrontare più classificatori, più dataset o più configurazioni. I risultati possono essere esportati, ad esempio in formato CSV, per analisi successive.

Solo nelle slide (non spiegato a voce)

Le slide indicano che l'**Experimenter** supporta **cross-validation**, **learning curve** e **hold-out**. Inoltre può iterare su diversi parametri e include strumenti di **significance testing**.

Il significance testing permette di capire se la differenza tra due classificatori è statisticamente significativa, invece di limitarsi a confrontare valori medi di accuratezza.

13.5 Feature Selection: obiettivi

La **feature selection**, o selezione degli attributi, serve a scegliere un sottoinsieme di feature informative rispetto al task predittivo.

Gli obiettivi principali sono:

- ridurre il costo di learning, diminuendo il numero di attributi;
- migliorare le performance rispetto all'uso del *full attribute set*;
- ridurre il costo di misurazione delle feature.

IMPORTANTE PER L'ESAME

Nel contesto della Software Engineering, il costo più importante non è sempre il tempo di addestramento del modello, ma il costo di misurazione. Estrarre decine o centinaia di metriche per ogni classe può richiedere molto effort. Ridurre il numero di feature significa ridurre anche il costo di raccolta dei dati.

Nei dataset di defect prediction è frequente avere metriche ridondanti o sovrapposte. Per esempio, LOC, numero di metodi e numero di attributi possono misurare indirettamente la dimensione della classe. La feature selection permette di mantenere solo le feature più utili.

13.6 Filter approach

Il **filter approach** valuta gli attributi partendo dai dati, senza considerare il classificatore che verrà poi usato.

I filtri assegnano alle feature un **merit score**, cioè un punteggio che misura quanto una feature sia utile per separare le classi o per descrivere la variabile target.

La valutazione può avvenire in due modi:

- valutando ogni feature singolarmente;
- valutando sottoinsiemi di feature.

Valutare le feature singolarmente è veloce, ma può essere sub-ottimale perché ignora le relazioni tra attributi. Valutare i subset è più potente, ma introduce un problema combinatorio: il numero di possibili sottoinsiemi cresce in modo esponenziale.

Nota del Prof

I filtri sono molto veloci e utili quando il numero di attributi è grande. Il limite è che il punteggio prodotto, ad esempio un valore di Info Gain, non sempre indica chiaramente dove fissare la soglia per eliminare le feature.

13.7 Info Gain e Spearman

13.7.1 Information Gain

L'**Information Gain** misura quanta informazione una feature fornisce sulla classe target. Più precisamente, quantifica la riduzione dell'incertezza, misurata tramite entropia, quando si conosce il valore di un attributo.

Un valore alto di Information Gain indica che la feature è utile per separare le istanze in classi distinte.

Nota del Prof

Una feature con alto Information Gain aiuta il classificatore perché riduce l'incertezza su quale classe assegnare a un'istanza.

13.7.2 Spearman correlation

La **Spearman correlation**, o coefficiente rho di Spearman, è una misura non parametrica della forza e della direzione dell'associazione tra due variabili ordinate.

Solo nelle slide (non spiegato a voce)

A differenza di Pearson, che misura relazioni lineari sui valori grezzi, Spearman valuta relazioni monotone sui ranghi. Il coefficiente varia da -1 a $+1$.

Una relazione monotona esiste quando una variabile tende ad aumentare al crescere dell'altra, oppure tende a diminuire al crescere dell'altra, anche se non necessariamente a ritmo costante.

Nota del Prof

Metriche come Spearman sono interpretabili, ma non risolvono completamente il problema della ridondanza. Due feature possono essere entrambe molto correlate con la classe target, ma misurare quasi la stessa informazione.

13.8 Wrapper approach

Il **wrapper approach** seleziona le feature usando il classificatore come una *black box*. A differenza dei filtri, il wrapper dipende dal classificatore specifico.

Il processo generale è:

1. scegliere un subset di feature;
2. creare training e test set basati su quel subset;
3. addestrare il classificatore sul training set;
4. valutare l'accuratezza su un validation set;
5. ripetere il processo per più subset e scegliere quello con il miglior risultato.

Il vantaggio è che le feature vengono ottimizzate per uno specifico classificatore. Lo svantaggio è il costo computazionale elevato, perché il modello deve essere addestrato e testato molte volte.

Nota del Prof

I wrapper sono più lenti dei filtri, ma possono produrre feature subset più adatti a un classificatore specifico.

13.9 Search strategies

Poiché il numero di possibili subset di feature è esponenziale, nei wrapper si usano strategie di ricerca.

- **Exhaustive search:** prova tutte le combinazioni possibili. È completa, ma spesso impraticabile;
- **Forward search:** parte da un insieme vuoto e aggiunge progressivamente la feature che migliora di più il risultato;
- **Backward search:** parte dall'insieme completo e rimuove progressivamente la feature la cui eliminazione danneggia meno l'accuratezza;
- **Greedy search:** prende decisioni locali cercando un buon compromesso tra accuratezza e costo computazionale.

Solo nelle slide (non spiegato a voce)

Le slide indicano che la forward search e la backward search hanno costo $O(n^2 \cdot \text{learning/testing time})$ e che esistono anche altre euristiche.

IMPORTANTE PER L'ESAME

Se si ha molta fiducia nel set di feature iniziale, può convenire usare **Backward Search**, perché parte da tutte le feature e ne elimina poche. Se invece si sospetta che molte feature siano inutili o ridondanti, può convenire usare **Forward Search**, perché costruisce un subset più ristretto partendo da zero.

13.10 Train, validation e test

È fondamentale distinguere tra:

- **training set**: usato per addestrare il modello;
- **validation set**: usato per tuning, scelta delle feature e scelta del modello;
- **test set**: usato solo per la valutazione finale.

IMPORTANTE PER L'ESAME

Il test set non deve essere usato per scegliere feature o parametri. Se si usa il test set durante la selezione, si introduce data leakage e la valutazione finale non è più realistica.

Il validation set serve a prendere decisioni sul modello senza contaminare il test set. Solo alla fine il modello selezionato viene valutato sul test set.

13.11 Feature Selection in Weka

In Weka, la selezione degli attributi può essere eseguita tramite il pannello **Select attributes**. I metodi di attribute selection sono composti da due parti:

- **Search Method**: metodo con cui si esplora lo spazio dei subset;
- **Attribute Evaluator**: criterio con cui si valuta la qualità delle feature o dei subset.

Solo nelle slide (non spiegato a voce)

Tra i search method citati nelle slide compaiono **best-first**, **forward selection**, **random**, **exhaustive**, **genetic algorithm** e **ranking**.

Solo nelle slide (non spiegato a voce)

Tra gli evaluation method citati nelle slide compaiono metodi **correlation-based**, **wrapper**, **information gain** e **chi-squared**.

Nota del Prof

Weka è flessibile perché permette di combinare quasi arbitrariamente search method ed evaluator.

13.12 Lab e collegamento con il progetto

Il laboratorio richiede di confrontare l'accuratezza con e senza feature selection.

Il workflow richiesto è:

1. prendere un dataset;
2. usare tre classificatori:
 - **RandomForest**;
 - **NaiveBayes**;
 - **IBk**;
3. eseguire una **10-fold cross validation**;
4. confrontare i risultati con e senza feature selection;
5. discutere se la valutazione è fair;
6. valutare se usare API o GUI.

IMPORTANTE PER L'ESAME

Fare feature selection sull'intero dataset prima della cross-validation non è fair. Significa permettere alla selezione delle feature di vedere anche le fold che dovrebbero essere usate come test. Questo produce data leakage.

Nota del Prof

In Weka, per evitare data leakage, è preferibile usare il meta-classificatore **AttributeSelectedClassifier**. In questo modo la feature selection viene eseguita separatamente dentro ogni fold di training, senza usare la fold di test.

Nota del Prof

La GUI è utile per capire il dataset, osservare le distribuzioni e sperimentare rapidamente. Le API o la CLI sono invece più adatte al progetto finale, perché permettono di automatizzare esperimenti ripetibili.

Nota del Prof

Se si usano sia feature selection sia balancing, è opportuno prestare attenzione all'ordine delle operazioni. La feature selection dovrebbe essere valutata senza contaminare il test set; anche il balancing deve essere applicato solo sul training set.

13.13 Da ricordare

IMPORTANTE PER L'ESAME

In Software Engineering, la feature selection è importante soprattutto perché riduce il costo di misurazione delle metriche, non solo il tempo di training del modello.

IMPORTANTE PER L'ESAME

I filtri, come Info Gain e Spearman, sono veloci e indipendenti dal classificatore. I wrapper sono più lenti ma ottimizzano le feature per uno specifico classificatore.

IMPORTANTE PER L'ESAME

Il test set non deve mai essere usato per scegliere feature, parametri o modelli. Qualsiasi forma di selezione deve avvenire usando solo training e validation set.

IMPORTANTE PER L'ESAME

In Weka, `AttributeSelectedClassifier` è utile perché consente di eseguire feature selection in modo corretto dentro la cross-validation, evitando data leakage.

IMPORTANTE PER L'ESAME

La GUI serve per comprendere e ispezionare il problema; API e CLI servono per automatizzare esperimenti ripetibili e scalabili.

Capitolo 14

Milestone 2: Classifiers Accuracy

14.1 Obiettivo della Milestone 2

La **Milestone 2** ha come obiettivo principale il confronto dell'accuratezza di tre classificatori di Machine Learning applicati al dataset costruito nella Milestone 1.

L'input della Milestone 2 è quindi il file CSV prodotto nella Milestone 1, contenente le metriche delle classi e la relativa etichetta di **bugginess**.

Le metriche da confrontare non si limitano alla semplice accuracy, ma includono:

- **Precision**;
- **Recall**;
- **AUC**;
- **Kappa**;
- **NPofB20**.

IMPORTANTE PER L'ESAME

La Milestone 2 non richiede solo di eseguire tre classificatori, ma di confrontarli criticamente usando più metriche. Il miglior classificatore può cambiare a seconda della metrica considerata.

14.2 Classificatori da confrontare

Solo nelle slide (non spiegato a voce)

I tre classificatori richiesti per l'esperimento sono **RandomForest**, **NaiveBayes** e **IBk**.

14.2.1 RandomForest

RandomForest è un classificatore basato su un insieme di alberi decisionali. Ogni albero produce una predizione e il modello finale combina i risultati. In genere è robusto e adatto a dataset complessi.

14.2.2 NaiveBayes

NaiveBayes è un classificatore probabilistico basato sul teorema di Bayes. Assume, in modo semplificato, che le feature siano indipendenti tra loro.

Nota del Prof

NaiveBayes è un classificatore molto veloce in Weka. Questa caratteristica può renderlo utile come baseline o come modello semplice da confrontare con algoritmi più complessi.

14.2.3 IBk

IBk è l'implementazione Weka del metodo *k-Nearest Neighbours*. È un classificatore *instance-based*: una nuova istanza viene classificata in base alle classi delle k istanze più simili presenti nel training set.

14.3 Validazione sperimentale

La tecnica richiesta è la **10 times 10-fold cross-validation**.

Nella **10-fold cross-validation** semplice, il dataset viene diviso in 10 parti. A turno, 9 parti vengono usate per il training e 1 per il testing, fino a usare ciascuna fold come test set una volta.

Nella **10 times 10-fold cross-validation**, l'intero processo viene ripetuto 10 volte con partizioni differenti, ottenendo complessivamente 100 run.

Ripetere la cross-validation serve a ridurre l'effetto della casualità nella suddivisione delle fold e a ottenere una stima più stabile delle performance.

IMPORTANTE PER L'ESAME

La 10 times 10-fold cross-validation è richiesta dalla Milestone 2. Tuttavia, nella Software Engineering è utile ragionare anche su split temporali, come ordered hold-out o walk-forward, perché mischiare release passate e future può produrre una stima ottimistica dell'accuratezza.

14.4 Feature Selection

La Milestone 2 richiede l'uso di filtri come tecnica di **feature selection**. La feature selection permette di selezionare solo le metriche più utili, eliminando attributi irrilevanti o ridondanti.

I principali vantaggi sono:

- ridurre il rumore nel dataset;
- migliorare, in alcuni casi, le performance del modello;
- ridurre il costo di estrazione e misurazione delle metriche;
- semplificare l'interpretazione del modello.

Nota del Prof

Se dopo la feature selection l'accuratezza migliora, significa che alcune feature generavano confusione nel modello. Se invece l'accuratezza diminuisce leggermente, si può comunque ottenere un vantaggio pratico: usare meno metriche e ridurre il costo di raccolta dati.

IMPORTANTE PER L'ESAME

La feature selection non deve essere applicata sull'intero dataset prima della cross-validation. Se il filtro vede anche le fold di test, si introduce **data leakage** e la valutazione diventa falsata.

In Weka, una soluzione corretta è usare il meta-classificatore:

`AttributeSelectedClassifier`

In questo modo la feature selection viene applicata separatamente sulle fold di training, senza usare informazioni provenienti dalla fold di test.

14.5 Balancing

Nei dataset di defect prediction la classe **buggy** è spesso minoritaria. Questo sbilanciamento può spingere il classificatore a predire quasi sempre la classe maggioritaria, cioè non **buggy**.

Per mitigare il problema si possono usare tecniche di **balancing**, come:

- **undersampling**: riduzione della classe maggioritaria;
- **oversampling**: aumento della classe minoritaria;
- **SMOTE**: generazione di istanze sintetiche della classe minoritaria.

IMPORTANTE PER L'ESAME

Il balancing deve essere applicato solo al **training set**, mai al test set. Bilanciare il test set significa alterare artificialmente la distribuzione reale dei dati su cui si valuta il modello.

In Weka, il balancing può essere gestito tramite il meta-classificatore:

`FilteredClassifier`

IMPORTANTE PER L'ESAME

Se si usano sia feature selection sia balancing, bisogna evitare che uno dei due passaggi contaminino il test set. Le operazioni devono essere incapsulate nei meta-classificatori, in modo che vengano applicate solo alle fold di training durante la cross-validation.

Nota del Prof

Quando si combinano feature selection e balancing, è importante ragionare sull'ordine delle operazioni. Il balancing altera artificialmente le istanze, quindi può influenzare la valutazione statistica delle feature se applicato nel momento sbagliato.

14.6 Metriche di valutazione

14.6.1 Precision

La **Precision** misura quanti degli elementi predetti come buggy sono effettivamente buggy:

$$Precision = \frac{TP}{TP + FP}$$

Una Precision alta indica pochi falsi positivi.

14.6.2 Recall

La **Recall** misura quanti degli elementi realmente buggy sono stati trovati dal classificatore:

$$Recall = \frac{TP}{TP + FN}$$

Una Recall alta indica pochi falsi negativi.

14.6.3 AUC

L'**AUC**, cioè Area Under the ROC Curve, valuta la capacità del classificatore di distinguere tra classi positive e negative al variare della soglia decisionale.

14.6.4 Kappa

Il **Kappa di Cohen** confronta le prestazioni del classificatore con quelle ottenibili per caso. Un valore maggiore di zero indica che il modello sta facendo meglio di una classificazione casuale o banale.

Nota del Prof

Il classificatore ZeroR predice sempre la classe maggioritaria. In dataset sbilanciati può ottenere un'accuracy alta, ma un Kappa pari a zero, perché non sta realmente imparando un pattern predittivo.

14.6.5 NPofB20

Solo nelle slide (non spiegato a voce)

NPofB20 è una metrica effort-aware normalizzata. Valuta quanti difetti si riescono a trovare ispezionando il 20% delle LOC del sistema.

La logica è ordinare le classi in base a una priorità di ispezione, tipicamente legata alla probabilità predetta di difettosità normalizzata rispetto alla dimensione della classe.

IMPORTANTE PER L'ESAME

L'accuracy da sola non basta nei dataset sbilanciati. Un modello che predice sempre **non buggy** può sembrare accurato, ma non trovare nessuna classe difettosa. Per questo sono fondamentali metriche come Recall, Kappa e NPofB20.

14.7 Domande da rispondere nella Milestone 2

La Milestone 2 richiede di rispondere a domande sperimentali come:

- quale classificatore è più accurato degli altri?
- il miglior classificatore cambia in base al dataset?
- il miglior classificatore cambia in base al numero di release considerate?
- il miglior classificatore cambia in base alla metrica?
- quale classificatore è migliore per una determinata metrica?

Non esiste necessariamente un classificatore migliore in assoluto. Un modello può avere alta Recall ma bassa Precision, oppure buona AUC ma Kappa modesto.

IMPORTANTE PER L'ESAME

Nel report è importante discutere i trade-off. Il docente non cerca solo il valore numerico migliore, ma la capacità di giustificare le scelte sperimentali e interpretare i risultati.

14.8 Weka e API

14.8.1 Uso della GUI

La GUI di Weka, in particolare Explorer ed Experimenter, è utile per comprendere il workflow, testare rapidamente i classificatori e confrontare configurazioni diverse.

L'Experimenter permette di lanciare esperimenti ripetuti, come la 10 times 10-fold cross-validation, e salvare i risultati in una tabella esportabile.

Nota del Prof

Dal CSV prodotto dall'Experimenter può essere utile costruire una colonna descrittiva del modello, combinando classificatore e opzioni, ad esempio `RandomForest_FS_Balanced`.

14.8.2 Limite della GUI per NPofB20

La GUI di Weka non calcola nativamente la **NPofB20**. Per calcolarla servono informazioni a livello di singola istanza, come:

- ID dell'istanza;
- LOC o dimensione della classe;
- classe reale;
- probabilità predetta;
- ordinamento delle classi secondo la priorità effort-aware.

Nota del Prof

Le API Java di Weka o uno script esterno sono utili per stampare le predizioni istanza per istanza e calcolare automaticamente NPofB20.

14.9 Collegamento con il progetto

L'input della Milestone 2 è il CSV finale prodotto nella Milestone 1. L'output è una tabella di confronto tra classificatori e configurazioni sperimentali.

Per ciascuno dei tre classificatori si possono confrontare diverse varianti:

- modello base;
- modello con feature selection;
- modello con balancing;
- modello con feature selection e balancing.

Questo produce una tabella comparativa su più metriche, come Precision, Recall, AUC, Kappa e NPofB20.

IMPORTANTE PER L'ESAME

L'obiettivo finale della Milestone 2 è identificare e giustificare un **best classifier**, cioè la combinazione di algoritmo e preprocessing più adatta al proprio dataset. Questo modello sarà poi usato nella Milestone 3.

14.10 Da ricordare

IMPORTANTE PER L'ESAME

Feature selection e balancing devono essere applicati senza contaminare il test set. In Weka è opportuno usare meta-classificatori come `AttributeSelectedClassifier` e `FilteredClassifier`.

IMPORTANTE PER L'ESAME

Il balancing va applicato solo al training set. Bilanciare il test set significa falsare la valutazione.

IMPORTANTE PER L'ESAME

La 10 times 10-fold cross-validation è richiesta dalla Milestone 2, ma bisogna essere consapevoli che nei dati software l'ordine temporale delle release ha significato.

IMPORTANTE PER L'ESAME

L'accuracy non è sufficiente per valutare modelli su dataset sbilanciati. Bisogna considerare Precision, Recall, AUC, Kappa e NPofB20.

IMPORTANTE PER L'ESAME

Il miglior classificatore può cambiare in base alla metrica. Per questo il risultato deve essere discusso, non solo riportato numericamente.

Capitolo 15

What If I Had No Smells?

15.1 Introduzione ai code smells

15.1.1 Definizione ed esempi

I **code smells** sono artefatti del codice che rappresentano sintomi di scelte di progettazione o implementazione non ottimali. Non coincidono necessariamente con un difetto osservabile, ma segnalano la presenza di strutture che possono rendere il software più difficile da comprendere, modificare o mantenere.

Tra gli esempi riportati nel materiale compaiono:

- **God classes**, cioè classi troppo grandi e sovraccariche di responsabilità;
- **code clones**, cioè duplicazioni di codice;
- **low comment frequency**, cioè una frequenza troppo bassa di commenti;
- **non-intuitive variable naming**, cioè nomi di variabili poco chiari o poco intuitivi.

15.1.2 Legame con il technical debt

I **code smells** contribuiscono all'accumulo di **technical debt**, cioè codice non pienamente buono o non pienamente pulito che viene comunque rilasciato nel prodotto software. Questo debito tecnico non implica necessariamente un malfunzionamento immediato, ma può ridurre progressivamente la qualità del prodotto e rendere più costose le attività future di evoluzione e manutenzione.

15.1.3 Analisi storica e analisi controfattuale

Gran parte della letteratura tradizionale ha studiato il problema in termini di **analisi storica**: si osservano i repository e si cerca di capire se gli smells siano correlati alla qualità del prodotto o al numero di difetti.

Questo studio propone invece una **analisi controfattuale**. La domanda non è più soltanto *che cosa è successo*, ma *che cosa sarebbe successo se gli smells fossero stati evitati*. Il passaggio concettuale è quindi da una logica descrittiva a una logica ipotetica e decisionale.

15.2 Obiettivo del lavoro

15.2.1 Domanda centrale del paper

La domanda centrale del lavoro è la seguente: **il numero di file difettosi diminuisce se i code smells vengono evitati, mantenendo inalterate le altre caratteristiche di processo e di prodotto?**

15.2.2 Significato della stima

L'obiettivo è definire un metodo per **stimare il numero di defective files** in uno scenario ipotetico in cui gli smells siano assenti. Non si tratta quindi di misurare direttamente un intervento reale di refactoring, ma di costruire uno scenario sintetico in cui la variabile relativa agli smells venga modificata per valutare quale impatto avrebbe avuto sul numero di file difettosi.

15.2.3 Interesse pratico e di ricerca

Dal punto di vista della ricerca, questo problema è interessante perché gli esperimenti controllati sugli smells sono costosi, difficili da scalare e poco adatti a scenari multivariati. Dal punto di vista industriale, invece, i manager hanno bisogno di strumenti che supportino decisioni pratiche su qualità, costi ed effort, senza richiedere necessariamente esperimenti complessi o interventi invasivi sul codice.

15.3 What-if analysis method

15.3.1 Significato di what-if scenario

La **what-if analysis** è una tecnica che costruisce scenari ipotetici modificando il valore di alcune variabili per osservare come cambierebbero i risultati finali. Nel caso di questo studio, lo scenario ipotetico è quello di un software in cui i file non presentino code smells.

15.3.2 Azzerare gli smells mantenendo invariate le altre caratteristiche

L'idea metodologica consiste nel modificare i dati storici in modo da porre a zero il numero di smells, mantenendo però invariate le altre caratteristiche del file e del processo di sviluppo, come dimensione, churn, numero di revisioni, autori e altre change metrics.

Nota del Prof

È importante capire perché la feature `NSmells` sia stata scelta come variabile da manipolare. Non tutte le feature sono realmente *actionable*. Se un modello dicesse che i difetti aumentano con la dimensione del codice, non potremmo semplicemente ridurre il numero di righe eliminando funzionalità utili. Invece, la presenza di code smells può essere controllata attivamente, per esempio tramite refactoring o quality gates, senza modificare i requisiti funzionali del sistema.

15.3.3 Uso di modelli appresi su dati reali e applicati a dati sintetici

Il metodo prevede di addestrare modelli di classificazione su dati reali e poi applicarli a dati sintetici ottenuti azzerando la variabile relativa agli smells. In questo modo si cerca di stimare la difettosità attesa in uno scenario in cui il codice, a parità di altre condizioni, non presenti smells.

15.4 Contesto industriale

15.4.1 Progetti e tipi di smell analizzati

Lo studio è stato applicato su dati provenienti da **cinque progetti industriali** della durata di circa dieci anni, appartenenti all'azienda **Keymind**. Complessivamente sono stati analizzati **106 tipi diversi di smells**.

15.4.2 Ruolo di SonarQube e dei quality gates

Nel contesto industriale illustrato, **SonarQube** viene usato per identificare gli smells nel codice e per supportare la gestione del debito tecnico. Inoltre, vengono utilizzati i **quality gates**, cioè regole che bloccano automaticamente l'accettazione di commit o push request quando il codice supera determinate soglie di qualità.

Solo nelle slide (non spiegato a voce)

Nel materiale è mostrato anche un esempio di output di SonarQube, in cui viene segnalato uno smell dovuto alla presenza di linee di codice commentate invece che rimosse.

15.4.3 Avoiding smells vs removing smells

Lo studio insiste sulla differenza tra due strategie:

- **removing smells**, cioè eliminare gli smells dopo che sono già entrati nella codebase, tipicamente tramite refactoring;
- **avoiding smells**, cioè impedire che entrino fin dall'inizio, per esempio bloccando il codice non conforme tramite quality gates.

La seconda strategia è considerata particolarmente interessante perché impedisce l'accumulo del debito tecnico e riduce il rischio di dover poi rifattorizzare codice già integrato.

15.4.4 Vantaggi e svantaggi dell'evitare smells a priori

Evitare gli smells a priori ha diversi vantaggi: impedisce l'accumulo progressivo di technical debt, evita parte dei rischi connessi al refactoring e rende più semplice mantenere il codice sotto controllo nel tempo.

Esistono però anche svantaggi importanti. Questa strategia richiede infrastrutture e tool adeguati, è applicabile soprattutto al nuovo codice e può entrare in conflitto con

obiettivi di business come il **time-to-market**. In alcuni contesti aziendali, accettare una certa quantità di smells può quindi essere una scelta intenzionale e ragionevole.

15.5 Metodo dello studio

Il metodo proposto si articola in **cinque step** principali:

1. **metric selection**;
2. **metric collection**;
3. **dataset manipulation**;
4. **model selection**;
5. **estimation results**.

L'intero studio può essere letto come una pipeline in cui si parte dalla scelta delle metriche, si raccolgono i dati, si costruiscono scenari sintetici, si seleziona il classificatore più adatto e infine si stima l'impatto dell'assenza di smells sulla difettosità.

15.6 Metric selection e metric collection

15.6.1 Perché servono metriche oltre a Size e NSmells

Per costruire un predittore credibile non basta conoscere la dimensione del file o il numero di smells presenti. È necessario considerare anche metriche capaci di descrivere l'evoluzione del file e le attività di manutenzione subite durante una release.

15.6.2 Ruolo delle change metrics

Le **change metrics** sono state selezionate perché ampiamente usate in letteratura per la **defect estimation**. Esse descrivono sia aspetti di prodotto sia aspetti di processo, e aiutano a catturare il comportamento storico del file durante lo sviluppo.

15.6.3 Tabella delle metriche

Solo nelle slide (non spiegato a voce)

La tabella delle metriche include, oltre a **NSmells**, anche metriche come **Size**, **LOC_touched**, **NR**, **NFix**, **NAuth**, **LOC_added**, **Churn**, **ChgSetSize**, **Age** e **WeightedAge**. Nel complesso, queste variabili descrivono quanto un file sia grande, quanto venga modificato, da quanti sviluppatori venga toccato e quanto sia esposto a dinamiche di manutenzione.

15.6.4 Raccolta dei dati con SonarQube

La raccolta delle metriche è stata eseguita usando **SonarQube**, che nel contesto del paper viene descritto come capace di identificare fino a **1297 tipi di smells**. Nel dataset studiato sono stati raccolti **6912 smells** complessivi.

15.6.5 Differenza temporale tra smells e difetti

Un punto metodologico cruciale è la differenza temporale tra le misurazioni:

- gli **smells** e la **dimensione del file** vengono misurati all'**inizio** della release;
- le **change metrics** e i **difetti** vengono misurati alla **fine** della release.

Questa scelta serve a rispettare la direzione temporale del fenomeno: gli smells devono essere già presenti prima che possano influenzare il lavoro degli sviluppatori e contribuire all'introduzione di difetti.

Nota del Prof

L'idea è che gli smells funzionino come una sorta di trappola o di fattore di rischio. Per poter influenzare negativamente chi modifica il codice, devono esistere già nel momento in cui inizia la manutenzione del file.

15.6.6 Significato del diagramma di raccolta dati

Solo nelle slide (non spiegato a voce)

Il diagramma di raccolta dati per release e file mostra visivamente una *release window* in cui gli smells sono osservati in prossimità della **first revision**, mentre churn e defects vengono osservati alla **last revision**. Il messaggio principale è che le cause potenziali vengono misurate prima degli effetti osservati.

15.7 Dataset manipulation

15.7.1 Definizione dei dataset A, B+, B e C

La manipolazione del dataset introduce quattro insiemi distinti:

- **A**: il dataset originale, non alterato;
- **B+**: la porzione di A che contiene solo file con almeno uno smell, cioè $NSmells > 0$;
- **C**: la porzione di A che contiene file senza smells, cioè $NSmells = 0$;
- **B**: il dataset sintetico ottenuto da B+ azzerando artificialmente la feature $NSmells$.

15.7.2 Perché B rappresenta lo scenario sintetico

Il dataset **B** rappresenta il vero **what-if scenario**. I file sono gli stessi di B+, ma la presenza di smells viene forzata a zero. In questo modo si costruisce una versione artificiale dei file originariamente “smelly”, come se tali smells fossero stati evitati fin dall'inizio.

15.7.3 Media delle feature e correlazione

Solo nelle slide (non spiegato a voce)

Nel materiale viene mostrata una tabella con la media delle feature nei dataset A, B e C e con la correlazione rispetto a **NSmells** e **Defectiveness**. Il messaggio importante è che **NSmells** ha una correlazione significativa ma non fortissima con la defectiveness, e non mostra una collinearità dominante con le altre change metrics. Questo suggerisce che la feature trasporta un'informazione aggiuntiva e non banalmente ridondante.

15.7.4 Messaggio metodologico della manipolazione

La manipolazione del dataset non ha soltanto un valore pratico, ma anche metodologico. Il paper giustifica l'uso del modello appreso su A per fare predizioni su B mostrando che, salvo eccezioni limitate, A e B non risultano trattabili come popolazioni radicalmente diverse. Ciò rende più plausibile applicare il classificatore addestrato sul dataset reale a uno scenario sintetico ottenuto modificando la sola feature **NSmells**.

15.8 Model selection

15.8.1 Classificatori confrontati

I modelli confrontati sono i seguenti:

- **Bagging**;
- **BayesNet**;
- **J48**;
- **Logistic**.

15.8.2 Uso della leave-one-out cross-validation

Per misurare in modo rigoroso le performance dei modelli, viene utilizzata la **leave-one-out cross-validation**. Questa tecnica è particolarmente adatta quando il dataset disponibile non è enorme e si vuole sfruttare al massimo l'informazione presente, mantenendo comunque una validazione severa.

15.8.3 Criterio di scelta del modello migliore

Il criterio di scelta si basa soprattutto sul bilanciamento tra **Precision** e **Recall**. L'idea non è selezionare un modello che sia semplicemente aggressivo nel trovare positivi, ma uno che riesca anche a farlo in modo sufficientemente affidabile.

15.8.4 Perché Bagging risulta il migliore

Il modello **Bagging** risulta il migliore nel materiale perché ottiene i valori migliori nel confronto mostrato, con una **Precision pari a 0.79** e una **Recall pari a 0.70**. Rispetto agli altri tre classificatori, offre quindi il compromesso più convincente tra capacità di trovare file difettosi e affidabilità delle predizioni positive.

15.9 Results

15.9.1 Applicazione del modello ai dataset A, B+, B e C

Una volta scelto il modello migliore, cioè **Bagging**, esso viene addestrato sul dataset A e poi applicato ai dataset A, B+, B e C per stimare il numero di **defective files** nei diversi scenari.

15.9.2 Interpretazione del passaggio da 66 a 38 defective files in B+

Nel sottoinsieme **B+**, cioè tra i file che originariamente avevano almeno uno smell, il numero di file difettosi passa da **66** a **38** quando si considera il dataset sintetico **B**, in cui gli smells sono stati azzerati.

Questo significa che **28 file** sarebbero potenzialmente stati risparmiati, con una riduzione del:

$$\frac{66 - 38}{66} = 42\%$$

Questa percentuale va letta come una riduzione interna al solo gruppo dei file che in origine erano affetti da smells.

15.9.3 Riduzione complessiva del 20% su A

Nel dataset complessivo **A** erano presenti **135 defective files**. Se 28 di essi risultano potenzialmente evitabili nello scenario senza smells, allora la riduzione globale stimata sull'intero dataset è pari a:

$$\frac{66 - 38}{135} \approx 20\%$$

Il risultato complessivo del paper è quindi che circa **il 20% dei file difettosi totali** potrebbe essere stato evitato se gli smells fossero stati prevenuti.

15.9.4 Differenza tra riduzione sui file smelly e riduzione sull'intero dataset

Nota del Prof

È fondamentale non confondere la riduzione del **42%** con quella del **20%**. Il 42% riguarda soltanto il sottoinsieme dei file originariamente smelly, cioè **B+**. Il 20% riguarda invece l'intero dataset **A**. I file presenti in **C** erano già privi di smells ma potevano comunque essere difettosi. Questi rappresentano bug che non sarebbero

stati evitati semplicemente eliminando gli smells, e spiegano perché la riduzione complessiva sia molto più bassa di quella osservata nel solo sottoinsieme smelly.

15.10 Limiti e messaggi chiave

15.10.1 Perché il risultato non implica causalità certa

Il risultato ottenuto non dimostra una causalità certa tra smells e difetti. La **what-if analysis** costruisce una stima controfattuale basata su modelli statistici, non un esperimento controllato in cui le condizioni vengono realmente manipolate nel mondo reale.

15.10.2 Natura ipotetica dello scenario senza smells

L'intero ragionamento si basa su una storia ipotetica: si immagina un software in cui il numero di smells sia pari a zero, ma si mantengano inalterate tutte le altre caratteristiche osservate. Questa è un'assunzione forte e semplificatrice, utile per costruire l'analisi ma non pienamente realistica.

Nota del Prof

Nella realtà, correggere uno smell non significa soltanto cambiare il valore di `NSmells`. Spesso comporta modifiche strutturali che alterano anche altre feature, come la dimensione del file, il churn, il numero di autori o la complessità complessiva. Per questo lo scenario sintetico è utile come strumento di ragionamento, ma non va interpretato come una fotografia perfetta di ciò che sarebbe davvero successo.

15.10.3 Evitare alcuni smells potrebbe non ridurre i difetti

Non tutti gli smells vanno interpretati come fattori che, se rimossi, riducono automaticamente il numero di bug. In alcuni casi, evitare o rimuovere certi smells potrebbe non produrre alcun beneficio rilevante sulla difettosità, e in altri casi potrebbe persino peggiorare la situazione se il codice risultante diventasse più complesso o meno comprensibile.

15.10.4 Casi in cui accettare smells può essere ragionevole

Dal punto di vista industriale, esistono casi in cui accettare una certa quantità di smells può essere una scelta razionale. Per esempio, un'azienda può preferire tollerare alcuni problemi di qualità interna pur di rispettare scadenze rigide, contenere i costi o arrivare rapidamente sul mercato.

15.10.5 Trade-off con costi, effort e time-to-market

Il tema centrale, quindi, non è inseguire sempre e comunque l'obiettivo di **zero smells**, ma bilanciare:

- qualità del codice;
- effort richiesto per prevenire o rimuovere gli smells;

- **time-to-market**;
- **costo complessivo della decisione.**

15.10.6 Contributo principale del paper

Il contributo principale del lavoro non è solo il valore numerico finale del **20%**, ma soprattutto la proposta di un metodo basato su **what-if analysis** per supportare il **decision making** manageriale. Il paper mostra come i dati storici e i modelli predittivi possano essere usati non solo per descrivere il passato, ma anche per ragionare in modo quantitativo su scenari alternativi.

15.10.7 Valore della what-if analysis e ruolo degli smells

Il valore della **what-if analysis** sta nel trasformare il problema degli smells in una domanda decisionale concreta: *vale la pena imporre regole più severe per prevenire gli smells?* Il lavoro suggerisce che gli smells possono rappresentare un fattore collegato alla difettosità e che, almeno in alcuni contesti, evitarli potrebbe ridurre in modo significativo il numero di file difettosi.

15.10.8 Importanza di contestualizzare i risultati

Il messaggio finale è che i risultati devono sempre essere letti nel loro contesto. Non esiste una regola universale secondo cui eliminare gli smells sia sempre la scelta migliore. La bontà della decisione dipende dal tipo di progetto, dai vincoli aziendali, dal processo di sviluppo e dagli obiettivi di business.

In sintesi, il paper propone una metodologia utile per ragionare su un trade-off reale della Software Engineering: **quanto conviene investire oggi nella qualità interna del codice per ridurre i costi e i difetti di domani.**

INIZIO DEANGELIS

Capitolo 16

Panoramica del modulo di Software Testing

16.1 Introduzione al modulo

Questa è la lezione introduttiva al modulo di **Software Testing** di **Ingegneria del Software 2**. Il modulo ha l'obiettivo di mostrare come migliorare la qualità del software in produzione attraverso processi, metodologie e tecnologie di testing.

Il corso è tenuto da **Guglielmo De Angelis**, ricercatore presso il gruppo **SaKS** del **CNR (IASI)** di Roma. Le sue aree di ricerca includono:

- modellazione dei sistemi software;
- modellazione di proprietà extra-funzionali;
- generazione automatica a partire da modelli;
- architetture orientate ai servizi;
- software testing.

16.2 Informazioni organizzative

Le lezioni si tengono il **mercoledì**, dalle **11:30 alle 13:30**, in **Aula B14**, fino al **3 giugno 2026**.

Nota del Prof

Di comune accordo con l'aula, si faranno due ore di lezione consecutive, iniziando in orario e finendo puntuali, senza pause intermedie. Non sono previsti ponti o riduzioni del calendario.

16.2.1 Canali Teams

Sono previsti due canali principali:

- il **canale Generale**, usato per informazioni di carattere generale e per la condivisione delle slide;

- il **canale Software Testing**, dedicato alle domande specifiche sugli argomenti del modulo e sul progetto d'esame.

16.2.2 Ricevimento e comunicazione

Nota del Prof

È preferibile porre i propri dubbi direttamente in aula, così che tutti possano ascoltare le risposte. In alternativa, è fortemente consigliato usare la mailing list associata al canale Teams, in modo da discutere i problemi collettivamente anche nella lezione successiva.

IMPORTANTE PER L'ESAME

Il docente non legge in modo sincrono i messaggi diretti su Teams. Le richieste vanno fatte sempre via mail, preferibilmente mettendo in copia il canale Teams del modulo. Le mail private al docente devono essere usate solo per questioni strettamente personali.

Quando il corso non è attivo, il ricevimento avviene solo su appuntamento via email.

16.3 Sillabo del modulo

Il sillabo segue una progressione che parte dalle basi e arriva fino alla generazione automatica dei test:

- **Intro and General Concepts;**
- **Test Automation e Continuous Testing;**
- **Unit and Integration Testing;**
- **Approaches to Test Generation;**
- **Adequacy of the Tests: Control Flow Coverage;**
- **Adequacy of the Tests: Mutation Testing;**
- **Coverage-based Approaches to Test Generation.**

16.4 Materiale didattico

Solo nelle slide (non spiegato a voce)

Tra i testi di riferimento compaiono, tra gli altri, **A.P. Mathur** con *Foundations of software testing*, **B. Garcia** e **P. Tahchiev et al.** per la parte su **JUnit**, **W.E. Lewis** per il testing e il miglioramento continuo della qualità, e **J. Humble** con **D. Farley** per la *Continuous Delivery*.

Nota del Prof

Le slide sono sintesi drastiche dei concetti. Studiare solo sulle slide non basta: è necessario approfondire sui libri. Il testo di Mathur è molto utile per la parte teorica, mentre i libri su JUnit sono più vicini a una manualistica tecnica da consultare per la pratica.

16.5 Modalità di esame

Il lavoro richiesto è **strettamente individuale** e consiste nell'applicare le tecniche del corso a **due classi differenti** appartenenti a un **progetto open-source** della **Apache Software Foundation**.

I sorgenti del progetto devono essere disponibili su **GitHub** e lo studente deve configurare l'ambiente di lavoro del progetto.

Nota del Prof

Si consiglia fortemente di partire da un *fork* personale del progetto su GitHub. In questo modo, se durante il lavoro si individua un bug reale, è anche possibile aprire una *pull request* verso il progetto originale.

IMPORTANTE PER L'ESAME

È richiesta la configurazione di un framework di **Continuous Integration**, ad esempio GitHub Actions o TravisCI. È possibile lavorare solo in locale, ma un approccio di questo tipo avrà un impatto negativo sulla valutazione finale.

16.6 Attività richieste: generazione dei test

16.6.1 Scelta delle classi

IMPORTANTE PER L'ESAME

Il docente raccomanda esplicitamente di non scegliere classi banali, né classi legate alla GUI. In questi casi sarebbe difficile dimostrare l'apprendimento dei concetti del corso.

Solo nelle slide (non spiegato a voce)

Se si intuisce che una classe raggiungerà subito il 100% di coverage senza sforzo, è consigliato contattare il docente.

16.6.2 Test manuali

Su ciascuna classe bisogna definire un insieme di test tramite **category partition**, adottando preferibilmente un approccio **black-box** basato sulle funzionalità esplicite o implicite della classe.

16.6.3 Test automatici

Occorre poi generare automaticamente altri test usando tre approcci distinti:

- approcci **randomici**;
- approcci basati su **LLM** e sperimentazione di diversi prompt;
- approcci guidati da **coverage control-flow**.

16.6.4 Integrazione nel build

Nota del Prof

Per evitare problemi di configurazione e interferenze, è consigliabile disabilitare o rimuovere tutti i test nativi del progetto Apache, lasciando nel ciclo di build soltanto i test sviluppati da voi.

16.7 Valutazione della qualità dei test

La qualità dei test deve essere validata scegliendo almeno **due metriche di adeguatezza**, non necessariamente calcolate da tool automatici, e confrontando i valori ottenuti.

Occorre inoltre:

- valutare la significatività dei test rispetto alle funzionalità attese;
- migliorare i test manuali aumentando la loro adeguatezza;
- applicare tecniche di **mutation testing**;
- aggiungere nuovi test per migliorare la robustezza della suite;
- stimare la **reliability** del sistema assumendo un profilo operativo uniforme.

Solo nelle slide (non spiegato a voce)

Per consentire il completamento della build, quando necessario è possibile disabilitare temporaneamente i test che falliscono, purché la cosa venga documentata.

Nota del Prof

Se un test fallisce sulla classe originale, ci sono due possibilità: o il test è stato scritto male e quindi va corretto, oppure avete scoperto un bug reale, che va documentato e gestito separatamente.

16.8 Varianti delle classi e uso degli LLM

La parte finale del progetto riguarda l'evoluzione del sistema e il comportamento dei test quando il codice cambia.

A partire dalla classe originale C_0 , bisogna chiedere a un LLM di generare quattro varianti di refactoring:

$$C_1, C_2, C_3, C_4$$

Nota del Prof

Il fulcro dell'esperimento è fornire all'LLM quantità crescenti di informazione. In particolare:

- C_1 : si fornisce solo la classe originale e si chiede il refactoring;
- C_2 : si chiede il refactoring imponendo il passaggio dei test black-box;
- C_3 : si aggiunge anche il vincolo di passare i test di control flow;
- C_4 : si impone il passaggio di tutti i test, inclusa la mutation analysis.

Occorre poi:

- eseguire tutti i test originari sulle varianti;
- verificare se le funzionalità iniziali siano state mantenute;
- generare nuovi test automatici per le varianti;
- confrontare qualitativamente i test delle varianti con quelli della classe originale.

Nota del Prof

Se la variante C_4 non supera un test che era stato fornito esplicitamente come vincolo all'LLM, significa che l'LLM ha fallito il refactoring.

16.9 Report finale e consegna

Lo studente deve redigere un **report dettagliato** in cui descrive:

- le attività svolte;
- le decisioni prese;
- la metodologia seguita;
- i problemi affrontati;
- i risultati ottenuti.

Il report ideale ha una lunghezza di circa **12 pagine A4**, a interlinea singola, carattere 10, font Arial, in formato PDF.

Nota del Prof

Le 12 pagine si riferiscono al testo descrittivo vero e proprio. Figure, tabelle e listati di codice vanno inseriti alla fine, come allegati, e referenziati nel testo.

IMPORTANTE PER L'ESAME

Non bisogna usare figure, tabelle o didascalie come scorciatoia per spostare fuori dal conteggio l'analisi testuale. Le tabelle mostrano i dati; la discussione e l'interpretazione devono stare nel corpo del report.

16.9.1 File `classes.txt`

Va inoltre consegnato un file di testo chiamato `classes.txt`, contenente i nomi completi delle classi considerate, in ordine alfabetico, nel formato:

$$\langle nomePackage \rangle . \langle nomeSubPackage \rangle . \dots \langle nomeClasse \rangle$$

16.9.2 Invio e discussione orale

Il report e il file `classes.txt` vanno inviati via email al docente entro le scadenze pubblicate su Teams. L'esame orale consiste nella presentazione e discussione del report.

Nota del Prof

I link al repository GitHub e al framework di CI dovrebbero essere inseriti esplicitamente nel report oppure nella mail di consegna.

16.10 Messaggi chiave della lezione

IMPORTANTE PER L'ESAME

Il docente valuterà la comprensione critica del lavoro svolto. Non basta riportare un valore numerico, per esempio un coverage del 37%: bisogna spiegare perché si è ottenuto quel valore e quali implicazioni ha.

Nota del Prof

Quando si generano le varianti C_1 – C_4 con l'LLM, conviene sempre iniziare una nuova sessione di chat fresca, in modo da evitare che il modello venga influenzato dai prompt precedenti e produca varianti troppo simili tra loro.

In sintesi

Il modulo di Software Testing prevede un esame basato su un progetto individuale rigoroso. Lo studente deve lavorare su due classi non banali di un progetto Apache, generare e valutare test con approcci diversi, integrare i test in una pipeline di build, studiare l'effetto delle mutazioni e delle varianti generate con LLM, e infine documentare tutto in un report tecnico dettagliato da discutere oralmente.